

Le LAR(s)

et autres algorithmes de suivi de chemin de régularisation

Stéphane Canu, Gilles Gasso et Alain Rakotomamonjy

LITIS
INSA de Rouen, France
St Etienne du Rouvray, France
Stephane.Canu@insa-rouen.fr

Paris, 21 Mai 2007

1 Définition et principe du chemin de régularisation

- Sélection de modèle : choisir λ
- Chemin de régularisation et parcimonie

2 Exemples de critères de type ℓ_1

3 le LAR(s)

- Le principe
- L'algorithme du LAR
- LARS et LASSO

4 SVR

- Principe

Notations

- Moindres carrés

$$\text{Cout : } S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2$$

$$\text{prédictions : } \hat{\mu} = X\beta = \sum_{j=1}^d \mathbf{x}_j \beta_j \quad X = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \dots & \mathbf{x}_j & \dots & \mathbf{x}_d \end{bmatrix}$$

$$\text{solution : } \beta_{\text{MC}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

- Ridge régression

$$\text{Pénalisation : } T(\beta) = \|\beta\|^2 = \sum_{j=1}^d \beta_j^2 \quad \beta(0) = \beta_{\text{MC}}$$

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$$

$$\beta(\infty) = 0$$

$$\text{Solution : } \beta(\lambda) = (X^\top X + \lambda I)^{-1} X^\top \mathbf{y}$$

Définition

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$$

Chemin de régularisation de la ridge

$$\{\beta(\lambda) \mid \lambda \in [0, \infty]\}$$

Calcul du chemin de régularisation :

$$\beta(\lambda^{\text{NEW}}) = \phi(\beta(\lambda^{\text{OLD}}))$$

Point de départ facile : $\beta(0) = \beta_{\text{MC}}$; ou $\beta(\infty) = 0$

Avantages ?

- efficace pour trouver β dans **certains cas** , certains S ou T
- trouver le bon λ
- générique : cas non convexe

Redémarrage à chaud vs. chemin de régularisation

$$\min_{\alpha \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$$



- Tantque on a pas trouvé le bon λ
 - 1 choisir un λ
 - 2 $\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$
 - 3 évaluer la solution
- Pour tous les λ calculer systématiquement tous les $\beta(\lambda)$
 - $\lambda = \infty \implies \beta(\infty) = 0$
 - $\lambda = 0 \implies \beta(0) = \beta_{\text{MC}}$

Chemin de régularisation

$$\{\beta(\lambda) \mid \lambda \in [0, \infty[\}$$

Sélection de modèle : choisir λ

exemples de chemins de régularisation



Avantages ?

- efficace pour trouver β dans certains cas, certains S ou T
- trouver le bon λ
- générique : cas non convexe

Sélection de modèle : choisir λ

Un autre exemple : le chemin du OC SVM

dans quels cas

cas favorable au chemin de régularisation

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta) \quad \Leftrightarrow \quad \{\beta(\lambda) \mid \lambda \in [0, \infty]\}$$

- quand on sait le calculer efficacement

 $\Rightarrow$ linéaire par morceau

$$\beta^{\text{NEW}} = \beta^{\text{OLD}} + (\lambda^{\text{NEW}} - \lambda^{\text{OLD}})\mathbf{u}$$

- linéaire par morceau

 $\Rightarrow$ un des critères S ou T est ℓ_1

- un critère ℓ_1

 $\Rightarrow$ parcimonie : plein de $\beta_j = 0$

parcimonie contraintes actives

quels choix pour S et T ?Il faut du ℓ_1

dans quels cas

Chemin de régularisation linéaire par morceau

cas convexe [Rosset & Zhu, 07]

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$$

① linéaire par morceau : $\lim_{\varepsilon \rightarrow 0} \frac{\beta(\lambda + \varepsilon) - \beta(\lambda)}{\varepsilon} = \text{constante}$

② optimalité

$$\nabla S(\beta(\lambda)) + \lambda \nabla T(\beta(\lambda)) = 0$$

$$\nabla S(\beta(\lambda + \varepsilon)) + (\lambda + \varepsilon) \nabla T(\beta(\lambda + \varepsilon)) = 0$$


③ développement de Taylor

$$\frac{\beta(\lambda + \varepsilon) - \beta(\lambda)}{\varepsilon} = (\nabla^2 S(\beta(\lambda)) + \lambda \nabla^2 T(\beta(\lambda)))^{-1} \nabla T(\beta(\lambda)) + \mathcal{O}(\varepsilon)$$

$$\nabla^2 S(\beta(\lambda)) = \text{constante} \quad \text{et} \quad \nabla^2 T(\beta(\lambda)) = 0$$

l'un quadratique et l'autre linéaire par morceau

Le monde bouge



The Gaussian Hare and the Laplacian Tortoise

Computability of ℓ_1 vs. ℓ_2 Regression Estimators.

Portnoy & Koenker 1997

cas favorable au chemin de régularisation

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta) \quad \Leftrightarrow \quad \{\beta(\lambda) \mid \lambda \in [0, \infty]\}$$

- quand on sait le calculer efficacement

$\Rightarrow$ linéaire par morceau

$$\beta^{\text{NEW}} = \beta^{\text{OLD}} + (\lambda^{\text{NEW}} - \lambda^{\text{OLD}})\mathbf{u}$$

- linéaire par morceau

$\Rightarrow$ un des critères S ou T est ℓ_1

- un critère ℓ_1

$\Rightarrow$ parcimonie : plein de $\beta_j = 0$

parcimonie contraintes actives

pourquoi ℓ_1 entraine t'il de la parcimonie ?

Définition : Ensemble d'homogénéité forte (variables)

$$I_0 = \{i \in \{1, \dots, d\} \mid \beta_i = 0\}$$

Théorème

Régulier si $S(\beta) + \lambda T(\beta)$ dérivable en 0 et si $I_0(\mathbf{y}) \neq \emptyset$

$$\forall \varepsilon > 0, \exists \mathbf{y}' \in \mathcal{B}(\mathbf{y}, \varepsilon) \text{ tel que } I_0(\mathbf{y}') \neq I_0(\mathbf{y})$$

Singulier si $S(\beta) + \lambda T(\beta)$ **NON** dérivable en 0 et si $I_0(\mathbf{y}) \neq \emptyset$

$$\exists \varepsilon > 0, \forall \mathbf{y}' \in \mathcal{B}(\mathbf{y}, \varepsilon) \text{ on a } I_0(\mathbf{y}') = I_0(\mathbf{y})$$

Critère singulier $\implies$ parcimonie

Nikolova, 2000

critères ℓ_1 ?

la singularité entraîne la parcimonie

cas favorable au chemin de régularisation

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta) \quad \Leftrightarrow \quad \{\beta(\lambda) \mid \lambda \in [0, \infty]\}$$

- quand on sait le calculer efficacement

$\Rightarrow$ plein de $\beta_j = 0$

$$\beta^{\text{NEW}} = \beta^{\text{OLD}} + (\lambda^{\text{NEW}} - \lambda^{\text{OLD}})\mathbf{u}$$

- calculer $\mathbf{u}$
- faire évoluer l'ensemble $I_0 = \{j \mid \beta_j = 0\}$

algorithme de type « contraintes actives »

quelques exemples de critères ℓ_1 ?



Lasso et Basis pursuit

$$\min_{\beta \in \mathbb{R}^d} \|\mathbf{y} - X\beta\|^2 + \lambda \sum_{i=1}^d |\beta_i| \iff \begin{cases} \min_{\beta \in \mathbb{R}^d} \|\mathbf{y} - X\beta\|^2 \\ \text{avec} \sum_{i=1}^d |\beta_i| \leq t \end{cases}$$
$$\iff \begin{cases} \min_{\beta \in \mathbb{R}^d} \sum_{i=1}^d |\beta_i| \\ \text{avec} \|\mathbf{y} - X\beta\|^2 \leq \epsilon \end{cases}$$

Tibshirani, 1996 ; Chen, Donoho & Saunders, 1999 (Basis pursuit) ;
Donoho *et al.*, 2004 - Tropp 2004

LASSO et parcimonie

$$\begin{cases} \min_{\beta \in \mathbb{R}^2} & S(\beta) = \|\mathbf{y} - X\beta\|^2 \\ \text{avec} & T(\beta) = |\beta_1| + |\beta_2| \leq t \end{cases}$$



Support vector regression - SVR

Minimise le cout ε -insensible avec une régularisation ℓ_2

$$\xi = \max(0, |\mathbf{y} - X\boldsymbol{\beta}| - \varepsilon)$$

$$\left\{ \begin{array}{ll} \min_{\boldsymbol{\beta} \in \mathbb{R}^d} & \frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) \\ \text{avec} & -\varepsilon \mathbf{I} - \xi^- \leq \mathbf{y} - X\boldsymbol{\beta} \leq \varepsilon \mathbf{I} + \xi^+ \\ \text{et} & 0 \leq \xi^+; 0 \leq \xi^- \end{array} \right.$$


Vapnik, 1995

dualité variable - exemples

parcimonie par rapport aux exemples

SVR et parcimonie (Smola & Schölkopf)

$$\mathcal{L}(\alpha, \xi, \beta) = \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) - \sum_{i=1}^n \alpha_i^+ (\mathbf{y} - X\beta - \varepsilon - \xi_i^+) - \sum_{i=1}^n \alpha_i^- (-\mathbf{y} + X\beta - \varepsilon - \xi_i^-) +$$



$$\beta = \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) \mathbf{x}_i^\top \iff f(\mathbf{x}) = \sum_{i=1}^n \alpha_i \mathbf{x}_i^\top \mathbf{x}$$

$$\exists i; \alpha_i^+ = \alpha_i^- = 0$$

parcimonie par rapport aux exemples


Model selection

Choose the "correct" values of hyperparameters ν (or ϵ) and λ

Illustration : tube width $\epsilon = 0.25$


Pareto front

Pareto front



Too smooth solution

$\epsilon = 0.25$ and $\lambda = 100$




Model selection

Choose the "correct" values of hyperparameters ν (or ϵ) and λ

Illustration : tube width $\epsilon = 0.25$


Pareto front

Pareto front



Better solution

$\epsilon = 0.25$ and $\lambda = 0.01$




Model selection

Choose the "correct" values of hyperparameters ν (or ϵ) and λ

Illustration : tube width $\epsilon = 0.05$


Pareto front

Pareto front



Too smooth solution

$\epsilon = 0.05$ and $\lambda = 72.2081$




Model selection

Choose the "correct" values of hyperparameters ν (or ϵ) and λ

Illustration : tube width $\epsilon = 0.05$


Pareto front

Pareto front



Convenient solution

$\epsilon = 0.05$ and $\lambda = 1.2328$




Model selection

Choose the "correct" values of hyperparameters ν (or ϵ) and λ

Illustration : tube width $\epsilon = 0.05$


Pareto front

Pareto front



Not enough smooth solution

$\epsilon = 0.05$ and $\lambda = 0.031623$



Le Dantzig selector

$$\begin{cases} \min_{\beta \in \mathbb{R}^d} & \|\beta\|_1 \\ \text{avec} & |X^\top (X\beta - \mathbf{y})| \leq \varepsilon \mathbb{I} \end{cases}$$

C'est de la programmation linéaire

$$\begin{cases} \min_{\beta \in \mathbb{R}^d, \mathbf{u} \in \mathbb{R}^d} & \sum_{i=1}^d u_i \\ \text{avec} & -\mathbf{u} \leq \beta \leq \mathbf{u}; \quad 0 \leq \mathbf{u} \\ \text{et} & -\varepsilon \mathbb{I} \leq X^\top (X\beta - \mathbf{y}) \leq \varepsilon \mathbb{I} \end{cases}$$

Candes & Tao, 2004

pénalisation ℓ_1 - Fidélité ℓ_∞

régulier vs. singulier

$S(\beta)$	$T(\beta)$	Régression	Discrimination
sing.	sing. ℓ_1	Dantzig Selector LP SVR	LP SVM
reg.	sing. ℓ_1	LASSO LARS	régression logistique L1
sing.	reg. ℓ_2	SVR	SVM
reg.	reg. ℓ_2	Ridge	régression logistique Lagrangien SVM

TAB.: SVM et SVR : *support vector machine* et *support vector regression*. LP *linear programming*, LARS *Least angle regression stagewise*.

comparaison empirique




Figure 2: Coefficient profiles as a function of $\|\beta\|_{\ell_1}$ for the Dantzig selector and lasso. There are 64 predictors, the main effects and interactions for the diabetes data. Both paths were truncated at one quarter the norm of the full least-squares fit, to allow us to zoom in on the earlier, more relevant parts of the paths.

Plan de l'exposé

1 Définition et principe du chemin de régularisation

- Sélection de modèle : choisir λ
- Chemin de régularisation et parcimonie

2 Exemples de critères de type ℓ_1

3 le LAR(s)

- Le principe
- L'algorithme du LAR
- LARS et LASSO

4 SVR

- Principe

Notations

- tout est centré - variables explicatives standardisées

$$\sum_{i=1}^n y_i = 0 \quad \sum_{i=1}^n x_{ij} = 0 \quad \sum_{i=1}^n x_{ij}^2 = 1 \quad j = 1, d$$

- Moindres carrés

$$\text{Cout : } S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2$$

$$\text{prédictions : } \hat{\mu} = X\beta = \sum_{j=1}^d \mathbf{x}_j \hat{\beta}_j \quad X = \begin{bmatrix} \vdots \\ \mathbf{x}_1 \mathbf{x}_2 \dots \mathbf{x}_j \dots \mathbf{x}_d \\ \vdots \end{bmatrix}$$

solution :

$$\nabla S(\beta) = 0 \quad \Leftrightarrow \quad \underbrace{X^\top (\mathbf{y} - \hat{\mu})}_{\text{corrélations}} = 0 \quad \Leftrightarrow \quad \beta_{\text{MC}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

une méthode itérative constructive

- le LASSO [Tibshirani 96]

$$\left\{ \begin{array}{l} \min_{\beta \in \mathbb{R}^d} S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec } T(\beta) = \sum_{j=1}^d |\hat{\beta}_j| \leq t \end{array} \right.$$

- Forward Stagewise regression [Weisberg 80]

$$\hat{\mu}^{\text{new}} \leftarrow \hat{\mu}^{\text{old}} + \epsilon \operatorname{sign}(\hat{c}_{\hat{j}}) \mathbf{x}_{\hat{j}}$$


$$\hat{j} = \operatorname{argmax}_{j=1,d} |\hat{c}_j| \quad \hat{c} = X^\top (\mathbf{y} - \hat{\mu}) = \nabla S(\beta)$$

Stagewise = la politique des petits pas


Chemin de régularisation (Hastie 05)

Example: Prostate Cancer Data


Lasso



Forward Stagewise



LAR et Stagewise [Efron et al. 04]



The LAR direction $\mathbf{u}_2$ at step 2 makes an equal angle with $\mathbf{x}_1$ and $\mathbf{x}_2$.

LAR = Stagewise + ϵ optimal et variable

une méthode itérative constructive

$$\begin{array}{llll}
 \beta_0 = 0 & 0 & \vdots & 0 \\
 \hat{\mu}_0 = X\beta_0 = 0 & \vdots & a & \leftarrow \hat{j}_1 \\
 & 0 & 0 & \\
 \beta_1 \leftarrow \beta_0 + \gamma_1 \mathbf{w}_1 & \mathbf{w}_1 = 1 & \leftarrow \hat{j}_1 & \mathbf{w}_2 = \vdots \\
 \hat{\mu}_1 \leftarrow \hat{\mu}_0 + \gamma_1 \mathbf{x}_1 & 0 & & 0 \\
 & \vdots & & b & \leftarrow \hat{j}_2 \\
 \beta_2 \leftarrow \beta_1 + \gamma_2 \mathbf{w}_2 & 0 & & 0 & \\
 \hat{\mu}_2 \leftarrow \hat{\mu}_1 + \gamma_2 \mathbf{u}_2 & & & \vdots &
 \end{array}$$


une approche de type « contraintes active »

$\mathcal{A}$ l'ensemble des variables actives

Le principe

LAR : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Départ : tous les β nuls

LAR : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Projection du résidu sur la variable active

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables




Calcul du pas, équi-corrélation entre le résidu et deux variables

Le principe

LAR : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Projection du résidu sur les variables actives

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables



Calcul du pas

L'algorithme du LAR

$\mathcal{A}$ = l'ensemble des variables *intéressantes*

$$\beta_{k+1} \leftarrow \beta_k + \gamma \mathbf{w}_{k+1} \quad \in \mathbb{R}^d$$

$$\beta_{\mathcal{A}} \leftarrow \beta_{\mathcal{A}} + \gamma \mathbf{w}_{\mathcal{A}} \quad \in \mathbb{R}^{\text{card}(\mathcal{A}) \leq d} \quad \beta_{\mathcal{A}} = \beta_k(\mathcal{A})$$

$$\hat{\mu}_{k+1} \leftarrow \hat{\mu}_k + \gamma \mathbf{u}_{k+1} \quad \in \mathbb{R}^n \quad \mathbf{u} = X\mathbf{w} = X_{\mathcal{A}}\mathbf{w}_{\mathcal{A}}$$

le LAR

- ① trouver la variable à ajouter $j : \mathcal{A} = \mathcal{A} \cup \{j\}$
- ② calculer la direction de descente $(\mathbf{w}, \mathbf{u} = X\mathbf{w} = X_{\mathcal{A}}\mathbf{w}_{\mathcal{A}})$
- ③ calculer le pas de descente γ

L'algorithme du LARS

$$\begin{aligned}\beta_{\mathcal{A}} &\leftarrow \beta_{\mathcal{A}} + \gamma_k \mathbf{w}_{\mathcal{A}} \\ \hat{\mu}_{k+1} &\leftarrow \hat{\mu}_k + \gamma_k \mathbf{u}_k\end{aligned} \quad \{1, \dots, d\} = \mathcal{A} \cup \mathcal{A}^c$$

- ① trouver la **variable à ajouter** j : maximise le gradient

$$j = \operatorname{argmax}_{j \in \mathcal{A}^c} |\nabla_{\beta_{\mathcal{A}^c}} S(\beta)| = |X_{\mathcal{A}^c}^\top (\mathbf{y} - \hat{\mu})| \quad ; \quad \mathcal{A} = \mathcal{A} \cup j$$

- ② la **direction de descente** : méthode du second ordre

$$\mathbf{w}_{\mathcal{A}} = H^{-1} \nabla_{\beta_{\mathcal{A}}} S(\beta) \quad \begin{cases} \nabla_{\beta_{\mathcal{A}}} S(\beta) = X_{\mathcal{A}}^\top (\mathbf{y} - \hat{\mu}) = \mathbf{c} \mathbb{I}_{\mathcal{A}} \\ H = X_{\mathcal{A}}^\top X_{\mathcal{A}} \end{cases}$$

$$(X_{\mathcal{A}}^\top X_{\mathcal{A}}) \mathbf{w}_{\mathcal{A}} = \mathbb{I}_{\mathcal{A}}$$

- ③ calculer le **pas** de descente γ

$$\text{pour concerver la propriété : } X_{\mathcal{A}}^\top (\mathbf{y} - \hat{\mu}) = \mathbf{c}' \mathbb{I}$$

que doit on calculer pour chaque opération

- ① trouver la variable à ajouter j : $\mathcal{O}(n(d - k))$

$$|X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}})|$$

- ② la direction de descente : mise à jour (Choleski update)

$$X_{\mathcal{A}} = X_{\mathcal{A}} \cup s_j X_j \quad s_j = \text{sign}(\hat{c}_j)$$

$$(X_{\mathcal{A}}^{\top} X_{\mathcal{A}}) \mathbf{w}_{\mathcal{A}} = \mathbf{1}_{\mathcal{A}} \quad \mathcal{O}(nk + k^2)$$

- ③ calculer le pas de descente γ , $\mathcal{O}(n(d - k))$

$\Leftrightarrow$ trouver la prochaine variable à ajouter

$$X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}) = \mathbf{c}' \mathbf{1} \quad \Leftrightarrow \quad c' = \max_{j \in \mathcal{A}^c} |\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}})|$$

Calcul du pas $\gamma > 0$ qui conserve l'équicorrélation

Du coté de l'ensemble des variables actives

$$X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_{k+1}) = X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k - \gamma \mathbf{u}) \quad (1)$$

$$= X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k) - \gamma X_{\mathcal{A}}^{\top} \mathbf{u} \quad (2)$$

$$= \mathbf{c} \mathbf{I} - \gamma \mathbf{I} \quad (3)$$

Chaque composante du vecteur des corrélations vaut : $c - \gamma$

$$c - \gamma = \max_{j \in \mathcal{A}^c} |\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_{k+1})| \quad (4)$$

$$= \max_{j \in \mathcal{A}^c} \underbrace{|\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k)|}_{c_j} - \gamma \underbrace{|\mathbf{x}_j^{\top} \mathbf{u}|}_{a_j} \quad (5)$$

au maximum j

$$c - \gamma = \begin{cases} c_j - \gamma a_j \\ -c_j + \gamma a_j \end{cases} \Leftrightarrow \gamma = \min_{j \in \mathcal{A}^c}^+ \left(\frac{c - c_j}{1 - a_j}, \frac{c + c_j}{1 + a_j} \right)$$

γ : le plus petit réel positif pour qu'une variable intègre $\mathcal{A}$

évolution de la corrélation




Figure 3. LARS analysis of the diabetes study. *Left:* estimates of regression coefficients $\hat{\beta}_j$, $j = 1, 2, \dots, 10$; plotted versus $\sum |\hat{\beta}_j|$; plot is slightly different than either Lasso or Stagewise, Figure 1. *Right:* Absolute current correlations as function of LARS step; variables enter active set (2.9) in

Adaptation du LAR au LASSO

$$\left\{ \begin{array}{l} \min_{\beta \in \mathbb{R}^d} S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec } T(\beta) = \sum_{j=1}^d |\hat{\beta}_j| \leq t \end{array} \right.$$

si $\exists j$ tel que β_j change de signe

alors on prend γ tel que $\beta_j = 0$ et cette composante quitte l'ensemble actif $\mathcal{A}$

Théorème 1

Avec la modification décrite ci-dessus,

le LARS donne **les** solutions du LASSO

les solutions = le chemin de régularisation $\beta(t)$

Le chemin de régularisation - Théorème 7

$$\beta(t) = \beta(t_0) - (t - t_0) A_A S_A \mathbf{w}_A$$

$$\textcircled{1} \quad \beta(t) = \operatorname{argmin} \|\mathbf{y} - X_A S_A \beta\|^2 \quad \text{avec} \quad \sum_A s_j \beta_j = t$$

$$\textcircled{2} \quad \mathcal{L}(\beta, \lambda) = \|\mathbf{y} - X_A S_A \beta\|^2 + \lambda (\sum_A s_j \beta_j - t)$$

$$\nabla_{\beta} \mathcal{L}(\beta, \lambda) = S_A^T X_A^T (\mathbf{y} - X_A S_A \beta) + \lambda S_A \mathbb{I} = 0$$

$$\textcircled{3} \quad \nabla \mathcal{L}(t_1) - \nabla \mathcal{L}(t_2) = S_A^T X_A^T X_A S_A (\beta(t_2) - \beta(t_1)) + (\lambda_1 - \lambda_2) S_A \mathbb{I}$$

$$\Leftrightarrow \beta(t_2) - \beta(t_1) = (\lambda_1 - \lambda_2) S_A (X_A^T X_A)^{-1} \mathbb{I}$$

$$\textcircled{4} \quad \mathbf{s}_A (\beta(t_2) - \beta(t_1)) = t_2 - t_1 = (\lambda_1 - \lambda_2) A_A^{-1} ; A_A^{-1} = \mathbb{I}^T (X_A^T X_A)^{-1} \mathbb{I}$$

$$\textcircled{5} \quad \beta(t_2) - \beta(t_1) = (t_1 - t_2) A_A S_A \underbrace{(X_A^T X_A)^{-1} \mathbb{I}}_{\mathbf{w}_A}$$

...est linéaire par morceau

Bilan sur le LAR(s)

Résumons nous

- LARS est efficace
- LARS = LASSO, LARS = *stagewise*
- problèmes de stabilité
→ utiliser plutôt le LARS *stagewise*
- calcule vite le chemin de régularisation
→ point de départ de nouvelles recherches

Plan de l'exposé

1 Définition et principe du chemin de régularisation

- Sélection de modèle : choisir λ
- Chemin de régularisation et parcimonie

2 Exemples de critères de type ℓ_1

3 le LAR(s)

- Le principe
- L'algorithme du LAR
- LARS et LASSO

4 SVR

- Principe



Support Vector Regression

Classical SVR (ϵ -SVR)

- ϵ -insensitive loss + L_2 penalty

$$f = \arg \min_f \frac{1}{N} \sum_{i=1}^N \max(0, |y_i - f(x_i, \beta)| - \epsilon) + \frac{\lambda}{2} \|f\|^2$$

- ϵ : width of the tube
- Problems : choice of ϵ and the regularization parameter λ



Support Vector Regression

● Repartition of the training points

$$\mathcal{L} : y_i - f(x_i) < -\epsilon, \quad \alpha_i = 1, \alpha_i^* = 0$$

hors du tube

$$\mathcal{R} : y_i - f(x_i) > \epsilon, \quad \alpha_i = 0, \alpha_i^* = 1$$

hors du tube

$$\mathcal{C} : |y_i - f(x_i)| < \epsilon, \quad \alpha_i = 0, \alpha_i^* = 0$$

dans le tube



$$\mathcal{E}_{\mathcal{L}} : y_i - f(x_i) = -\epsilon, \quad 0 \leq \alpha_i \leq 1, \alpha_i^* = 0$$

sur le tube

$$\mathcal{E}_{\mathcal{R}} : y_i - f(x_i) = \epsilon, \quad \alpha_i = 0, 0 \leq \alpha_i^* \leq 1$$

sur le tube

- Chemin de régularisation : trouver comment les points x_i circulent entre ces ensembles en lien avec ϵ et λ



Support Vector Regression

- Repartition of the training points

$$\mathcal{L} : y_i - f(x_i) < -\epsilon, \quad \alpha_i = 1, \alpha_i^* = 0$$

hors du tube

$$\mathcal{R} : y_i - f(x_i) > \epsilon, \quad \alpha_i = 0, \alpha_i^* = 1$$

hors du tube

$$\mathcal{C} : |y_i - f(x_i)| < \epsilon, \quad \alpha_i = 0, \alpha_i^* = 0$$

dans le tube



$$\mathcal{E}_{\mathcal{L}} : y_i - f(x_i) = -\epsilon, \quad 0 \leq \alpha_i \leq 1, \alpha_i^* = 0$$

sur le tube

$$\mathcal{E}_{\mathcal{R}} : y_i - f(x_i) = \epsilon, \quad \alpha_i = 0, 0 \leq \alpha_i^* \leq 1$$

sur le tube

- Chemin de régularisation : trouver comment les points x_i circulent entre ces ensembles en lien avec ϵ et λ



Derivation of the λ -path

- Regression function :

$$f(x) = \frac{1}{\lambda} \left(\sum_{i=1}^m (\alpha_i^* - \alpha_i) k(x_i, x) + \beta_0 \right)$$

- At step t : $f^t(x)$ associated to λ^t and $\mathcal{E}_{\mathcal{L}}^t$, $\mathcal{E}_{\mathcal{R}}^t$, $\mathcal{C}^t$, $\mathcal{L}^t$ and $\mathcal{R}^t$
- For $\lambda < \lambda^t$, suppose the sets unchanged. Thus

$$\begin{aligned} \lambda f(x) &= \lambda f(x) - \lambda^t f^t(x) + \lambda^t f^t(x) \\ &= \sum_{i \in \mathcal{E}_{\mathcal{L}}^t \cup \mathcal{E}_{\mathcal{R}}^t} (\delta \alpha_i^* - \delta \alpha_i) k(x_i, x) + \delta \beta_0 + \lambda^t f^t(x) \end{aligned}$$

$\delta \theta = \theta - \theta^t$ unknowns variations of the parameters.

- Sets unchanged $\Rightarrow$ two consequences for the points on the tube
 - $\forall j \in \mathcal{E}_{\mathcal{L}}^t$, $y_j - f^t(x_j) = -\epsilon^t$ and $y_j - f(x_j) = -\epsilon$
 - $\forall j \in \mathcal{E}_{\mathcal{R}}^t$, $y_j - f^t(x_j) = +\epsilon^t$ and $y_j - f(x_j) = +\epsilon$
- Optimality conditions : $(\delta \alpha^* - \delta \alpha)^\top \mathbf{1} = 0$ and $(\delta \alpha^* + \delta \alpha)^\top \mathbf{1} = 0$

Derivation of the λ -path

Tiding all these informations, we have a linear square system of $|\mathcal{E}_{\mathcal{L}}| + |\mathcal{E}_{\mathcal{R}}| + 2$ unknowns $\delta\alpha_i$, with $i \in \mathcal{E}_{\mathcal{L}}$, $\delta\alpha_i^*$ with $i \in \mathcal{E}_{\mathcal{R}}$, $\delta\beta_0 = \lambda b - \lambda^t b^t$ and $\delta d = \lambda \epsilon - \lambda^t \epsilon^t$

$$A \delta \theta = (\lambda - \lambda^t) \mathbf{z}$$

Piecewise linear variation of the parameters

- Parameter variations : $\theta = \theta^t + (\lambda - \lambda^t) A^{-1} \mathbf{z}$
- α^* and α are piecewise linear in λ
- Bias b and width of the tube ϵ are piecewise linear in $1/\lambda$

Determination of next λ - Algorithm

Detection of the points move between the sets

- Points x_i on the tube move inside or outside

From $\mathcal{E}_{\mathcal{L}}$ to $\mathcal{L}$: $\alpha_i = 1$ From $\mathcal{E}_{\mathcal{R}}$ to $\mathcal{R}$: $\alpha_i^* = 1$

From $\mathcal{E}_{\mathcal{L}}$ or $\mathcal{E}_{\mathcal{R}}$ to $\mathcal{C}$: $\alpha_i = 0$ or $\alpha_i^* = 0$

- Points x_i inside or outside move on the tube

From $\mathcal{L}$ to $\mathcal{E}_{\mathcal{L}}$: $f(x_i) = y_i + \epsilon$ From $\mathcal{R}$ to $\mathcal{E}_{\mathcal{R}}$: $f(x_i) = y_i - \epsilon$

From $\mathcal{C}$ to $\mathcal{E}_{\mathcal{L}}$ or $\mathcal{E}_{\mathcal{R}}$

Algorithm

- 1 Fix ν - Initialize λ and the sets
- 2 Solve the linear system
- 3 Detect the points move and deduce the next value of λ
- 4 Update the parameters and the sets
- 5 Run from 2 until a termination criterion is reached

2000 Homotopy [Osborne et al.]

2003 LARS [Efron et al.]

2004 SVM [Hastie et al., Bach et al.]

2004 cas général : linéaire par morceau [Rosset et al.]


2004-06 cas non linéaire : prédiction correction [Friedman et al.]

2004-06 Traitement de nombreux cas particuliers

- Kernel LARS [Guigue et al.]
- ν SVM [Loosli et al.]
- ν SVR [Gasso et al.]
- OC SVM [Rakotomamonjy et al.]
- Laplacian SVM (semi supervisé) [Gasso et al.]

- un algorithme efficace
- parcimonie - n taille moyenne
- limites de l'approche
 - instabilité
 - quand s'arrêter
 - non convexité

- un algorithme efficace
- parcimonie - n taille moyenne
- limites de l'approche
 - instabilité
 - quand s'arrêter
 - non convexité



Compressive imaging
[Baraniuk et al, 2006]

Perspectives

- **passage à l'échelle** : approches stochastique
- **instabilité** - couplage avec les contraintes actives
- **quand s'arrêter ?** : borne adaptée
- **critères non convexes** : linéarisation par morceau

Questions ?

Des questions ?

LAR(s) (et svmpath) en R
Matlab

www-stat.stanford.edu/~hastie

asi.insa-rouen.fr/~vguigue/LARS.html

kernlab cran.r-project.org/src/contrib/Descriptions/kernlab.html

SVR Matlab

asi.insa-rouen.fr/~arakotom

Danzig selector

www.ll-magic.org/

biblio

- Least Angle Regression. Least angle regression, Bradley Efron, Trevor Hastie, Iain Johnstone and Robert Tibshirani ; Annals of statistics, vol. 32 (2), pp.407-499, 2004
- A tutorial on support vector regression, A. Smola and B. Scholkopf, Statistics and Computing 14(3), pp 199-222, 2004
- The Dantzig selector : Statistical estimation when p is much smaller than n , Emmanuel Candes and Terence Tao Submitted to IEEE Transactions on Information Theory, June 2005.
- Two-Dimensional Solution Path for Support Vector Regression, Gang Wang, Dit-Yan Yeung, Frederick H. Lochovsky, ICML, 2006
- Piecewise Linear Regularized Solution Paths, Saharon Rosset, Ji Zhu. Annals of Statistics, to appear, 2007
- Algorithmic linear dimension reduction in the l_1 norm for sparse vectors, A. C. Gilbert, M. J. Strauss, J. A. Tropp, and R. Vershynin, 2006 (submitted).
- An iterative thresholding algorithm for linear inverse problems with a sparsity constraint, I. Daubechies, M. Defrise and C. De Mol, Comm. Pure Appl. Math, 57, pp.1413-1541, 2004.
- Local strong homogeneity of a regularized estimator, Mila Nikolova, SIAM Journal on Applied Mathematics, vol. 61, no. 2, pp. 633-658, 2000.