

Tour d'horizon de l'apprentissage statistique

from Machine Learning to Big Data Analytics

Stéphane Canu


asi.insa-rouen.fr/enseignants/~scanu

Codeur en Seine 2014, Université de Rouen

27 novembre 2014

Plan

- 1 Une définition de l'apprentissage statistique
- 2 Etudes de cas
 - Apprendre à rechercher l'information
 - Apprendre à recommander
- 3 Les principaux algorithmes d'apprentissage
- 4 Les outils pour l'apprentissage statistique



Apprentissage : humain vs. machine

Les apprentissages d'un enfant



- marcher : un an
- parler : deux ans
- raisonner : le reste




Apprentissage : humain vs. machine

Les apprentissages d'un enfant

- marcher : un an
- parler : deux ans
- raisonner : le reste




Apprendre à raisonner



Deux définitions de l'apprentissage

Arthur Samuel (1959)

Machine Learning : Field of study that gives computers the ability to learn without being explicitly programmed.



Tom Mitchell (The Discipline of Machine Learning, 2006)

“How can we build computer systems that automatically improve with experience, and what are the fundamental laws that govern all learning processes?”

A computer program CP is said to learn from experience E with respect to some class of tasks T and performance measure P, if its **performance at tasks in T, as measured by P, improves** with experience E

Une tâche T « apprenable »

Machine Learning



A computer program CP learn from **experience E** with respect to some **class of tasks T** and **performance measure P**, if its performance at **tasks in T**, as **measured by P**, improves with **experience E**

Points clés

- **experience E** : statistiques
- **performance measure P** : optimisation
- **tasks T** : utilité
 - ▶ traduction automatique
 - ▶ jouer aux échec
 - ▶ ...faire ce que l'homme fait



Les tâches T



L'expérience E : les données

capteurs →	variables qualitatives / ordinales / quantitatives
texte →	chaîne de caractères
parole →	temps - série temporelle
images/vidéos →	dépendances 2/3 d
réseaux →	graphes
jeux →	séquences d'interactions
flots →	tickets de caisse, web logs, trafic. . .
étiquettes →	information d'évaluation



Les mégadonnées (volume, vitesse, variété, véracité)

Des données qui arrivent sans qu'on ait décidé de les collecter

→ l'importance des pré-traitements (nettoyage, normalisation, codage. . .)

→ et de la représentation : de la donnée au vecteur

Objectifs, tâches et mesures de performance P

non supervisé
supervisé

- ▶ clustering
- ▶ classification
 - ★ bi classe
 - ★ multi classe
 - ★ détection
- ▶ ordonnancement
- ▶ regression

homogénéité des groupes

nombre d'erreur (0/1)

nombre de non détection

erreur de rang

erreur quadratique

renforcement
expliquer

probabilité de gagner

qualité du résumé

... et semi supervisé, transductif, séquentiel, actif. ...

Généraliser

→ bien faire (minimiser P) sur les futures données qu'on ne connaît pas

Meilleure compréhension du monde à partir d'observations en vue de prédiction



C'est beau mais

→ Comment ça marche ?

Plan

- 1 Une définition de l'apprentissage statistique
- 2 Etudes de cas
 - Apprendre à rechercher l'information
 - Apprendre à recommander
- 3 Les principaux algorithmes d'apprentissage
- 4 Les outils pour l'apprentissage statistique



Une brève histoire des moteurs de recherche

1994




solution manuelle

1995




logique

1996



modèle statistique
+ valeur propre

La recherche sur le web comme un problème de matrice




$$Y = \begin{pmatrix} 0 & 0 & 1/3 & 0 & 0 & 0 \\ 1/3 & 0 & 1/2 & 0 & 0 & 0 \\ 2/3 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1/2 & 1/2 \\ 0 & 0 & 1/3 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1/2 & 0 \end{pmatrix}$$

$\mathbb{P}(\text{visiter la page}) =$ une mesure de l'intérêt de la page

$Y : \mathbb{P}(j \rightarrow i) =$ matrice des transitions

Formalisation du problème



Modèle


$$\mathbb{P}(\text{visiter } p_i) = \sum_j \mathbb{P}(\text{visiter } p_j) \mathbb{P}(j \rightarrow i) + \mathbb{P}(\text{hasard})$$

$$\begin{array}{lcl} \mathbb{P} & = & (1 - \delta) Y \mathbb{P} \\ \textit{observation} & = & \textit{information} + \delta \mathbb{I} \mathbb{P} \\ & & \textit{bruit} \end{array}$$

avec Y la matrice des transitions

et $\mathbb{P}$ le vecteur des probabilités de visiter une page

Formalisation du problème



Modèle

$$\mathbb{P}(\text{visiter } p_i) = \sum_j \mathbb{P}(\text{visiter } p_j) \mathbb{P}(j \rightarrow i) + \mathbb{P}(\text{hasard})$$

$$\begin{array}{lcl} \mathbb{P} & = & (1 - \delta) Y \mathbb{P} \quad + \quad \delta \mathbb{I} \mathbb{P} \\ \text{observation} & = & \text{information} \quad + \quad \text{bruit} \end{array}$$

avec Y la matrice des transitions

et $\mathbb{P}$ le vecteur des probabilités de visiter une page

Problème : retrouver $\mathbb{P}(\text{visiter } p_i)$

$$M \mathbb{P} = \mathbb{P} \quad \text{avec} \quad M = (1 - \delta) Y + \delta \mathbb{I}$$

- C'est un problème de **valeur propre** de très grande taille
- avec $\delta = 0.15$

Les leçons de l'histoire des moteurs de recherche

- l'arrivée des big data
mégadonnées
- innover avec la recherche
fondamentale & académique
créer des partenariats
- poser les problèmes : faire des
maths et des statistiques
programmation à base
d'exemples
- poser les vrai usages : interroger
un moteur de recherche
organiser l'information
au niveau mondial
- business model : la valeur c'est
la requête
vers la recommandation



Plan

2 Etudes de cas

- Apprendre à rechercher l'information
- Apprendre à recommander



La recommandation de tous les jours

amazon.com Hello, Sign in to get [personalized recommendations](#). New customer? [Start here](#)

Your Amazon.com [Today's Deals](#) [Gifts & Wish Lists](#) [Gift Cards](#)

Shop All Departments [Go](#) [Cart](#)

P3 Downloads [Getting Started](#) [Top Downloads](#) [New & Future Releases](#) [Install The MP3 Downloader](#) [Amazon MP3 Suppliers](#)

[PEPSI STUFF](#) MADE WITH AMZN [amazonmp3](#) Drink Pepsi, enter Codes, get M

amazonmp3
Play Anywhere, DRM-Free Music Downloads

[Browse](#)
[Events & Deals](#)
[Green Music & Musicians](#)
[Special Deals](#)
[Pepsi Stuff MP3s](#)
[Genres](#)
[Alternative Rock](#)
[Blues](#)
[Broadway & Vocalists](#)
[Children's Music](#)
[Christian & Gospel](#)
[Classic Rock](#)
[Classical: Instrumental](#)
[Classical: Opera & Vocal](#)
[Country](#)

Hello, Sign in to get [personalized recommendations](#). New customer? [Start here](#)

[Next Generation](#) System
[Easy Decision T](#)
[SPSS Data Mini](#)
[SPSS Whispapper](#)
[Data Mining A](#) report. Get it now!
[Vacation Rental](#) \$1 Switch

[Add by Google](#)
[Next Generation](#) System
[Easy Decision T](#)
[SPSS Data Mini](#)
[SPSS Whispapper](#)
[Data Mining A](#) report. Get it now!
[Vacation Rental](#) \$1 Switch

[E-MC²](#) ~Maniah Casey
[Rihanna Montana](#) ~Rihanna Montana
[Worlds Collide DeL...](#) ~Apocalyptic
[Lady Antebell](#) ~Lady Antebell

[Home](#)
[Documents](#)
[Resources](#)
[Premium](#)
[Upload](#)

[All Documents](#)

[Ads by Google](#)
[Business Contract](#)
[Sample Contract](#)
[Sample Contracts](#)
[Agreement Contract](#)

[How to use PLS path modeling for analyzing multiblock data sets](#)

[DOWNLOAD](#)
[PRINT](#)

Ads by Google

Next Generation PCR RainDanceTech.com/RainDrop A Billion Reactions. Digital Answers. RainDrop dPCR System

Easy Decision Trees www.SmartDraw.com Make Decision Tree Diagrams Fast See Examples. Free Download!

SPSS Data Mining Secrets www.ibm.com/SPSS_data_mining Learn The Keys To Data Mining. Get Your Free SPSS Whitepaper.

Data Mining Automation www.kx.com/datamining Learn why KXEN was named a Leader. Free Forrester Report. Get it now!

Yacation Rental Software www.istamanager.com Website, CRM, PMS & Dist Marketing InstaManager - Do the \$1 Switch

Systemes existants

Libre : Myrrix (facto, Web Mahout), Easyrec (item-based, Web), Duine (multi approches), Propriétaires : KXpro...

Quelle méthode choisir ?

Netflix Challenge (2007-2009)

- Recommandation de films
- Moteur maison : CineMatch
- Améliorer les performances de 10%
- critère : erreur quadratique




Les données

- 450 000 spectateurs
- 17 000 films
- 100 millions d'évaluations (de 1 à 5)
- taux de remplissage : 1,3 %
- test sur les 3 millions les plus récents
- 48 000 téléchargements des données

Faire de la science un sport !

Top contenders for Progress Prize 2007



Netflix Prize

[Home](#) [Rules](#) [Leaderboard](#) [Register](#) [Update](#) [Submit](#) [Download](#)

Leaderboard


10.05%

Display top leaders.


Rank	Team Name	Best Score	% Improvement	Last Submit Time
1	BelKor's Pragmatic Chaos	0.8558	10.05	2009-06-26 18:42:37
Grand Prize - RMSE <= 0.8563				
2	PragmaticTheory	0.8582	9.80	2009-06-25 22:15:51
3	BelKor in BigChaos	0.8590	9.71	2009-05-13 08:14:09
4	Grand Prize Team	0.8593	9.68	2009-06-12 08:20:24
5	Daos	0.8604	9.56	2009-04-22 05:57:03
6	BigChaos	0.8613	9.47	2009-06-23 23:06:52

Les résultats sur Netflix

- erreur initiale : 0.9514
- factorisation - 4 %
- nombres de facteurs - .5 %
- améliorations - 2.5 %
 - ▶ normalisation
 - ▶ poids
 - ▶ temps
- bagging : - 3 % = 0.8563
mélange 100 méthodes



La recommandation comme un problème de matrice



$\langle U_i, V_j \rangle$ une mesure d'appétence de l'utilisateur i pour le produit j

Formalisation du problème

Modèle

$$\begin{array}{rcccl} Y & = & F & + & R \\ \textit{observation} & = & \textit{information} & + & \textit{bruit} \end{array}$$

avec F régulière et R une **matrice** de bruit.

Formalisation du problème

Modèle

$$\begin{array}{rcccl} Y & = & F & + & R \\ \text{observation} & = & \text{information} & + & \text{bruit} \end{array}$$

avec F régulière et R une **matrice** de bruit.


Problème : construire $\hat{F}$ un estimateur de F

$$\min_{\hat{F}} \underbrace{\mathcal{L}(Y, \hat{F})}_{\text{attache aux données}} + \lambda \underbrace{\Omega(\hat{F})}_{\text{pénalisation}}$$

- optimiser un cout bien choisi
- avec $\hat{F} = UV$ factorisation à l'aide de valeurs propres


Les leçons de Netflix

- trop d'efforts spécifiques pour être généralisée
- Modèle statistique : **factorisation** *is the solution*
- prendre en compte **les spécificités** (ici l'effet temps et les feedback implicites)
- une optimisation de type **gradient stochastique**
 - ▶ flexible
 - ▶ qui passe à l'échelle
- quels **usages** pour la recommandation ?



Faire de la science un sport !

- Netflix : un million de dollar pour deux ans de travail
- ...au service des entreprises : Datascience.net
 - ▶ SNCF : Prédiction de la fréquentation des gares SNCF en Ile-de-France
 - ▶ GDF Suez : Modéliser les consommations électriques de sites B2B
- Kaggle : *Go from Big Data to Big Analytics*
 - ▶ Higgs Boson Machine Learning Challenge
proposé par le *Paris-Saclay Center for Data Science*



Il est plus facile d'apprendre les mathématiques que d'essayer de s'en passer
(H. Cartan)

Plan


1 Une définition de l'apprentissage statistique

2 Etudes de cas

- Apprendre à rechercher l'information
- Apprendre à recommander



3 Les principaux algorithmes d'apprentissage

4 Les outils pour l'apprentissage statistique



Les objectifs de l'apprentissage automatique

- Algorithmes d'apprentissage
 - ▶ bonne généralisation
 - ▶ généricité
 - ▶ passage à l'échelle
- Questions théoriques (Vapnik's Book, 1982 - Valiant, 1984)
 - ▶ apprenabilité, sous quelles conditions ?
 - ▶ complexité (en temps, en échantillon)




Une brève histoire de l'apprentissage artificiel

- 1940 Etude de la logique en temps qu'objet mathématique (Shannon, Godel et al).
- 1950 Test de Turing,
1956 Dartmouth conférence : *artificial intelligence*.
- 1960 "*Within a generation ... the problem of creating 'artificial intelligence' will substantially be solved.*"
- 1960 *Le perceptron*
- 1970 *Systèmes experts*
- 1980 *AI Winter & Réseaux de neurones (perceptron non linéaire)*
- 1990 *SVM & COLT*
- 2000 *les applications : Google, Amazon (recommendation), spam filtering, OCR, parole, traduction...*
- 2010 *Big data, Go player*




Top 10 algorithmes en fouille de données

- Arbres de décision (et les forêts)
 - ▶ C4.5,
 - ▶ CART,
- SVM,
- AdaBoost,
- kNN,
- Bayésien
 - ▶ k-Means,
 - ▶ Apriori,
 - ▶ EM,
 - ▶ Naive Bayes,
- PageRank,
-




Top 10 algorithmes en fouille de données


- Arbres de décision (et les forêts)
 - ▶ C4.5,
 - ▶ CART,
- SVM,
- AdaBoost,
- kNN,
- Bayésien
 - ▶ k-Means,
 - ▶ Apriori,
 - ▶ EM,
 - ▶ Naive Bayes,
- PageRank,
- en 2014 un 11 ème : deep networks



Une brève histoire des modes en apprentissage




Une brève histoire de la mode en technology (by Gartner)



Gartner's 2014 Hype Cycle for Emerging Technologies Maps the Journey to Digital Business

<http://www.gartner.com/newsroom/id/2819918>

Une brève histoire de la mode en technology (by Gartner)




Gartner's 2000 Hype Cycle for Emerging Technologies Maps the Journey to Digital Business

<http://www.gartner.com/newsroom/id/2819918>

Quelles propriétés

passage à l'échelle → parcimonie : sélectionner les exemples et les variables
randomisation → traiter la masse par le hasard




$$y = [A_1, A_2, \dots, A_n] \times x + e$$




Plan


- 1 Une définition de l'apprentissage statistique
- 2 Etudes de cas
 - Apprendre à rechercher l'information
 - Apprendre à recommander
- 3 Les principaux algorithmes d'apprentissage
- 4 Les outils pour l'apprentissage statistique





Les outils de la science des données



Les outils de la science des données



Les outils de la science des données



Logiciels (mloss.org)

environ. interactifs

- ▶ R (opensource)
- ▶ Matlab,

Java

- ▶ Weka,
- ▶ Rapid miner,
- ▶ MLib (Spark), spark.apache.org

Python


- ▶ Orange, <http://orange.biolab.si>
- ▶ SciPy, <http://www.scipy.org>
- ▶ Shogun, MLpy, ...

C, C++

- ▶ Vowpal Wabbit, hunch.net/~vw
- ▶ Torch (Lua), <http://torch.ch/>
- ▶ libLinear, libSVM,

ML as a service

- ▶ Google prediction API,
- ▶ Microsoft Azure Machine Learning API,



Question méthode



- ① définir objectifs, les contraintes et les couts
- ② étude préliminaire
 - ▶ récupérer des données
 - ▶ construire un bac à sable
 - ▶ affiner les objectifs et les couts en interagissant avec les données
 - ▶ proposer un modèle et choisir une solution (un alto)
- ③ mise en oeuvre sur de véritable flots de données
 - ▶ randomisation
 - ▶ outils adaptés



New trends in ML fashion : big data

ICML 2014 workshops

- Designing Machine Learning Platforms for **Big Data**
Xiangxiang Meng, Wayne Thompson, Xiaodong Lin
- New Learning Frameworks and Models for **Big Data**
Massih-Reza Amini, Eric Gaussier, James Kwok, Yiming Yang
- Deep Learning Models for Emerging **Big Data** Applications
Shan Suthaharan, Jinzhu Jia
- Unsupervised Learning for Bioacoustic **Big Data**
Hervé Glotin, P. Dugan, F. Chamroukhi, C. Clark, Yann LeCun
- Knowledge-Powered **Deep Learning for Text Mining**
Bin Gao, Scott Yih, Richard Socher, Jiang Bian
- Optimizing Customer Lifetime Value in **Online Marketing**
Georgios Theodorou, Mohammad Ghavamzadeh, Shie Mannor

Comment traiter ces *big data* : data science

this joke makes perfect sense

4 January 2013 12:28

Big data is like teenage sex: everyone talks about it, nobody really knows how to do it, everyone thinks everyone else is doing it, so everyone claims they are doing it




@博海ishi

weibo.com/bohaishi1

New trends in ML fashion : data science



Data science?



Data Scientist Voted Sexiest Job of 21st Century

The Rise of Data Scientists

BEFORE



nobody cared for a
"math geek" in parties.

NOW




People love ~~math~~geeks!
data scientists!
RK

New trends in ML fashion : big data hiring boom




Data Science is the Enabler



Quelques prédictions... à propos du futur

- Data science - Applications
 - ▶ multi compétences
 - ▶ chaine de traitements
- Outils pour l'apprentissage
 - ▶ l'apprentissage sans paramètres (off-the-shelf)
 - ▶ passage à l'échelle (4v - big data - mégadonnées)
- Algorithmes d'apprentissage
 - ▶ optimisation (mégadonnées, non convexe)
 - ▶ dynamique (interactions)
 - ▶ apprendre à apprendre (transfert)
- Théorie de l'apprentissage
 - ▶ la nature de l'information





● livres

- ▶ Bishop, C. M. 1995. Neural Networks for Pattern Recognition. Oxford : Oxford University Press.
- ▶ Duda, R. O., P. E. Hart, and D. G. Stork. 2001. Pattern Classification, 2nd ed. New York : Wiley.
- ▶ Hastie, T., R. Tibshirani, and J. Friedman. 2001. The Elements of Statistical Learning : Data Mining, Inference, and Prediction. New York : Springer.
- ▶ A. Cornuéjols & L. Miclet, "L'apprentissage artificiel. Concepts et algorithmes". Eyrolles. 2 ème éd. 2010.

● conférences

- ▶ xCML, NIPS, COLT, séminaire SMILE, Paris Machine Learning Applications Group

● revues

- ▶ JMLR, Machine Learning, Foundations and Trends in Machine Learning, machine learning survey <http://www.mlsurveys.com/>