

Le calcul du chemin de régularisation pour la ν -SVR

G. Gasso, K. Zapien and S. Canu
gilles.gasso@insa-rouen.fr

LITIS

Laboratoire d'Informatique, Traitement de l'Information, Systèmes.

GRETSI'2007

September 13, 2007, Troyes



Le problème de la régression

Cadre général

- N échantillon $\{x_i, y_i\}_{i=1\dots N}$, $x_i \in \mathcal{X}$, $y_i \in \mathbb{R}$
- le modèle de régression : $f(x, \beta) : \mathcal{X} \rightarrow \mathbb{R}$
- les propriétés souhaitées : précision et régularité

Approche initiale

- **cout:** $L(y_i, x_i, f)$ + **terme de pénalisation :** $P(f)$
- L et P : deux fonction convexes non négatives
- problème d'optimisation

$$\min_f L(y_i, x_i, f) + \lambda P(f)$$

- λ : *trade-off* entre le coût et la pénalisation



Support Vector Regression

ϵ -SVR

- coût ϵ -insensible + pénalité L_2

$$f = \arg \min_f \frac{1}{N} \sum_{i=1}^N \max(0, |y_i - f(x_i, \beta)| - \epsilon) + \frac{\lambda}{2} \|f\|^2$$

- ϵ : largeur du tube
- Problèmes: réglage du ϵ et du paramètre de régularisation λ



Support Vector Regression (suite)

ν -SVR : une autre manière de poser le problème

- intégrer le choix de ϵ dans le problème d'optimisation
- reformulation

$$f = \arg \min_{f, \epsilon} \frac{1}{N} \sum_{i=1}^N \max(0, |y_i - f(x_i, \beta)| - \epsilon) + \nu \epsilon + \frac{\lambda}{2} \|f\|^2$$

t. q. $\epsilon \geq 0$

Propriétés de ν

- hyperparamètre plus « intuitif »: $\nu \in [0, 1]$
- borne sup de la proportion de points hors du tube
- borne inf du nombre de « vecteurs support »


Sélection de Modèle

réglage des hyperparamètres ν (ou ϵ) et λ

Illustration : $\epsilon = 0.25$


Front de Pareto

Pareto front



deux solutions *smooth*

$\epsilon = 0.25$ and $\lambda = 100$




Sélection de Modèle

réglage des hyperparamètres ν (ou ϵ) et λ

Illustration : $\epsilon = 0.25$


Front de Pareto

Pareto front



Meilleure solution

$\epsilon = 0.25$ and $\lambda = 0.01$




Sélection de Modèle

réglage des hyperparamètres ν (ou ϵ) et λ

Illustration : $\epsilon = 0.05$


Front de Pareto

Pareto front



deux solutions *smooth*

$\epsilon = 0.05$ and $\lambda = 72.2081$




Sélection de Modèle

réglage des hyperparamètres ν (ou ϵ) et λ

Illustration : $\epsilon = 0.05$


Front de Pareto

Pareto front



solution correcte

$\epsilon = 0.05$ and $\lambda = 1.2328$




Sélection de Modèle

réglage des hyperparamètres ν (ou ϵ) et λ

Illustration: $\epsilon = 0.05$


Front de Pareto

Pareto front



solution trop irrégulière

$\epsilon = 0.05$ and $\lambda = 0.031623$




Sélection de modèle

réglage des hyper parameters ν et λ

- Deux solutions

- 1 recherche exhaustive dans un ensemble pré défini
 $\{\lambda_0, \dots, \lambda_{\max}\}, \{\nu_0, \dots, \nu_{\max}\}$
- 2 suit du chemin de régularisation




- Valeurs spécifiées par l'utilisateur
- la solution retenue (minimisant une erreur de validation) $f(x)$ dépend de la résolution de la « grille » initiale

Sélection de modèle

réglage des hyper parameters ν et λ

- Deux solutions

- recherche exhaustive dans un ensemble pré défini
 $\{\lambda_0, \dots, \lambda_{\max}\}, \{\nu_0, \dots, \nu_{\max}\}$
- suivit du chemin de régularisation



- pas de « grille » à spécifier
- calcule TOUTES les $f_{\lambda}(x)$
- algorithme EFFICACE

Deux chemins de régularisation

- ν fixé, évolution de $f(x)$ en fonction de λ : λ -path
- λ fixé, évolution de $f(x)$ en fonction de ν : ν -path

Chemin de régularisation pour le ν -SVP
6/15

SVR : optimisation duale

Solution du ν -SVR

- $f(x) = \frac{1}{\lambda} \sum_{i=1}^N (\alpha_i^* - \alpha_i) k(x_i, x) + b$
- $k(., x_i)$: le NOYAU
- $\alpha, \alpha^* \in \mathbb{R}^N$: multiplicateurs de Lagrange (variables duales)

$$\left\{ \begin{array}{ll} \max_{\alpha^{(*)} \in \mathbb{R}^N} & -\frac{1}{2\lambda} (\alpha^* - \alpha)^\top K (\alpha^* - \alpha) + (\alpha^* - \alpha)^\top y \\ \text{t. q.} & \begin{array}{ll} 0 \leq \alpha_i, \alpha_i^* \leq 1, & \forall i \in \{1, \dots, N\} \\ (\alpha^* - \alpha)^\top \mathbf{1}_N = 0, & (\alpha^* + \alpha)^\top \mathbf{1}_N \leq \nu \end{array} \end{array} \right.$$

$\alpha - \alpha^* =$ l'influence de l'exemple x_i dans la solution

SVR : contraintes actives

- Répartition des points disponibles

$$\mathcal{L} : y_i - f(x_i) < -\epsilon, \quad \alpha_i = 1, \alpha_i^* = 0$$

hors du tube

$$\mathcal{R} : y_i - f(x_i) > \epsilon, \quad \alpha_i = 0, \alpha_i^* = 1$$

hors du tube

$$\mathcal{C}_0 : |y_i - f(x_i)| < \epsilon, \quad \alpha_i = 0, \alpha_i^* = 0$$

dans le tube



$$\mathcal{E}_{\mathcal{L}} : y_i - f(x_i) = -\epsilon, \quad 0 \leq \alpha_i \leq 1, \alpha_i^* = 0$$

sur le tube

$$\mathcal{E}_{\mathcal{R}} : y_i - f(x_i) = \epsilon, \quad \alpha_i = 0, 0 \leq \alpha_i^* \leq 1$$

sur le tube

- Chemin de régularisation : suit les mouvements des x_i lorsque les hyperparamètres varient



Chemin de régularisation pour le ν -SVR

SVR : contraintes actives

- Répartition des points disponibles

$$\mathcal{L} : y_i - f(x_i) < -\epsilon, \quad \alpha_i = 1, \alpha_i^* = 0$$

hors du tube

$$\mathcal{R} : y_i - f(x_i) > \epsilon, \quad \alpha_i = 0, \alpha_i^* = 1$$

hors du tube

$$\mathcal{C}_0 : |y_i - f(x_i)| < \epsilon, \quad \alpha_i = 0, \alpha_i^* = 0$$

dans le tube



$$\mathcal{E}_{\mathcal{L}} : y_i - f(x_i) = -\epsilon, \quad 0 \leq \alpha_i \leq 1, \alpha_i^* = 0$$

sur le tube

$$\mathcal{E}_{\mathcal{R}} : y_i - f(x_i) = \epsilon, \quad \alpha_i = 0, 0 \leq \alpha_i^* \leq 1$$

sur le tube

- Chemin de régularisation : suit les mouvements des x_i lorsque les hyperparamètres varient



Dérivation du λ -path

- la solution : $f(x) = \frac{1}{\lambda} \left(\sum_{i=1}^m (\alpha_i^* - \alpha_i) k(x_i, x) + \beta_0 \right)$
- à l'étape t : $f^t(x)$ est associée à λ^t et $\mathcal{E}_{\mathcal{L}}^t$, $\mathcal{E}_{\mathcal{R}}^t$, $\mathcal{C}^t$, $\mathcal{L}^t$ et $\mathcal{R}^t$
- pour $\lambda < \lambda^t$, supposons les ensembles stables. Alors

$$\begin{aligned} \lambda f(x) &= \lambda f(x) - \lambda^t f^t(x) + \lambda^t f^t(x) \\ &= \sum_{i \in \mathcal{E}_{\mathcal{L}}^t \cup \mathcal{E}_{\mathcal{R}}^t} (\delta \alpha_i^* - \delta \alpha_i) k(x_i, x) + \delta \beta_0 + \lambda^t f^t(x) \end{aligned}$$

$\delta \theta = \theta - \theta^t$ les variations (inconnues) des paramètres.

- ensembles inchangés $\Rightarrow$ deux conséquences sur le tube
 - $\forall j \in \mathcal{E}_{\mathcal{L}}^t, y_j - f^t(x_j) = -\epsilon^t$ et $y_j - f(x_j) = -\epsilon$
 - $\forall j \in \mathcal{E}_{\mathcal{R}}^t, y_j - f^t(x_j) = +\epsilon^t$ et $y_j - f(x_j) = +\epsilon$
- conditions d'optimalité : $(\delta \alpha^* - \delta \alpha)^\top \mathbf{1} = 0$ et $(\delta \alpha^* + \delta \alpha)^\top \mathbf{1} = 0$

Dérivation du λ -path

Nous obtenons un système linéaire avec $|\mathcal{E}_{\mathcal{L}}| + |\mathcal{E}_{\mathcal{R}}| + 2$ inconnues $\delta\alpha_i$, avec $i \in \mathcal{E}_{\mathcal{L}}$, $\delta\alpha_i^*$ et avec $i \in \mathcal{E}_{\mathcal{R}}$, $\delta\beta_0 = \lambda b - \lambda^t b^t$ et $\delta d = \lambda \epsilon - \lambda^t \epsilon^t$

$$A \delta\theta = (\lambda - \lambda^t)z$$

variation des paramètres linéaire par morceau

- les variations des paramètres : $\theta = \theta^t + (\lambda - \lambda^t)A^{-1}z$
- α^* et α sont linéaire par morceau en fonction de λ
- le terme de biais b et la largeur du tube ϵ sont linéaire par morceau en $1/\lambda$

Calcul du λ suivant - l'algorithme

Detection des mouvements de points

- les points x_i sur le tube le quittent
 de $\mathcal{E}_{\mathcal{L}}$ vers $\mathcal{L}$: $\alpha_i = 1$ de $\mathcal{E}_{\mathcal{R}}$ vers $\mathcal{R}$: $\alpha_i^* = 1$
 de $\mathcal{E}_{\mathcal{L}}$ ou $\mathcal{E}_{\mathcal{R}}$ vers $\mathcal{C}$: $\alpha_i = 0$ or $\alpha_i^* = 0$
- les points x_i bougent de l'extérieur (ou int.) SUR le tube
 de $\mathcal{L}$ vers $\mathcal{E}_{\mathcal{L}}$: $f(x_i) = y_i + \epsilon$ de $\mathcal{R}$ vers $\mathcal{E}_{\mathcal{R}}$: $f(x_i) = y_i - \epsilon$
 de $\mathcal{C}$ vers $\mathcal{E}_{\mathcal{L}}$ ou $\mathcal{E}_{\mathcal{R}}$

Algorithme

- 1 Fixe ν - Initialisation de λ et des ensembles
- 2 Résolution du système linéaire
- 3 Détection des mouvements de points et calcul de $\lambda(t+1)$
- 4 mise à jour des paramètres et des ensembles
- 5 tant que... des mouvements sont encore possible


Dérivation du ν -path

- calculs analogue au λ -path
- les paramètres sont linéaires par morceau par rapport à ν
- L'algorithme est légèrement modifié

que faire avec ces chemins ?

- il est possible de passer de l'un à l'autre
- et s'arrêter au bon endroit


Efficacité de l'algorithme : problème jouet



- Noyau gaussien avec $\sigma = 0.05$
- calcul du λ -path pour différents ν
- moyennes sur 10 fois

Applications

Efficacité de l'algorithme : problème jouet



- Noyau gaussien avec $\sigma = 0.05$
- calcul du λ -path pour différents ν
- moyennes sur 10 fois

$N = 1500$ - temps de calcul (sec)

	$\nu = 0.01$	$\nu = 0.5$	$\nu = 0.75$
λ -path	1.70 ± 0.076	1.95 ± 0.03	2 ± 0.031
ν -SVR avec redémarrage	4.30 ± 0.053	21.8 ± 0.15	21.15 ± 0.12

gain d'un facteur 10

Applications

efficacité de l'algo : Boston Housing data (UCI repository)

- regression multiple ($x \in \mathcal{R}^{13}$), 506 points
- $N = 406$ pour l'apprentissage
- noyau gaussien avec différents σ
- calcul du λ -path pour différents ν
- moyennes sur 10 fois

$\sigma = 0.1$ - temps de calcul (sec)

	$\nu = 0.01$	$\nu = 0.5$	$\nu = 0.75$
λ -path	12.31 ± 0.34	12.29 ± 0.44	12.27 ± 0.38
ν -SVR avec redémarrage	51.44 ± 0.78	51.63 ± 1.24	51.32 ± 0.95

gain d'un facteur 4

Applications

efficacité de l'algo : Boston Housing data (UCI repository)

- regression multiple ($x \in \mathcal{R}^{13}$), 506 points
- $N = 406$ pour l'apprentissage
- noyau gaussien avec différents σ
- calcul du λ -path pour différents ν
- moyennes sur 10 fois

$\sigma = 1$ - temps de calcul (sec)

	$\nu = 0.01$	$\nu = 0.5$	$\nu = 0.75$
λ -path	0.95 ± 0.32	1.95 ± 0.35	2.06 ± 1.31
ν -SVR avec redémarrage	8.6 ± 1.96	13.08 ± 5.17	13.77 ± 5.15


gain d'un facteur 8

Quand s'arrêter ?

Retour sur l'exemple jouet : λ -path


validation par LOO

Variation of the LOO criterion with respect to $1/\lambda$



détermination automatique de ϵ

Variation of the tube width ϵ with respect to $1/\lambda$



mêmes comportements pour le ν -path

Conclusions et perspectives

chemin de régularisation vs *grid search*

- + on obtient TOUTES les solutions
- + grâce à un algorithme efficace
- + ok pour les problèmes petits ou moyens

perspectives

- une borne adaptée pour bien s'arrêter
- suivit bi directionnel : « valley tracking » (λ et ν)
- adaptation pour les problèmes de grande taille