

# Least Angle Regression (LAR)

**Efron, Hastie, Johnstone, Tibshirani**

**Annals of statistics, vol. 32(2), 2004**

**<http://www-stat.stanford.edu/~hastie>**

Stéphane Canu

LITIS

INSA de Rouen, France

St Etienne du Rouvray, France

[Stephane.Canu@insa-rouen.fr](mailto:Stephane.Canu@insa-rouen.fr)

Rouen, 28 Septembre 2006

# La promesse

- Le problème
  - selection de modèle pour la régression linéaire
  - selection de variable = parcimonie
- La solution
  - un algorithme rapide de type « forward selection »
  - LARS  $\approx$  Lasso
  - LARS  $\approx$  Forward stagewise
  - Critère d'arrêt  $\approx C_p$

## Deux exemples

- Diabete :  $n$  individus et  $m$  variables

$$X = \begin{pmatrix} \text{age} & \text{sex} & \dots & x_{m=10} \\ 59 & 2 & \dots & 87 \\ \vdots & \vdots & \dots & \vdots \\ 36 & 1 & \dots & 92 \end{pmatrix}; \mathbf{y} = \begin{pmatrix} \text{diab.} \\ 151 \\ \vdots \\ 57 \end{pmatrix}$$

| Patient | AGE | SEX | BMI  | BP  | ... Serum Measurements ... |       |    |    |     |     | Response |
|---------|-----|-----|------|-----|----------------------------|-------|----|----|-----|-----|----------|
|         | x1  | x2  | x3   | x4  | x5                         | x6    | x7 | x8 | x9  | x10 | y        |
| 1       | 59  | 2   | 32.1 | 101 | 157                        | 93.2  | 38 | 4  | 4.9 | 87  | 151      |
| 2       | 48  | 1   | 21.6 | 87  | 183                        | 103.2 | 70 | 3  | 3.9 | 69  | 75       |
| 3       | 72  | 2   | 30.5 | 93  | 156                        | 93.6  | 41 | 4  | 4.7 | 85  | 141      |
| 4       | 24  | 1   | 25.3 | 84  | 198                        | 131.4 | 40 | 5  | 4.9 | 89  | 206      |
| 5       | 50  | 1   | 23.0 | 101 | 192                        | 125.4 | 52 | 4  | 4.3 | 80  | 135      |
| 6       | 23  | 1   | 22.6 | 89  | 139                        | 64.8  | 61 | 2  | 4.2 | 68  | 97       |
| ⋮       | ⋮   | ⋮   | ⋮    | ⋮   | ⋮                          | ⋮     | ⋮  | ⋮  | ⋮   | ⋮   | ⋮        |
| 441     | 36  | 1   | 30.0 | 95  | 201                        | 125.2 | 42 | 5  | 5.1 | 85  | 220      |
| 442     | 36  | 1   | 19.6 | 71  | 250                        | 133.2 | 97 | 3  | 4.6 | 92  | 57       |

**Table 1.** Diabetes study. 442 diabetes patients were measured on 10 baseline variables. A prediction model was desired for the response variable, a measure of disease progression one year after baseline.

- microarray :  $n = 38 \ll m = 7126$

- tout est centré - variables explicatives standardisées

$$\sum_{i=1}^n y_i = 0 \quad \sum_{i=1}^n x_{ij} = 0 \quad \sum_{i=1}^n x_{ij}^2 = 1 \quad j = 1, m$$

- Moindres carrés

$$\text{Cout : } S(\hat{\beta}) = \|\mathbf{y} - X\hat{\beta}\|^2 = \|\mathbf{y} - \hat{\mu}\|^2$$

$$\text{prédictions : } \hat{\mu} = X\hat{\beta} = \sum_{j=1}^m \mathbf{x}_j \hat{\beta}_j \quad X = [\mathbf{x}_1 \mathbf{x}_2 \dots \mathbf{x}_j \dots \mathbf{x}_m]$$

solution :

$$\nabla S(\hat{\beta}) = 0 \quad \Leftrightarrow \quad \underbrace{X^\top (\mathbf{y} - \hat{\mu})}_{\text{corrélations}} = 0 \quad \Leftrightarrow \quad \hat{\beta}_{\text{MC}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

- le LASSO [Tibshirani 96]


$$\left\{ \begin{array}{l} \min_{\hat{\beta} \in \mathbb{R}^m} S(\hat{\beta}) = \|\mathbf{y} - X\hat{\beta}\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec } T(\hat{\beta}) = \sum_{j=1}^m |\hat{\beta}_j| \leq t \end{array} \right.$$

- Forward Stagewise regression [Weisberg 80]

$$\hat{\mu}^{\text{new}} \leftarrow \hat{\mu}^{\text{old}} + \epsilon \operatorname{sign}(\hat{c}_j) \mathbf{x}_{\hat{j}}$$

$$\hat{j} = \operatorname{argmax}_{j=1,m} |\hat{c}_j| \quad \hat{c} = X^\top (\mathbf{y} - \hat{\mu}) = \nabla S(\hat{\beta})$$



*Stagewise* = la politique des petits pas



**Figure 1.** Estimates of regression coefficients  $\hat{\beta}_j, j = 1, 2, \dots, 10$ , for the diabetes study. *Left Panel* Lasso estimates, as a function of  $t = \sum_j |\hat{\beta}_j|$ . The covariates enter the regression equation sequentially as  $t$  increases, in order  $j = 3, 9, 4, 7, \dots, 1$ . *Right Panel* The same plot for Forward Stagewise regression. The order of entry is the same as in the Lasso plot.

# LASSO et sélection de variable

$$\begin{cases} \min_{\hat{\beta} \in \mathbb{R}^2} & S(\hat{\beta}) = \|\mathbf{y} - X\hat{\beta}\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec} & T(\hat{\beta}) = |\hat{\beta}_1| + |\hat{\beta}_2| \leq t \end{cases}$$




# Forward Stagewise regression

- ① initialisation :  $\hat{\beta} = 0$  : résidus :  $\mathbf{y} - X\hat{\beta} = \mathbf{y}$
- ② trouver le prédicteur  $\mathbf{x}_{\hat{j}}$  le plus corrélé avec le résidu :

$$\max_{j=1,m} |\hat{\mathbf{c}}| \quad \text{avec} \quad \hat{\mathbf{c}} = X^\top (\mathbf{y} - X\hat{\beta})$$


- ③  $\beta_{\hat{j}} \leftarrow \beta_{\hat{j}} + \epsilon'$  avec  $\epsilon' = \epsilon \operatorname{sign}(\hat{c}_{\hat{j}})$




# Chemin de régularisation (Hastie 05)

## Example: Prostate Cancer Data

Lasso




Forward Stagewise



# Le LAR (S)

## Least **A**ngle **R**egression

- 1 illustration dans  $\mathbb{R}^3$
- 2 l'algorithme de base LAR
- 3 adaptation au LASSO et au *Stagewise* :  
LAR **S** = Lasso & Stagewise



The LAR direction  $\mathbf{u}_2$  at step 2 makes an equal angle with  $\mathbf{x}_1$  and  $\mathbf{x}_2$ .

LAR = Stagewise +  $\epsilon$  optimal et variable

## Le principe

## une méthode itérative constructive


$$\begin{array}{lll}
 \hat{\beta}_0 = 0 & & \vdots \\
 \hat{\mu}_0 = X\hat{\beta}_0 = 0 & & 0 \\
 & & a \leftarrow \hat{j}_1 \\
 & & 0 \\
 \hat{\beta}_1 \leftarrow \hat{\beta}_0 + \gamma_1 \mathbf{w}_1 & \mathbf{w}_1 = \begin{matrix} 0 \\ \vdots \\ 0 \\ 1 \leftarrow \hat{j}_1 \\ 0 \\ \vdots \\ 0 \end{matrix} & \mathbf{w}_2 = \begin{matrix} \vdots \\ 0 \\ \vdots \\ 0 \\ b \leftarrow \hat{j}_2 \\ 0 \\ \vdots \end{matrix} \\
 \hat{\mu}_1 \leftarrow \hat{\mu}_0 + \gamma_1 \mathbf{x}_1 & & \\
 & & \\
 \hat{\beta}_2 \leftarrow \hat{\beta}_1 + \gamma_2 \mathbf{w}_2 & & \\
 \hat{\mu}_2 \leftarrow \hat{\mu}_1 + \gamma_2 \mathbf{u}_2 & & 
 \end{array}$$

**une approche de type « contraintes active »**

$\mathcal{A}$  l'ensemble des variables actives

# LARS : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Départ : tous les  $\beta$  nuls

# LARS : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Projection du résidu sur la variable active

# LARS : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Calcul du pas, équi-corrélation entre le résidu et deux variables

# LARS : corrélation et géométrie (V. Guigue)


Évolution de la solution dans l'espace des variables



Projection du résidu sur les variables actives

# LARS : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables



Calcul du pas

# L'algorithme du LARS

$$\hat{\beta}_{k+1} \leftarrow \hat{\beta}_k + \gamma \mathbf{w}_{k+1} \quad \in \mathbb{R}^m$$

$$\hat{\beta}_{\mathcal{A}} \leftarrow \hat{\beta}_{\mathcal{A}} + \gamma \mathbf{w}_{\mathcal{A}} \quad \in \mathbb{R}^{\text{card}(\mathcal{A})} \quad \hat{\beta}_{\mathcal{A}} = \hat{\beta}_k(\mathcal{A})$$

$$\hat{\mu}_{k+1} \leftarrow \hat{\mu}_k + \gamma \mathbf{u}_{k+1} \quad \in \mathbb{R}^n \quad \mathbf{u} = X\mathbf{w} = X_{\mathcal{A}}\mathbf{w}_{\mathcal{A}}$$

- ❶ trouver la variable à ajouter  $j : \mathcal{A} = \mathcal{A} \cup \{j\}$
- ❷ calculer la direction de descente  $(\mathbf{w}, \mathbf{u} = X\mathbf{w} = X_{\mathcal{A}}\mathbf{w}_{\mathcal{A}})$
- ❸ calculer le pas de descente  $\gamma$

## L'algorithme du LARS

$$\begin{aligned}\hat{\beta}_{\mathcal{A}} &\leftarrow \hat{\beta}_{\mathcal{A}} + \gamma_k \mathbf{w}_{\mathcal{A}} \\ \hat{\mu}_{k+1} &\leftarrow \hat{\mu}_k + \gamma_k \mathbf{u}_k\end{aligned} \quad \{1, \dots, m\} = \mathcal{A} \cup \mathcal{A}^c$$

- 1 trouver la variable à ajouter  $j$  : maximise le gradient

$$j = \operatorname{argmax} |\nabla_{\hat{\beta}_{\mathcal{A}^c}} S(\hat{\beta})| = |X_{\mathcal{A}^c}^\top (\mathbf{y} - \hat{\mu})| \quad ; \quad \mathcal{A} = \mathcal{A} \cup j$$

- 2 la direction de descente : méthode du second ordre

$$\mathbf{w}_{\mathcal{A}} = H^{-1} \nabla_{\hat{\beta}_{\mathcal{A}}} S(\hat{\beta}) \quad \begin{cases} \nabla_{\hat{\beta}_{\mathcal{A}}} S(\hat{\beta}) = X_{\mathcal{A}}^\top (\mathbf{y} - \hat{\mu}) = \mathbf{c} \, \mathbb{I}_{\mathcal{A}} \\ H = X_{\mathcal{A}}^\top X_{\mathcal{A}} \end{cases}$$

$$(X_{\mathcal{A}}^\top X_{\mathcal{A}}) \mathbf{w}_{\mathcal{A}} = \mathbb{I}_{\mathcal{A}}$$

- 3 calculer le pas de descente  $\gamma$

$$\text{pour conserver la propriété : } X_{\mathcal{A}}^\top (\mathbf{y} - \hat{\mu}) = \mathbf{c}' \, \mathbb{I}$$

# que doit on calculer : pour chaque opération

- ❶ trouver la variable à ajouter  $j$  :  $\mathcal{O}(n(n-k))$

$$|X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}})|$$

- ❷ la direction de descente : mise à jour (Choleski update)

$$X_{\mathcal{A}} = X_{\mathcal{A}} \cup s_j X_j \quad s_j = \text{sign}(\hat{c}_j)$$

$$(X_{\mathcal{A}}^{\top} X_{\mathcal{A}}) \mathbf{w}_{\mathcal{A}} = \mathbf{II}_{\mathcal{A}} \quad \mathcal{O}(nk + k^2)$$

- ❸ calculer le pas de descente  $\gamma$ ,  $\mathcal{O}(n(n-k))$

$\Leftrightarrow$  trouver la prochaine variable à ajouter

$$X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}) = \mathbf{c}' \mathbf{II} \quad \Leftrightarrow \quad \mathbf{c}' = \max_{j \in \mathcal{A}^c} |\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}})|$$

# Calcul du pas $\gamma > 0$ qui conserve l'équicorrélation

Du coté de l'ensemble des variables actives

$$X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_{k+1}) = X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k - \gamma \mathbf{u}) \quad (1)$$

$$= X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k) - \gamma X_{\mathcal{A}}^{\top} \mathbf{u} \quad (2)$$

$$= \mathbf{c} \mathbf{I} - \gamma \mathbf{I} \quad (3)$$

Chaque composante du vecteur des corrélations vaut :  $c - \gamma$

$$c - \gamma = \max_{j \in \mathcal{A}^c} |\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_{k+1})| \quad (4)$$

$$= \max_{j \in \mathcal{A}^c} \underbrace{|\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k)|}_{c_j} - \gamma \underbrace{|\mathbf{x}_j^{\top} \mathbf{u}|}_{a_j} \quad (5)$$


au maximum  $j$

$$c - \gamma = \begin{cases} c_j - \gamma a_j \\ -c_j + \gamma a_j \end{cases} \Leftrightarrow \gamma = \min_{j \in \mathcal{A}^c}^+ \left( \frac{c - c_j}{1 - a_j}, \frac{c + c_j}{1 + a_j} \right)$$

$\gamma$  : le plus petit réel positif pour qu'une variable intègre  $\mathcal{A}$


## L'algorithme du LARS

## évolution de la corrélation



**Figure 3.** LARS analysis of the diabetes study. *Left:* estimates of regression coefficients  $\hat{\beta}_j$ ,  $j = 1, 2, \dots, 10$ ; plotted versus  $\sum |\hat{\beta}_j|$ ; plot is slightly different than either Lasso or Stagewise, Figure 1. *Right:* Absolute current correlations as function of LARS step; variables enter active set (2.9) in

# Illustration du LAR



**Figure 4.** At each stage the LARS estimate  $\hat{\mu}_k$  approaches, but does not reach, the corresponding OLS estimate  $\bar{y}_k$ .

# Adaptation du LAR

$$\left\{ \begin{array}{l} \min_{\hat{\beta} \in \mathbb{R}^m} S(\hat{\beta}) = \|\mathbf{y} - X\hat{\beta}\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec } T(\hat{\beta}) = \sum_{j=1}^m |\hat{\beta}_j| \leq t \end{array} \right.$$

si  $\exists j$  tel que  $\beta_j$  change de signe

**alors** on prend  $\gamma$  tel que  $\beta_j = 0$  et cette composante quitte l'ensemble actif  $\mathcal{A}$

## Théorème 1 (page 11)

Avec la modification décrite ci-dessus,

le LARS donne **les** solutions du LASSO

**les** solutions = le chemin de régularisation  $\hat{\beta}(t)$

# Le chemin de régularisation - Théorème 7

$$\hat{\beta}(t) = \hat{\beta}(t_0) - (t - t_0) A_A S_A \mathbf{w}_A \quad (5.17)$$

$$① \quad \hat{\beta}(t) = \operatorname{argmin} \|\mathbf{y} - X_A S_A \beta\|^2 \quad \text{avec} \quad \sum_A s_j \beta_j = t$$

$$② \quad \mathcal{L}(\beta, \lambda) = \|\mathbf{y} - X_A S_A \beta\|^2 + \lambda \left( \sum_A s_j \beta_j - t \right) \\ \nabla_{\beta} \mathcal{L}(\beta, \lambda) = S_A^T X_A^T (\mathbf{y} - X_A S_A \beta) + \lambda S_A \mathbf{I} = 0$$


$$③ \quad \nabla \mathcal{L}(t_1) - \nabla \mathcal{L}(t_2) = S_A^T X_A^T X_A S_A (\beta(t_2) - \beta(t_1)) + (\lambda_1 - \lambda_2) S_A \mathbf{I} \\ \Leftrightarrow \beta(t_2) - \beta(t_1) = (\lambda_1 - \lambda_2) S_A (X_A^T X_A)^{-1} \mathbf{I}$$

$$④ \quad \mathbf{s}_A (\beta(t_2) - \beta(t_1)) = t_2 - t_1 = (\lambda_1 - \lambda_2) A_A$$

$$⑤ \quad \beta(t_2) - \beta(t_1) = (t_1 - t_2) A_A S_A \underbrace{(X_A^T X_A)^{-1} \mathbf{I}}_{\mathbf{w}_A}$$

...est linéaire par morceau

# Front de Pareto : $S(\hat{\beta}(t))$ vs. $T(\hat{\beta}(t))$



**Figure 8.** Plot of  $S$  versus  $T$  for Lasso applied to diabetes data; points indicate the 12 modified LARS steps of Figure 1; triangle is  $(T, S)$  boundary point at  $t = 1000$ ; dashed arrow is tangent at

Quand faut t'il s'arrêter

# Utiliser le $C_p$ de Mallows

$$\mathbf{y} \sim \mathcal{N}(\mu, \sigma^2 I)$$

$$\begin{aligned} (\hat{\mu}_i - y_i)^2 &= (\hat{\mu}_i - \mu_i + \mu_i - y_i)^2 \\ (\hat{\mu}_i - \mu_i)^2 &= (\hat{\mu}_i - y_i)^2 - (\mu_i - y_i)^2 + 2(\hat{\mu}_i - \mu_i)(y_i - \mu_i) \end{aligned}$$

$$\mathbb{E}(\hat{\mu}_i - \mu_i)^2 = \mathbb{E}(\hat{\mu}_i - y_i)^2 - \sigma^2 + 2\text{cov}(\hat{\mu}_i, y_i)$$

$$\mathbb{E} \left( \frac{\|\hat{\mu} - \mu\|^2}{\sigma^2} \right) = \mathbb{E} \left( \frac{\|\hat{\mu} - \mathbf{y}\|^2}{\sigma^2} \right) - n + 2 \sum_{i=1}^n \frac{\text{cov}(\hat{\mu}_i, y_i)}{\sigma^2}$$



$$C_p = \frac{\|\hat{\mu} - \mathbf{y}\|^2}{\sigma^2} - n + 2 \underbrace{\sum_{i=1}^n \frac{\text{cov}(\hat{\mu}_i, y_i)}{\sigma^2}}_{df}$$

$$\widehat{C}_p = \frac{\|\hat{\mu} - \mathbf{y}\|^2}{\hat{\sigma}^2} - n + 2k \quad (\text{eq 4.10})$$

...we do not yet have any mathematical support for this claim.

Quand faut-il s'arrêter

# Quand s'arrêter ?



**Figure 7.**  $C_p$  estimates of risk (4.10) for the two situations of Figure 6. *Left Panel*  $m = 10$  model has smallest  $C_p$  at  $k = 7$ ; *Right Panel*  $m = 64$  model has smallest  $C_p$  at  $k = 16$ .

## Quand faut t'il s'arrêter

## LARS : *Least Angle Regression Stepwise*



**L** : Lissage, Limite, LASSO

**A** : Angulaire, Angle

**R** : Récuratif, Régression, Régularisation

**S** : Système

Idées en vrac : dérivée, chemin de régularisation, équi-corrélation, pas à pas...

Quand faut t'il s'arrêter

# Proposition de francisation (V. Guigue - LIP6)

LARS : *Least Angle Regression Stepwise*



**L** : Lissage, Limite, LASSO

**A** : Angulaire, Angle

**R** : Récursif, Régression, Régularisation

**S** : Système

Idées en vrac : dérivée, chemin de régularisation,  
équi-corrélation, pas à pas...



Lissage Angulaire Récursif pour la Régression  
= LARR = LARs

# Conclusion

## Résumons nous

- LARS est efficace
- LARS = LASSO
- solution du lasso est linéaire par morceau

## extentions

- chemins de régularisation SVM, Regression logistique
- généralisation
- kernelisation...

# Questions ?

## Des questions ?

`http ://www-stat.stanford.edu/~hastie`

code matlab :

`http ://asi.insa-rouen.fr/~vguigue/LARS.html`