

Les machines à noyaux et leur mise en œuvre

le 8 juin 2007

GdR ISIS - ENST Paris

Laboratoire d'Informatique, de Traitement de l'Information et des Systèmes

Stéphane Canu

stephane.canu@litislab.eu



Plan


- 1 L'apprentissage statistique
- 2 Les outils
- 3 Les méthodes à noyau non parcimonieuses
- 4 Les méthodes à noyau parcimonieuses
- 5 Aspects pratiques liés à la mise en œuvre des machines à
- 6 Conclusion

OCR : Base de données MNIST

Exemple (Base de données MNIST)

- ▶ La base de donnée MNIST¹, données = couples « imagerie-étiquette »
- ▶ $n = 60.000$, $d = 700$, nbclasses = 10
- ▶ noyaux : taux d'erreur = 0,56 %, meilleur résultat = 0,4 % d'erreur).


7



8



7



9



deux autres exemples

Exemple (Base de données RCV 1)

La base de données catégorisation, disponible en ligne², contient un ensemble de textes chacun associé à plusieurs catégories. Cette base contient 800.000 textes associés à plus d'un millier de catégories. Sur cette base on peut, soit essayer de retrouver les catégories d'un document (discrimination multiclassées), soit proposer une nouvelle hiérarchie de classement des documents (classification automatique)

Exemple (Base de données *census-house*)

Cette base de données a été construite à partir du recensement de 1990 aux Etats Unis. Elle contient 22 784 cas avec chacun 139 variables explicatives. La variable à prévoir est le prix médian d'une maison dans un quartier. Le projet DELVE³, disponible sur le site internet de l'université de Toronto, recense un ensemble intéressant de problèmes type.

²<http://www.daviddlewis.com/resources/testcollections/rcv1/>

³<http://www.cs.toronto.edu/~delve/data/datasets.html>

Notations

- ▶ $\mathbf{x}$ est le vecteur des variables observées
- ▶ y la variable non observée à prévoir.
- ▶ $\mathbf{x} \in \Omega$ le domaine
- ▶ $y \in \mathcal{Y}$ le codomaine.
- ▶ une fonction f de Ω sur $\mathcal{Y}$
- ▶ un critère ℓ

	Entrée - Forme Domaine Ω	Sortie - étiquette Codomaine $\mathcal{Y}$	Fonction cout ℓ
MNIST	imagerie 28×28 pixels	$\{0, 1, \dots, 9\}$	0/1
RDV 1	une dépêche Reuters l'ensemble des textes	103 sujets classement Reuters	0/1
census-house	$\mathbf{R}^{139}$	$\mathbf{R}$	$(f(\mathbf{x}) - y)^2$

Table: Exemples de domaines d'apprentissage, de codomaines et de fonctions cout.

apprentissage statistique

Definition (problème d'apprentissage théorique)

Soit Ω et $\mathcal{Y}$ deux ensembles. Soit $\mathcal{P}$ une famille de probabilités sur $(\Omega, \mathcal{Y})$. Soit $\mathbb{P}(\mathbf{x}, y) \in \mathcal{P}$ et ℓ une fonction de $\mathcal{Y} \times \mathcal{Y}$ sur $\mathbb{R}$. Trouver la fonction f de Ω sur $\mathcal{Y}$ minimisant $R(f) = \mathbb{E}(\ell(f(X), Y))$.

$\mathbb{P}$ est inconnue on dispose d'un échantillon $\{(\mathbf{x}_i, y_i), i \in [1, n]\}$

Definition (problème d'apprentissage effectif)

Soit $(\mathbf{x}_i, y_i)_{i=1, n}$ un échantillon i.i.d. tiré selon une loi $\mathbb{P} \in \mathcal{P}$ inconnue. Construire $\mathcal{A}$ pour laquelle $\forall \varepsilon > 0$ et $\delta > 0$, il existe un entier n_0 pour lequel $\forall n \geq n_0$:

$$\mathbb{P}\left(R\left(\mathcal{A}((\mathbf{x}_i, y_i)_{i=1, n})\right) - R(f) \geq \varepsilon\right) \leq \delta$$

machines à noyaux

Definition (machine à noyaux)

$$\mathcal{A}((\mathbf{x}_i, y_i)_{i=1,n})(\mathbf{x}) = \psi\left(\sum_{i=1}^n \alpha_i k(\mathbf{x}, \mathbf{x}_i) + \sum_{j=1}^p \beta_j \varphi_j(\mathbf{x})\right)$$

α et β : paramètres à estimer.

Example

$$\mathcal{A}(x) = \sum_{i=1}^n \alpha_i (x - x_i)_+^3 + \beta_0 + \beta_1 x$$

$$\mathcal{A}(\mathbf{x}) = \text{signe}\left(\sum_{i \in I} \alpha_i \exp^{-\frac{\|\mathbf{x} - \mathbf{x}_i\|^2}{b}} + \beta_0\right) \quad \text{avec } I \subset \{1, \dots, n\}$$


$$\mathbb{P}(y|\mathbf{x}) = \frac{1}{Z} \exp\left(\sum_{i \in I} \alpha_i \mathbb{I}_{\{y=y_i\}} (\mathbf{x}^\top \mathbf{x}_i + b)^2\right)$$

Stratégie de résolution du problème

Definition (machine à noyaux)

$$\mathcal{A}((\mathbf{x}_i, y_i)_{i=1,n})(\mathbf{x}) = \psi \left(\sum_{i=1}^n \alpha_i k(\mathbf{x}, \mathbf{x}_i) + \sum_{j=1}^p \beta_j \varphi_j(\mathbf{x}) \right)$$

α_i : influence du point $(\mathbf{x}_i, y_i)$ dans la solution



Plan

1 L'apprentissage statistique

2 Les outils

3 Les méthodes à noyau non parcimonieuses

4 Les méthodes à noyau parcimonieuses

5 Aspects pratiques liés à la mise en œuvre des machines à

6 Conclusion

Au début était le noyau...

Definition (Noyau)

une fonction k de deux variables de $\Omega \times \Omega$ à valeur dans $\mathbb{R}$.

Definition (Noyau positif)

Un noyau $k(s, t)$ sur Ω est dit positif s'il est symétrique et si

$$\forall \{\alpha_i\}_{i=1,n} \in \mathbb{R}, \forall \{\mathbf{x}_i\}_{i=1,n} \in \Omega, \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \geq 0$$

Definition (Matrice de Gram)

Soit $k(s, t)$ un noyau positif sur Ω et $(\mathbf{x}_i)_{i=1,n}$ une suite de points de Ω . On appelle matrice de Gram la matrice carrée K de dimension n et de terme général $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$.

des noyaux...

Les noyaux radiaux, aussi dits stationnaires ou invariants par translation :

$$k(s, t) = k_s(s - t)$$

les noyaux projectifs font intervenir un produit scalaire :

$$k(s, t) = k_p(s^\top t)$$

noyaux dit localement stationnaires :

$$k(s, t) = k_1(s + t)k_s(s - t)$$

et des noyaux sur des histogrammes, des chaines de caractères, des graphes, des objets hétérogènes...

Exemples de noyaux...

type	nom	$k(s, t)$
radial	gaussien	$\exp\left(-\frac{r^2}{b}\right), \quad r = \ s - t\ $
radial	laplacien	$\exp(-r/b)$
radial	rationnel	$1 - \frac{r^2}{r^2 + b}$
radial	loc. gauss.	$\max\left(0, 1 - \frac{r}{3b}\right)^d \exp\left(-\frac{r^2}{b}\right)$
non stat	χ^2	$\exp(-r/b), \quad r = \sum_k \frac{(s_k - t_k)^2}{s_k + t_k}$
projectif	polynôme	$(s^\top t)^p$
projectif	affine	$(s^\top t + b)^p$
projectif	cosinus	$s^\top t / \ s\ \ t\ $
projectif	corrélacion	$\exp\left(\frac{s^\top t}{\ s\ \ t\ } - b\right)$

Table: Quelques exemples de noyaux usuels pour $\Omega = \mathbb{R}^d$. Les noyaux dépendent d'un paramètre de largeur de bande b qui caractérise l'amplitude de leur zone d'influence.

EHNR - RKHS

Definition (espace de Hilbert à noyau reproduisant (EHNR))

Un espace de Hilbert $\mathcal{F}$ muni du produit scalaire $\langle ., . \rangle_{\mathcal{F}}$ est dit « à noyau reproduisant » s'il existe un noyau k pour lequel :



$$\forall s \in \Omega, k(., s) \in \mathcal{F} \text{ et } \forall f \in \mathcal{F}, \quad f(s) = \langle f(.), k(s, .) \rangle_{\mathcal{F}}$$

noyau positif $\Leftrightarrow$ EHNR

- ▶ une fonction peut être évaluée en un point
- ▶ une mesure de corrélation entre deux variables.
- ▶ C'est encore un produit scalaire
- ▶ il exprime une **régularité** de l'espace des hypothèses

Critère d'ajustement : fonction de perte

$$\begin{aligned} \ell : \mathcal{H}, \Omega, \mathcal{Y} &\longrightarrow \mathbb{R}^+ \\ f, \mathbf{x}, y &\longmapsto \ell(f, \mathbf{x}, y) \end{aligned}$$



Critère d'ajustement : fonction de perte

	Régulier	Singulier
Convexe	logistique $\log(1 + \exp^{-yf(x)})$ L2-gaussien $(f(x) - y)^2$	charnière $(yf(x) - 1)_+$ L1-laplacien $ f(x) - y $
NON convexe	sigmoïde $1 - \tanh(yf(x))$ Cauchy $\log(1 + (f(x) - y)^2)$	$0/1$ $ \text{signe}(f(x)) - y $ Lp - racine $ f(x) - y ^{1/2}$

Table: Quelques exemples de fonctions de perte ℓ . Dans la ligne *c* on retrouve des critères convexes alors que ceux de la ligne *nc* ne le sont pas. Pour le coût charnière, on utilise la notation suivante $(x)_+ = \max(x, 0)$. Dans le cas de la discrimination on a codé les étiquettes $y \in \{-1, 1\}$.

Critère de régularité

	régulier	singulier
convexe	$\mathcal{L}_2$ $\ f\ _2^2$	$\mathcal{L}_1$ $\ f\ _1$
non convexe	normalized $\sum_j \frac{\alpha_j^2}{1 + \alpha_j^2}$	$\mathcal{L}_q, \quad q < 1$ $\ f\ ^q$

$$\|f\|_{\mathcal{H}_f}^2 = \alpha^\top \alpha, \quad \|f\|_{\mathcal{H}}^2 = \alpha^\top K \alpha$$

$$\|f\|_{1,\mathcal{H}_f} = \sum_{i=1}^n |\alpha_i|, \quad \|f\|_{1,\mathcal{H}} = \sum_{i=1}^n |\beta_i| \text{ avec } \beta = L^\top \alpha$$

$$\|f\|_{p,\mathcal{H}}^p = \sum_{i=1}^n |\beta_i|^p \text{ toujours avec } \beta = L^\top \alpha$$

qui, lorsque $p < 1$, n'est plus convexe.

petite nomenclature

ℓ	$h(\mathcal{H})$	Régression	Discrimination
sing.	sing. $\mathcal{L}_1$	Danzig Selector	LP SVM
reg.	sing. $\mathcal{L}_1$	K LASSO K LARS	reg. log. L1
sing.	reg. $\mathcal{L}_2$	SVR	SVM
reg.	reg. $\mathcal{L}_2$	Splines	K-rég. logistique Lagrangien SVM

Table: Récapitulatif de divers algorithmes d'apprentissage selon la nature de leurs fonctions objectifs. SVM et SVR signifient *support vector machine* et *support vector regression*. LP *linear programming*, LARS *Least angle regression stagewise* et reg. log. la régression logistique. Le K. représente la version avec des noyaux ds algorithmes. Certaines de ces méthodes seront détaillées dans la suite du texte.

ℓ_1 engendre la parcimonie : encore plus vite !

Définition : Ensemble d'homogénéité forte (variables)

$$l_0 = \{i \in \{1, \dots, d\} \mid \beta_i = 0\}$$

Théorème

Régulier si $S(\beta) + \lambda T(\beta)$ dérivable en 0 et si $l_0(\mathbf{y}) \neq \emptyset$

$$\forall \varepsilon > 0, \exists \mathbf{y}' \in \mathcal{B}(\mathbf{y}, \varepsilon) \text{ tel que } l_0(\mathbf{y}') \neq l_0(\mathbf{y})$$

Singulier si $S(\beta) + \lambda T(\beta)$ **NON** dérivable en 0 et si $l_0(\mathbf{y}) \neq \emptyset$

$$\exists \varepsilon > 0, \forall \mathbf{y}' \in \mathcal{B}(\mathbf{y}, \varepsilon) \text{ on a } l_0(\mathbf{y}') = l_0(\mathbf{y})$$

Critère singulier $\implies$ parcimonie

Plan

- 1 L'apprentissage statistique**
- 2 Les outils**
- 3 Les méthodes à noyau non parcimonieuses**
- 4 Les méthodes à noyau parcimonieuses**
- 5 Aspects pratiques liés à la mise en œuvre des machines à
- 6 Conclusion

Les splines d'interpolation

Trouver $f \in \mathcal{H}$ telle que $f(\mathbf{x}_i) = y_i$, $i = 1, \dots, n$

C'est un problème mal posé !

$$\begin{cases} \min_{f \in \mathcal{H}} \frac{1}{2} \|f\|_{\mathcal{H}}^2 \\ \text{avec } f(\mathbf{x}_i) = y_i, \quad i = 1, \dots, n \end{cases}$$

$$L(f, \alpha) = \frac{1}{2} \|f\|^2 - \sum_{i=1}^n \alpha_i (f(\mathbf{x}_i) - y_i)$$

$$\nabla_f L(f, \alpha) = 0 \quad \Leftrightarrow \quad f(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}_i, \mathbf{x})$$

$$L(\alpha) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^n \alpha_i y_i \quad K\alpha = y$$

Théorème de représentation

Theorem (Théorème de représentation)

Soit $\mathcal{H}$ un EHNR de noyau $k(s, t)$. Soit ℓ une fonction de Ω sur $\mathbb{R}$ (un critère de fidélité) et Φ une fonction non décroissante de $\mathbb{R}$ dans $\mathbb{R}$. S'il existe une fonction f^* réalisant le minimum du critère suivant :

$$f^* = \underset{f \in \mathcal{H}}{\operatorname{argmin}} \sum_{i=1}^n \ell(y_i, f(\mathbf{x}_i)) + \Phi(\|f\|_{\mathcal{H}}^2)$$

alors il existe un vecteur $\alpha \in \mathbb{R}^n$ tel que :

$$f^*(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}, \mathbf{x}_i)$$

qui peut être généralisé : $+\sum_{j=1}^m \beta_j \phi_j(\mathbf{x})$

Les splines de lissage

$$(S) \quad \begin{cases} \min_{f \in \mathcal{H}} & \frac{1}{2} \|f\|_{\mathcal{H}}^2 + \frac{1}{2\lambda} \sum_{i=1}^n \xi_i^2 \\ \text{avec} & f(x_i) = y_i + \xi_i, \quad i = 1, n \end{cases}$$

$$(S') \quad \min_{f \in \mathcal{H}} \frac{1}{2} \sum_{i=1}^n (f(x_i) - y_i)^2 + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2$$

$$\begin{cases} \min_{f \in \mathcal{H}} & \frac{1}{2} \|f\|_{\mathcal{H}}^2 \\ \text{avec} & \sum_{i=1}^n (f(x_i) - y_i)^2 \leq C' \end{cases} \quad \begin{cases} \min_{f \in \mathcal{H}} & \sum_{i=1}^n (f(x_i) - y_i)^2 \\ \text{avec} & \|f\|_{\mathcal{H}}^2 \leq C'' \end{cases}$$

$$(S'') \quad \min_{\alpha \in \mathbb{R}^n} \frac{1}{2} \|K\alpha - \mathbf{y}\|^2 + \frac{\lambda}{2} \alpha^\top K \alpha$$

$$(S) \Leftrightarrow (S') \Leftrightarrow (S'') \Leftrightarrow (K + \lambda I)\alpha = \mathbf{y}$$

La régression logistique à noyau

$$D(\mathbf{x}) = \text{signe}(f(\mathbf{x}) + \alpha_0) \implies \log \left(\frac{\mathbb{P}(Y=1|\mathbf{x})}{\mathbb{P}(Y=-1|\mathbf{x})} \right) = f(\mathbf{x}) + \alpha_0$$

$$\mathbb{P}(Y = 1|\mathbf{x}) = \frac{\exp^{f(\mathbf{x})+\alpha_0}}{1 + \exp^{f(\mathbf{x})+\alpha_0}} \quad \mathbb{P}(Y = -1|\mathbf{x}) = \frac{1}{1 + \exp^{f(\mathbf{x})+\alpha_0}}$$

$$\mathcal{L}(x_i, y_i, f, \alpha_0) = \mathbb{P}(Y = 1|\mathbf{x})^{\frac{y_i+1}{2}} (1 - \mathbb{P}(Y = 1|\mathbf{x}))^{\frac{1-y_i}{2}}$$

vraisemblance **pénalisée**

$$\begin{aligned} \ell(f, \alpha_0) &= - \sum_{i=1}^n \log(\mathcal{L}(x_i, y_i, f, \alpha_0)) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2 \\ &= \sum_{i=1}^n \log \left(1 + \exp^{-y_i(f(\mathbf{x}_i) + \alpha_0)} \right) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2 \end{aligned}$$

La régression logistique à noyau

$$(\mathcal{R}) \quad \begin{cases} \min_{f \in \mathcal{H}} & \frac{1}{2} \|f\|_{\mathcal{H}}^2 + \frac{1}{\lambda} \sum_{i=1}^n \log(1 + \exp^{-\xi_i}) \\ \text{avec} & \xi_i = y_i (f(\mathbf{x}_i) + \alpha_0), \quad i = 1, n \end{cases}$$

$$\ell(f, \alpha_0) = \mathbb{I}^\top \log(\mathbb{I} + \exp^{\text{diag}(\mathbf{y})K\alpha + \alpha_0\mathbf{y}}) + \frac{\lambda}{2} \alpha^\top K\alpha$$

$$\nabla_{\alpha} \ell(f, \alpha_0) = K(\mathbf{y} - (2\mathbf{p} - \mathbb{I})) + \lambda K\alpha$$


$$H_{\alpha} \ell(f, \alpha_0) = K \text{diag}(\mathbf{p}(\mathbb{I} - \mathbf{p}))K + \lambda K$$

$$\alpha^{\text{new}} = \alpha^{\text{old}} + (K \text{diag}(\mathbf{p}(\mathbb{I} - \mathbf{p}))K + \lambda K)^{-1} K(\mathbf{y} - (2\mathbf{p} - \mathbb{I}) + \lambda \alpha)$$


Plan

- 1 L'apprentissage statistique
- 2 Les outils
- 3 Les méthodes à noyau non parcimonieuses
- 4 Les méthodes à noyau parcimonieuses
- 5 Aspects pratiques liés à la mise en œuvre des machines à
- 6 Conclusion

représentation par caractéristiques...



Espace des formes x



Espace des caractéristiques $k(x,.)$

un point devient une fonction $x \longrightarrow k(x,.)$

Les SVM dans le cas séparable

$$\left\{ \begin{array}{l} \max_{f, \alpha_0} \quad m \\ \text{avec} \quad y_i(f(\mathbf{x}_i) + \alpha_0) \geq m \\ \text{et} \quad \frac{1}{2} \|f\|_{\mathcal{H}}^2 = 1 \end{array} \right. \Leftrightarrow \left\{ \begin{array}{l} \min_{f, \alpha_0} \quad \frac{1}{2} \|f\|_{\mathcal{H}}^2 \\ \text{avec} \quad y_i(f(\mathbf{x}_i) + \alpha_0) \geq 1 \end{array} \right.$$

$$L(f, \alpha_0, \alpha) = \frac{1}{2} \|f\|_{\mathcal{H}}^2 - \sum_{i=1}^n \alpha_i (y_i(f(\mathbf{x}_i) + \alpha_0) - 1)$$

$$\nabla_f L(f, \alpha_0, \alpha) = 0 \quad \Leftrightarrow \quad f(\mathbf{x}) = \sum_{i=1}^n \alpha_i y_i k(\mathbf{x}_i, \mathbf{x})$$

$$\left\{ \begin{array}{l} \max_{\alpha \in \mathbb{R}^n} \quad -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^n \alpha_i \\ \text{avec} \quad \sum_{i=1}^n \alpha_i y_i = 0 \quad \text{et} \quad 0 \leq \alpha_i, i = 1, n \end{array} \right.$$

Les SVM et les exemples

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i y_i k(\mathbf{x}_i, \mathbf{x})$$

type d'exemple	α	valeur de la contrainte
$\mathbf{x}_i$ inutile	$\alpha_i = 0$	$y_i (f(\mathbf{x}_i) + \alpha_0) > 1$
$\mathbf{x}_i$ support	$\alpha_i > 0$	$y_i (f(\mathbf{x}_i) + \alpha_0) = 1$

Table: Tableau récapitulatif des différents types d'exemples en fonction de la solution des SVM. Si l'exemple est « support », il est positionné exactement sur la marge dans l'espace de représentation $\mathcal{H}$.

L'algorithme efficace est là !

parcimonie : $\alpha_i = 0$

Le cas général : les C -SVM

$$(\mathcal{P}) \begin{cases} \min_{f \in \mathcal{H}, \alpha_0, \xi \in \mathbb{R}^n} & \frac{1}{2} \|f\|^2 + \frac{C}{p} \sum_{i=1}^n \xi_i^p \\ \text{avec} & y_i (f(\mathbf{x}_i) + \alpha_0) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, n \end{cases}$$

$p = 1$ ou 2 . C est un paramètre d'équilibrage à fixer a priori.










$p = 1$

$$\begin{cases} \max_{\alpha \in \mathbb{R}^n} & -\frac{1}{2} \alpha^\top H \alpha + \alpha^\top \mathbb{I} \\ \text{avec} & \alpha^\top \mathbf{y} = 0 \text{ et } 0 \leq \alpha_i \leq C \quad i = 1, n \end{cases} \quad (1)$$

$p = 2$, L_2 SVM

$$\begin{cases} \max_{\alpha \in \mathbb{R}^n} & -\frac{1}{2} \alpha^\top \left(H + \frac{1}{C} I \right) \alpha + \alpha^\top \mathbb{I} \\ \text{avec} & \alpha^\top \mathbf{y} = 0 \text{ et } 0 \leq \alpha_i \quad i = 1, n \end{cases}$$

et hop



C grand

C moyen

C petit

+

classe 1

x

classe 2

o

vecteur support

deux autres formulations équivalentes

$$\min_{f \in \mathcal{H}, \alpha_0 \in \mathbb{R}} \frac{1}{p} \sum_{i=1}^n \max(0, 1 - y_i(f(\mathbf{x}_i) + \alpha_0))^p + \frac{1}{2C} \|f\|^2$$

$$\left\{ \begin{array}{l} \min_{\alpha} \quad \|u - v\|_{\mathcal{H}}^2 \\ \text{avec} \quad u(\mathbf{x}) = \sum_{\{i|y_i=1\}} \alpha_i k(\mathbf{x}_i, \mathbf{x}), \quad v(\mathbf{x}) = \sum_{\{i|y_i=-1\}} \alpha_i k(\mathbf{x}_i, \mathbf{x}) \\ \text{et} \quad \sum_{\{i|y_i=1\}} \alpha_i = 1, \quad \sum_{\{i|y_i=-1\}} \alpha_i = 1, \quad 0 \leq \alpha_i \quad i = 1, n \end{array} \right.$$

$$f(\mathbf{x}) = \frac{2}{\|u - v\|_{\mathcal{H}}^2} (u(\mathbf{x}) - v(\mathbf{x})) \quad \text{et} \quad \alpha_0 = \frac{\|u\|_{\mathcal{H}}^2 - \|v\|_{\mathcal{H}}^2}{\|u - v\|_{\mathcal{H}}^2}$$

ν -SVM et autres variantes...

$$\nu \in [0, 1]$$

$$(\nu) \begin{cases} \min_{f, \alpha_0, \xi, m} & \frac{1}{2} \|f\|_{\mathcal{H}}^2 + \frac{1}{np} \sum_{i=1}^n \xi_i^p - \nu m \\ \text{avec} & y_i (f(\mathbf{x}_i) + \alpha_0) \geq m - \xi_i, \quad i = 1, n, \\ \text{et} & m \geq 0, \quad \xi_i \geq 0, \quad i = 1, n, \end{cases}$$

Pour $p = 1$ on obtient la formulation duale suivante :

$$\begin{cases} \max_{\alpha \in \mathbb{R}^n} & -\frac{1}{2} \alpha^\top H \alpha \\ \text{avec} & \alpha^\top \mathbf{y} = 0 \text{ et } 0 \leq \alpha_i \leq \frac{1}{n} \quad i = 1, n \\ \text{et} & \nu \leq \alpha^\top \mathbb{I} \end{cases}$$

$$C = \frac{1}{m}.$$

SVM à coûts dissymétriques

$$\left\{ \begin{array}{l} \min_{f \in \mathcal{H}, \alpha_0, \xi \in \mathbb{R}^n} \quad \frac{1}{2} \|f\|_{\mathcal{H}}^2 + C^+ \sum_{\{i|y_i=1\}} \xi_i^p + C^- \sum_{\{i|y_i=-1\}} \xi_i^p \\ \text{avec} \quad y_i(f(\mathbf{x}_i) + \alpha_0) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, n \end{array} \right.$$

Toujours pour $p = 1$ la formulation duale est la suivante :

$$\left\{ \begin{array}{l} \max_{\alpha \in \mathbb{R}^n} \quad -\frac{1}{2} \alpha^\top H \alpha + \alpha^\top \mathbb{I} \\ \text{avec} \quad \alpha^\top \mathbf{y} = 0 \text{ et } 0 \leq \alpha_i \leq C^+ \text{ ou } C^- \quad i = 1, n \end{array} \right.$$

SVM généralisées

$$\min_{f \in \mathcal{H}, \alpha_0 \in \mathbb{R}} \sum_{i=1}^n \max(0, 1 - y_i(f(\mathbf{x}_i) + \alpha_0)) + \frac{1}{C} \varphi(f) \quad \varphi \text{ convexe.}$$

Le cas particulier $\varphi(f) = \|f\|_p^p$ avec $p = 1$ donne les L1 SVM.

$$\left\{ \begin{array}{l} \min_{\alpha \in \mathbb{R}^n, \alpha_0, \xi} \quad \mathbb{I}^\top \beta + C \mathbb{I}^\top \xi \\ \text{avec} \quad y_i \left(\sum_{j=1}^n \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) + \alpha_0 \right) \geq 1 - \xi_i, \\ \text{et} \quad -\beta_i \leq \alpha_i \leq \beta_i, \quad \xi_i \geq 0, \quad i = 1, n \end{array} \right.$$

avec $\beta = |\alpha|$. Le dual de ce programme linéaire s'écrit alors :

$$\left\{ \begin{array}{l} \max_{\gamma, \delta, \delta^* \in \mathbb{R}^{3n}} \quad \mathbb{I}^\top \gamma \\ \text{avec} \quad \mathbf{y}^\top \gamma = 0, \quad \delta_i + \delta_i^* = 1 \\ \quad \sum_{j=1}^n \gamma_j k(\mathbf{x}_i, \mathbf{x}_j) = \delta_i - \delta_i^*, \quad i = 1, n \\ \text{et} \quad 0 \leq \delta_i, 0 \leq \delta_i^*, 0 \leq \gamma_i \leq C, \quad i = 1, n \end{array} \right.$$

Régression logistique à noyau et machine à vecteurs importés

- ▶ la régression logistique est une méthode structurellement non parcimonieuse.
- ▶ rechercher la solution à partir d'un sous ensemble $\mathcal{S}$ des observations $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_i, \dots, \mathbf{x}_n\}$.
- ▶ construire itérativement l'ensemble $\mathcal{S}$ à la manière d'une méthode de contrainte active, en partant de l'ensemble vide ($\mathcal{S} = \emptyset$) et en ajoutant à chaque itération un exemple $\mathbf{x}_\ell$ judicieusement choisi ($\mathcal{S} = \mathcal{S} \cup \{\mathbf{x}_\ell\}$).
- ▶ Cette astuce permet de recréer artificiellement la parcimonie.

La réduction des SVM

- ▶ objectif : réduire taille du modèle.

- ▶ $f(x) = \sum_{i=1}^{n_s} \beta_i k(\mathbf{x}_i, \mathbf{x}) + c, n_s \ll n$ n_s trop important

- ▶ modèle « compilé » de la forme

$$g(\mathbf{x}) = \sum_{i=1}^{n_c} \beta_i k(\mathbf{z}_i, \mathbf{x}) + c, n_c \ll n_s$$

- ▶ les $\beta, \mathbf{z}_i$ et c sont trouvés en minimisant la fonction coût suivante :

$$\min_{\beta, \mathbf{z}_i, c} \|g - f\|_H^2$$

Certains auteurs suggèrent de choisir $0,03 \leq \frac{n_c}{n_s} \leq 0,1$

SVM et probabilités

$\log \frac{\mathbb{P}(Y = 1|\mathbf{x})}{\mathbb{P}(Y = -1|\mathbf{x})}$ est presque de même signe que $f(\mathbf{x})$

$$\log \frac{\mathbb{P}(Y = 1|\mathbf{x})}{\mathbb{P}(Y = -1|\mathbf{x})} = a_1 f(\mathbf{x}) + a_2$$

$$\mathbb{P}(Y = 1|\mathbf{x}) = 1 - \frac{1}{1 + \exp^{a_1 f(\mathbf{x}) + a_2}}$$

a_1 et a_2 estimés par maximum de vraisemblance. Une autre approche

$$g(\mathbf{x}) - \varepsilon^-(\mathbf{x}) \leq \mathbb{P}(Y = 1|\mathbf{x}) \leq g(\mathbf{x}) + \varepsilon^+(\mathbf{x})$$

$g(\mathbf{x}) = \frac{1}{1 + 4^{-f(\mathbf{x}) - \alpha_0}}$. Les fonctions « non paramétriques » ε^- et ε^+ sont ensuite trouvées car elles doivent vérifier :

$$\begin{aligned} g(\mathbf{x}) + \varepsilon^+(\mathbf{x}) &= \exp^{-a_1(1-f(\mathbf{x})-\alpha_0)+a_2} \\ 1 - g(\mathbf{x}) - \varepsilon^-(\mathbf{x}) &= \exp^{-a_1(1+f(\mathbf{x})+\alpha_0)+a_2} \end{aligned}$$

SVM et probabilités

La seconde approche : poser un modèle a priori.

$$\mathbb{P}(Y = 1|\mathbf{x}) = \frac{\exp^{f(\mathbf{x})+\alpha_0}}{1 + \exp^{f(\mathbf{x})+\alpha_0}}$$

Plus généralement, il est possible d'associer aux machines à noyau une version probabiliste en passant par la famille exponentielle généralisée associée à l'EHRN $\mathcal{H}$ de noyau k sur un domaine Ω par rapport à une mesure de référence μ . En effet, $\forall f \in \mathcal{H}$ on peut définir la mesure de probabilité :

$$\mathbb{P}_f(\mathbf{x}) = \exp^{f(\mathbf{x})-\phi(f)} \quad \phi(f) = \log \int_{\Omega} \exp^{f(\mathbf{x})} d\mu(\mathbf{x})$$

f est appelé le paramètre « naturel » et ϕ la fonction de log partition. Une telle loi existe lorsque la quantité $\log \int_{\Omega} \exp^{f(\mathbf{x})} d\mu(\mathbf{x})$ est bornée ce qui, pour un noyau donné, dépend du choix de la mesure de référence μ .

SVM Multiclasses

- ▶ les méthodes de type « un contre tous »
- ▶ enfin les méthode de type « un contre un »
- ▶ Les méthodes globales (taille $c \times n$),

$$\left\{ \begin{array}{l} \min_{f \in \mathcal{H}, \alpha_0, \xi \in \mathbb{R}^n} \quad \frac{1}{2} \sum_{\ell=1}^c \|f_{\ell}\|_{\mathcal{H}}^2 + \frac{C}{p} \sum_{i=1}^n \sum_{\ell=1, \ell \neq y_i}^c \xi_{i\ell}^p \\ \text{avec} \quad y_i (f_{y_i}(\mathbf{x}_i) + b_{y_i} - f_{\ell}(\mathbf{x}_i) - b_{\ell}) \geq 1 - \xi_{i\ell} \\ \text{et} \quad \xi_{i\ell} \geq 0 \text{ pour } i = 1, \dots, n; \quad \ell = 1, \dots, c; \quad \ell \neq y_i \end{array} \right.$$

estimateur non consistant mais bons résultats en pratiques.

type de méthode	taille de chaque pb.	nombre de problèmes
<i>tous à la fois</i>	$n \times c$	1
<i>1 contre tous</i>	n	c
<i>1 contre 1</i>	$\frac{2n}{c}$	$\frac{c(c-1)}{2}$

SVM à sorties complexes

la sortie $y \in \mathcal{Y}$ est structurée : suite, arbre ou graphe.

utiliser $k(\mathbf{x}, y, \mathbf{x}', y')$ (exemple $k(\mathbf{x}, y, \mathbf{x}', y') = yy' k'(\mathbf{x}, \mathbf{x}')$)

$$\left\{ \begin{array}{l} \min_{f \in \mathcal{H}, \xi \in \mathbb{R}^{n \times \text{card}(\mathcal{Y})}} \quad \frac{1}{2} \|f\|_{\mathcal{H}}^2 + \frac{C}{p} \sum_{i=1}^n \xi_i^p \\ \text{avec} \quad f(\mathbf{x}_i, y_i) - f(\mathbf{x}_i, y) \geq \Delta(y_i, y) - \xi_i \\ \text{et} \quad \xi_i \geq 0, \quad i = 1, n, \quad y \neq y_i \in \mathcal{Y} \end{array} \right.$$

où Δ est une fonction coût positive vérifiant $\Delta(y, y) = 0$.

$$f(\mathbf{x}, y) = \sum_{i=1}^n \sum_{y'=1}^{\text{card}(\mathcal{Y})} \alpha_{iy} (k(\mathbf{x}_i, y_i, \mathbf{x}, y) - k(\mathbf{x}_i, y', \mathbf{x}, y))$$

$$\left\{ \begin{array}{l} \max_{\alpha} \quad -\frac{1}{2} \sum_{i, y \neq y_i}^{\text{card}(\mathcal{Y})} \sum_{j, y' \neq y_j}^{\text{card}(\mathcal{Y})} \alpha_{iy} \alpha_{jy'} J(i, y, j, y') + \sum_{i, y \neq y_i}^{\text{card}(\mathcal{Y})} \alpha_{iy} \\ \text{avec} \quad \sum \frac{\alpha_{iy}}{\Lambda(y_i, y)} \leq C \text{ et } 0 \leq \alpha_{iy}, \quad i = 1, n, \quad y \in \mathcal{Y} \end{array} \right.$$

Plan

- 1 L'apprentissage statistique
- 2 Les outils
- 3 Les méthodes à noyau non parcimonieuses
- 4 Les méthodes à noyau parcimonieuses
- 5 Aspects pratiques liés à la mise en œuvre des machines à noyaux**
- 6 Conclusion

Programmation quadratique et noyau

répartissent les inconnues α dans trois sous ensembles.

$[I_s]$ points **supports** vecteurs supports candidats $0 < \alpha_i < C$.

$[I_c]$ points **saturés** $\alpha_i = C$ on limite leur contribution

$[I_0]$ points **inactifs** : $\alpha_i = 0$ points loin de la frontière ne contribuent pas

initialisation

Tant que (la solution courante n'est pas optimale) **faire**

mettre à jour la répartition des groupes

calculer les coefficients α_i correspondant aux changements

Fait

Algorithme 1: Schéma général des algorithmes de résolution itératifs.

Programmation quadratique et noyau

$$\begin{pmatrix} H_s & y_s \\ y_s^\top & 0 \end{pmatrix} \begin{pmatrix} \alpha_s \\ \alpha_0 \end{pmatrix} = \begin{pmatrix} \mathbb{I} \\ d \end{pmatrix}$$

$$\begin{cases} \alpha_0 = \frac{d - y_s^\top M}{y_s^\top N} \\ \alpha_s = N - \alpha_0 M \end{cases}$$

```
U = chol(H);
M = U / Ut/y;
N = U / Ut/e;
b = (yt*M)/(yt*N);
alpha = N-b*M;
```

% Ut désignant la transposée de U
% e = vecteur de 1

choleski update $\mathcal{O}(ns^2)$

Logiciels

- ▶ <http://asi.insa-rouen.fr/~arakotom/toolbox/>
- ▶ <http://asi.insa-rouen.fr/~gloosli/simpleSVM.html>
- ▶ libsvm⁴ SMO
- ▶ Torch⁵ (écrite en C++).
- ▶ YALE⁶ (*yet another learning environment*)
- ▶ WEKA⁷.
- ▶ Lush⁸. (LASVM, HMM, RNA convolution...)
- ▶ Danzig selector

www.l1-magic.org/

⁴<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>

⁵<http://www.torch.ch/>

⁶<http://yale.cs.uni-dortmund.de>

⁷<http://www.cs.waikato.ac.nz/ml/weka/>

⁸<http://lush.sourceforge.net/>

Réglage des hyperparamètres pour la sélection de modèle

comment explorer - quand s'arrêter ?

- ▶ une grille
- ▶ chemin de régularisation.

$C \leq C_0$ assez petit, la solution est $\alpha_i = \frac{1}{n}$. Tous les points sont dans I_c .

lorsque C augmente il va exister existe un exemple vérifiant $y_i f(\mathbf{x}_i) = 1$.

calculer ce C_0 : car $f(\mathbf{x}_i) = C \sum_{j=1}^n k(\mathbf{x}_i, \mathbf{x}_j)$ on a

$$C_0 = \max_{i=1,n} \frac{1}{\sum_j y_j k(\mathbf{x}_i, \mathbf{x}_j)}.$$

calculer successivement l'ensemble des solutions (C augmente)

Les différentes phases de la mise en œuvre

1. définition des objectifs de l'étude
 - 1.1 choix des entrées et des sortie du modèle
 - 1.2 choix du critère de qualité d'une prévision (3.3)
 - 1.3 choix du noyau (3.2)
2. recueil des données
 - 2.1 nettoyage des données
 - 2.2 définition des données de validation et de test
 - 2.3 choix de l'algorithme d'apprentissage (5)
3. sélection du modèle (6.2)
 - 3.1 choix de la méthode d'évaluation
 - 3.2 sélection des variables
 - 3.3 sélection des hypermaramètres
4. estimation des paramètres du modèle (6.1)

Conclusion

quelques précisions

- ▶ marge : **régularité**
- ▶ noyau de mercer : **noyau positif**
- ▶ SVM : **une méthode parmi d'autres**

- ▶ noyaux (EHNR) **universalité**
- ▶ regularisation **consistance**
- ▶ convexité **efficacité**
- ▶ parcimonie **efficacité**

pas de modèle...

...mais un noyau, un cout, et une régularité !