

Apprentissage et factorisation matricielle pour la recommandation



Décembre 2012, GdR ISIS
Laboratoire d'Informatique, de Traitement de l'Information et des Systèmes

Julien Delporte & Stéphane Canu
stephane.canu@litislab.eu

1 Le problème de la recommandation

- ## 2 Factorisation et apprentissage

- ### 3 Recommandation avec préférences et liens

- Problème Tuenti
- Optimisation alternée
- Résultats expérimentaux



La recommandation de tous les jours

amazon.com Hello, Sign in to get [personalized recommendations](#). New customer? [Start here](#)

Your Amazon.com [Today's Deals](#) [Gifts & Wish Lists](#) [Gift Cards](#)

Shop All Departments Search GO [Cart](#)

MP3 Downloads Getting Started Top Downloads New & Future Releases Install The MP3 Downloader Amazon MP3 Support

PEPSI STUFF [amazonmp3](#) Drink Pepsi, enter Codes, get MP3s [Learn more](#)

amazonmp3
Play Anywhere, DRM-Free Music Downloads

All Songs Compatible with:
iTunes
Windows Media Player

Browse
Events & Deals
Green Music & Musicians
Special Deals
Pepsi Stuff MP3s
Genres
Alternative Rock
Blues
Broadway & Vocalists
Children's Music
Christian & Gospel
Classic Rock
Classical: Instrumental
Classical: Opera & Vocal
Country

Hello, Sign in to get [personalized recommendations](#). New customer? [Start here](#).

New & Notable

 E-MC*
~Maniah Carey

 Hannah Montana...
~Hannah Montana

 Worlds Collide De...
~Apocalyptic

 Lady Antebellum
~Lady Antebellum

 Closer
~Ne-Yo

docstoc Documents & Resources for Small Businesses & Professionals

login Sign In Register

Home Documents Resources Premium Upload

All Documents search all documents Q Search

Ads by Google Business Contract Sample Contract Sample Contracts Agreement Contract

How to use PLS path modeling for analyzing multiblock data sets

DOWNLOAD
PRINT

Ads by Google

Next Generation PCR RainDroptech.com/RainDrop A Billion Reactions. RainDrop dPCR System

Easy Decision Trees www.SmartDraw.com Make Decision Tree Diagrams Fast See Examples. Free Download!

SPSS Data Mining Secrets www.IBM.com/SPSS_data_mining Learn The Keys To Data Mining. Get Your Free SPSS Whitepaper.

Data Mining Automation www.kxen.com/datamining Learn why KXEN was named a Leader. Free Forecaster report. Get it now!

Vacation Rental Software www.instantmanager.com Website, CRM, PMS & Dist Marketing InstantManager - Do the \$1 Switch

Related docs

How to use PLS path modeling for

Recommander musique, films, amis, lieux...

The logo for Yahoo!, featuring the word "YAHOO!" in a red, stylized, sans-serif font with a registered trademark symbol.The logo for YouTube, consisting of the word "You" in black and "Tube" in white inside a red rounded rectangle.The logo for Amazon, featuring the word "amazon" in black with a yellow curved arrow underneath it.The logo for Google, featuring the word "Google" in its multi-colored, sans-serif font.The logo for Netflix, featuring the word "NETFLIX" in white, bold, sans-serif font on a red background.The logo for Twitter, featuring the word "twitter" in a light blue, lowercase, sans-serif font.The logo for Facebook, featuring the word "facebook" in white, lowercase, sans-serif font on a dark blue background.The logo for tuenti, featuring a blue speech bubble icon with a white smiley face and the word "tuenti" in white, lowercase, sans-serif font on a blue background.

Les problèmes liés à la recommandation

Problèmes types

- ▶ la recommandation d'articles (publicité, lignes de code, ...)
- ▶ la recommandation d'amis (à partir de graphes)
- ▶ identification de variables cachées (profiles, groupes, ...)
Latent variables
- ▶ le monde bouge (temps)
- ▶ long tail problem
- ▶ cold start
- ▶ le système de recommandation (pré et post processing)

Les données de base : matrice client/produit

TABLE: Matrice d'achat

		Produit									
Client	0	0	1	0	1	0	0	0	0	0	0
	1	0	0	0	0	1	1	0	0	1	0
	1	1	0	0	0	0	0	0	1	0	0
	0	1	0	0	0	0	0	0	0	0	1
	0	0	0	1	0	0	0	1	0	0	0
	0	0	1		0	0	0	0	1	0	0
	0	1	1	1	0	0	0	0	1	1	1

0 peut signifier :

- ▶ l'utilisateur n'apprécie pas l'article
- ▶ l'utilisateur ne connaît pas l'article (ou n'a pas encore signifié son goût).

Les types de données : matrice client/produit

TABLE: Matrice de vote (*rating*)

		Films									
Spectateur	?	?	4	?	1	?	?	?	?	?	?
	3	?	?	?	?	4	3	?	?	2	?
	1	5	?	?	?	?	?	?	5	?	?
	?	2	?	?	?	?	?	?	?	?	1
	?	?	?	2	?	?	?	2	?	?	?
	?	?	1	?	?	?	?	?	1	?	?
	?	5	3	4	?	?	?	?	1	1	4

? signifie que nous ne connaissons pas l'avis du spectateur

Les types de données : Big Data

La matrice des achats

- ▶ volumineuse
- ▶ creuse
- ▶ datée

Matrice bloc 3d

Autres données possibles

- ▶ Données contextuelles
 - ▶ sur les clients
 - ▶ sur les articles
- ▶ Réseau social
(représentation : graphe)

Matrices associées

Données multi blocs structurés


Données multi blocs (tableaux = matrices)

produits

clients

achats

Données multi blocs (tableaux = matrices)




produits

clients


achats

↑ temps

Données multi blocs (tableaux = matrices)




Données multi blocs (tableaux = matrices)



Résumons nous :

- ▶ systèmes de recommandation disponible.
 - ▶ certains fonctionnent bien
 - ▶ ...et d'autres moins bien
- ▶ moteur : l'exploitation de la matrice d'achat
- ▶ Exploiter *toutes* les données disponibles
 - ▶ multiblocs (temps, utilisateur, produit)
 - ▶ structurés (arbres, graphes, relations)
 - ▶ création de variables cachées : profils
 - ▶ orienté « usage »



Plan de la présentation

1 Le problème de la recommandation

- Les problèmes de recommandation
- Les données : Big Data

2 Factorisation et apprentissage

- Factorisation et décomposition en valeurs singulières
- Factorisation et Netflix
- Apprentissage pour la recommandation

3 Recommandation avec préférences et liens


- Problème Tuenti
- Optimisation alternée
- Résultats expérimentaux



Factorisation matricielle

$$Y = UV + \text{bruit}$$

V (variables latentes items)



Y Matrice des observations : $Y_{3,2} = 5$

Complétion de matrice

$$Y = UV + \text{bruit}$$

V (variables latentes items)

									2						
									0						
									1						

$$U$$
(variables latentes users)

2	1	-3

[illegible]

$$\hat{Y}_{ij} = U_{i\bullet} V_{\bullet j} \quad (\text{problème de complétion})$$

Comment trouver U et V ?

Problème de reconstruction de la matrice Y

$$\begin{array}{ll} \min_{\hat{Y}} & \mathcal{L}(Y, \hat{Y}) := \|Y - \hat{Y}\|_F^2 \\ \text{avec} & \text{rang}(\hat{Y}) = k \end{array}$$

Eckart & Young 1936

Solution : décomposition en valeurs singulières (*SVD*)

$$\hat{Y} = UV \quad (= U'\Sigma V')$$

Méthode de résolution « exacte » sur matrices creuses

- ▶ algorithme : processus de Lanczos
 - ▶ Bidiagonalisation $Y = WBZ$
 - ▶ diagonalisation de B (rotations de givens GVL 8.6.1)
- ▶ logiciel : PROPACK^a

^a. <http://soi.stanford.edu/~rmunk/PROPACK/>

Comment calculer U et V ?

$$\min_{U,V} \mathcal{L}(Y, UV) \quad \text{avec} \quad \text{rang}(U) = \text{rang}(V) = k$$

SGD (Stochastic Gradient Descent)

- ▶ Calcul de gradient
- ▶ règle de mise à jour par descente de gradient
- ▶ $U_i^{NEW} = U_i^{OLD} - p \nabla_{U_i} \mathcal{L}(Y, U, V)$
- ▶ $V_j^{NEW} = V_j^{OLD} - p \nabla_{V_j} \mathcal{L}(Y, U, V)$

Algorithmes efficaces

- ▶ S. Funk process ^a, PLSA, MMMF (Srebro et al, 2004), ...
- ▶ code : RSVD ^b, CofiRank ^c, ...

^a. <http://sifter.org/~simon/journal/20061211.html>

^b. <http://code.google.com/p/pyrsvd/>

^c. <http://www.cofirank.org/>

Optimisation alternée

Formulation Générale

- ▶ $\min_{U, V} \mathcal{L}(U, V, Y) + \Omega(U, V)$
 - ▶ attache aux données : $\mathcal{L}(U, V, Y)$
 - ▶ pénalisation : $\Omega(U, V)$

Algorithme qui passe à l'échelle

- ▶ calculer le gradient et isoler le terme à mettre à jour pour obtenir la règle
- ▶ exemple :
 - pour $L(U, V, Y) = \|UV - Y\|^2$ et $\Omega(U, V) = 0$
 - on a : $\rightarrow U_i = (Y_i V^\top) \cdot (V V^\top)^{-1}$
- ▶ utilisé dans CoFi pour *implicit feedback datasets* [2]

Un succès de la factorisation

Netflix Challenge (2007-2009)

- ▶ Recommandation de films
- ▶ Moteur maison : CineMatch
- ▶ Améliorer les performances de 10%
- ▶ critère : erreur quadratique



Les données

- ▶ 450 000 spectateurs
- ▶ 17 000 films
- ▶ 100 millions d'évaluations (de 1 à 5)
- ▶ taux de remplissage : 1,3 %
- ▶ test sur les 3 millions les plus récents
- ▶ 48 000 téléchargements des données

- ▶ baseline : CineMatch
- ▶ factorisation : SVD régularisée à k facteurs $U_i, V_j \in \mathbb{R}^k$

$$\min_{U,V} \sum_{i,j} (Y_{ij} - U_i^\top V_j)^2 + \lambda(\|U_i\|^2 + \|V_j\|^2)$$

- ▶ **normalisation** : moyenne globale μ , pour l'utilisateur i b_i

$$\min_{U,V} \sum_{i,j} (Y_{ij} - U_i^\top V_j - \mu - b_i - b_j)^2 + \lambda(\|U_i\|^2 + \|V_j\|^2)$$

- ▶ **poids** : *implicit feedback* c_{ij} : niveau de **confiance**

$$\min_{U,V} \sum_{i,j} c_{ij} (Y_{ij} - U_i^\top V_j - \mu - b_i - b_j)^2 + \lambda(\|U_i\|^2 + \|V_j\|^2)$$


- ▶ **temps**

$$\min_{U,V} \sum_{i,j} (Y_{ij} - U_i(t)^\top V_j)^2 + \lambda(\|U_i\|^2 + \|V_j\|^2)$$

- ▶ Mélanges de modèles


Les résultats sur Netflix

- ▶ erreur initiale : 0.9514
- ▶ factorisation - 4 %
- ▶ nombres de facteurs - .5 %
- ▶ améliorations - 2.5 %
 - ▶ normalisation
 - ▶ poids
 - ▶ temps
- ▶ bagging : - 3 % = 0.8563
mélange 100 méthodes



Les leçons de Netflix

- ▶ trop d'efforts spécifiques pour être généralisée
- ▶ **factorisation** *is the solution*
- ▶ **poids** : *implicit feedback*
- ▶ prendre en compte les spécificités (ici l'effet temps)
- ▶ une algorithmique de type **gradient stochastique**
 - ▶ flexible
 - ▶ qui passe à l'échelle



Modèles de complétion de matrice

Régularité

data = info + bruit

$$Y = M + \text{bruit}$$

et M régulière

- ▶ norme(M)
- ▶ rang(M)
 - ▶ factorisation : $M = UV^T$
 - ▶ parcimonie
 - ▶ non linéaire : noyaux
- ▶ blocs (classification croisée)
 - ▶ $M = UBV^T$ $U_{ij} \in \{0, 1\}$
 - ▶ probabiliste : blocs latent

Bruit Modèle de bruit :

- ▶ gaussien $Y_{ij} \sim \mathcal{N}(M_{ij}, \sigma^2)$
- ▶ logistic $Y_{ij} \sim \mathcal{B}(M_{ij})$

problèmes d'optimisation

non convexe et non différentiable

Modèles du bruit : attache aux données

- ▶ continue
 - ▶ Gaussien ℓ_2 : frobenius
 - ▶ entropie
 - ▶ divergences
- ▶ 0/1
 - ▶ distance du χ^2 : AFC
 - ▶ cout logistique
 - ▶ cout charnière
- ▶ Rang
 - ▶ NDCG@k (*Normalized Discounted Cumulative Gain*)
 - ▶ relaxation convexe (CoFiRank)

problèmes d'optimisation

non convexe

Exemple des données 0/1 : l'ACP logistique

- ▶ Observations : $y_{ij} \in \{0, 1\}$
- ▶ Loi de Bernouilli : $Y_{ij} \sim \mathcal{B}(P_{ij}(\theta_{ij}))$
 - ▶ Y_{ij} : le passage à l'acte
 - ▶ P_{ij} probabilité d'acheter
 - ▶ θ_{ij} appétence ou fonction d'utilité

- ▶ Modèle logistique : $P_{ij} = \mathbb{P}(Y_{ij} = 1) = \frac{\exp^{\theta_{ij}}}{1 + \exp^{\theta_{ij}}}$

- ▶ Modèle d'utilité : $\theta_{ij} = \sum_{\kappa=1}^k U_{\kappa,i} V_{\kappa,j} = U_i^\top V_j$

- ▶ Cout : $\min_{U,V} \mathcal{L}(U, V)$

$$\mathcal{L}(U, V) = \sum_i^n \sum_j^p -y_{ij} U_i^\top V_j + \log(1 + \exp^{U_i^\top V_j})$$

Modèles de régularité

- ▶ Rang(M) : Eckart & Young 1936 = SVD
- ▶ norme de Frobenius : $\|U\|_F^2 = \sum_{i,j} U_{ij}^2$
- ▶ norme parcimonieuse : $\|U\|_1 = \sum_{i,j} |U_{ij}|$
- ▶ contraintes de positivité : $U_{i,j} \geq 0$
- ▶ normes d'opérateurs : $\|M\|_p = \sup_x \frac{\|Mx\|_p}{\|x\|_p}$
 - ▶ $p = 1$: max lignes
 - ▶ $p = 2$: max λ_i
 - ▶ $p = \infty$: max colonnes
- ▶ max normes $\|M\|_{q \rightarrow p} = \sup_x \frac{\|Mx\|_p}{\|x\|_q}$
- ▶ norme nucléaire $\|M\|_* = \text{Tr}(\sqrt{M^T M}) = \sum \lambda_i$
- ▶ normes mixtes, groupées, structurées ou pondérées...

problèmes d'optimisation

non convexe et non différentiable

Optimisation non convexe et non différentiable

- ▶ Traitement de la non convexité – cardinalité : $\text{rang}(M)$
 - ▶ relaxation sous modulaire¹
 - ▶ relaxation ℓ_1 (non différentiable) :

$\ell_0 \rightarrow \ell_1$ vue comme son enveloppe convexe

$$\text{rang}(M) \rightarrow \text{norme nucléaire}^2 \|M\|_* = \text{Tr}(\sqrt{M^T M}) = \sum \lambda_i$$

- ▶ Optimisation non convexe et non différentiable³

$$\min_{U, V} J(U, V) = \mathcal{L}(Y, UV) + \lambda \Omega(U, V)$$

$(U^*, V^*) \text{ min loc} \Rightarrow 0 \in \partial_c J(U^*, V^*)$ sous différentielle de **Clark**

1. tutorial MLSS 2012 de F. Bach *Learning with submodular functions* di.ens.fr/~fbach/

2. Pour l'heuristique de la norme nucléaire voir : [Fazel, Hindi, Boyd 01] et [Recht, Fazel, Parillo 08]

3. S. Sra, Scalable nonconvex inexact proximal splitting, NIPS 2012.

Optimisation non convexe et non différentiable

- Réécriture : séparation de la partie non convexe différentiable de la partie non différentiable convexe :

$$J(U, V) = \mathcal{L}(Y, UV) + \lambda \Omega(U, V) = \underbrace{J_1(U, V)}_{\text{différentiable}} + \underbrace{J_2(U, V)}_{\text{convexe}}$$

- Condition d'optimalité locale (stationarité)⁴ :

$$0 \in \partial_c J(U^*, V^*) \iff \nabla J_1(U^*, V^*) \in \partial J_2(U^*, V^*)$$

- Possibilité d'utiliser un algorithme proximal


4. proposition 2.3.3 corollary 1, F. Clarke, Optimization and nonsmooth analysis, 1987

NNMF (Non-Negative Matrix Factorization)

$$Y = UV + b \quad \text{et} \quad V_{ij} \geq 0$$

Coûts usuels

- ▶ Distance euclidienne
- ▶ Divergence de Kullback-Leibler
- ▶ Divergence de Itakura-Saito



Algorithme

- ▶ Algorithme multiplicatif (garantit positivité et parcimonie)^a
- ▶ $U^{NEW} = U^{OLD} \otimes \frac{\nabla_U^- \mathcal{L}(Y, U, V)}{\nabla_U^+ \mathcal{L}(Y, U, V)}$ (idem sur V)

a. voir le site de C. Févotte perso.telecom-paristech.fr/~fevotte

Approches non linéaires

Les réseaux de neurones

- ▶ *Restricted Boltzmann Machines* et architectures profondes,

L'utilisation de noyaux : *kernel-CoFi*

- ▶ données
 - ▶ clients et produits sont des points dans un RKHS
 - ▶ appétence de c pour p : $f(c, p) = \langle c, Fp \rangle$
 - ▶ F est un opérateur (une matrice) et 2 noyaux
- ▶ $\min_F \mathcal{L}(F, Y) + \Omega(F)$
 - ▶ $\Omega(F)$ régularisation (typiquement $\|F\|_F^2$ ou $\|F\|_*$)
- ▶ Algorithme
 - ▶ régularisation spectrale adaptée aux opérateurs [1]
 - ▶ optimisation en dimension finie

Classification croisée – *Co-Clustering*


$$Y = M + \text{bruit}$$

But : Identifier simultanément

- ▶ des groupes d'utilisateurs
- ▶ des groupes d'articles

Algorithmes

- ▶ K-moyennes
- ▶ SVD (*spectral coclustering*)
- ▶ NNM tri Factorisation [3]
- ▶ modèles à blocks latent
- ▶ extension aux blocs de données



voir G. G. Govaert & M. Nadif www.math-info.univ-paris5.fr/~nadifmoh

Social-based recommendation

Recommandation d'amis (Y = graphe social)

- ▶ completion de matrice sur le réseau social
- ▶ utilisation des préférences d'utilisateurs

Graphe social en tant qu'outil

- ▶ appui pour la recommandation d'articles
- ▶ construction de graphes de confiance
- ▶ ...

Résumé

traitement des *big data*

- ▶ modèle
 - ▶ Factorisation
 - ▶ terme d'attache aux données
 - ▶ pénalité
 - ▶ Classification croisée (blocs)
- ▶ algorithmes
 - ▶ gradient stochastique
 - ▶ optimisation alternée
 - ▶ non linéaire et non convexe
- ▶ problème : extension aux données complexes

Plan de la présentation

1 Le problème de la recommandation

- Les problèmes de recommandation
- Les données : Big Data

2 Factorisation et apprentissage

- Factorisation et décomposition en valeurs singulières
- Factorisation et Netflix
- Apprentissage pour la recommandation

3 Recommandation avec préférences et liens

- Problème Tuenti
- Optimisation alternée
- Résultats expérimentaux



Contexte

Tuenti

- ▶ Réseau social espagnol
- ▶ 80% des 14-27 ans l'utilisent
- ▶ Aussi gros que facebook (en Espagne)

le système de recommandation

- ▶ Possibilité d'aimer un lieu (bar, restaurant, théâtre, ...)
- ▶ Recommandation de lieu

Les données


Les tailles

- ▶ 13 millions d'utilisateurs
- ▶ 100000 lieux
- ▶ 200 millions de connexions

				...
user 1	1	0	1	...
user 2	1	1	0	...
user 3	0	0	1	...
user 4	0	1	0	...
⋮	⋮	⋮	⋮	⋮

Parcimonie

- ▶ 4 lieux par utilisateurs
- ▶ 20 amis par utilisateurs



Formulation du problème

fonction objectif

$$\min_{U,V} \sum_{(i,j) \in \mathcal{Y}} c_{ij} (U_i V_j - Y_{ij})^2 + \lambda \Omega_{U,V} \quad (1)$$

- ▶ c_{ij} pour pénaliser les 1 plus que les 0
- ▶ $\Omega_{U,V} = \mu \|U\|_{\text{Fro}}^2 + (1 - \mu) \|V\|_{\text{Fro}}^2$

fonction de décision

$$\hat{Y}_{ij} = U_i V_j \quad (2)$$

Formulation du problème

fonction objectif

$$\min_{U, V, \alpha} \sum_{(i,j) \in \mathcal{Y}} c_{ij} \left(U_i V_j + \sum_{k \in \mathcal{F}_i} \frac{\alpha_{ik} U_k V_j}{|\mathcal{F}_i|} - Y_{ij} \right)^2 + \Omega_{U,V} \quad (1)$$

- ▶ c_{ij} pour pénaliser les 1 plus que les 0
- ▶ $\Omega_{U,V} = \mu \|U\|_{\text{Fro}}^2 + (1 - \mu) \|V\|_{\text{Fro}}^2$
- ▶ $\mathcal{F}_i$ l'ensemble des « amis » de i
- ▶ α_{ik} influence de l'« ami » k sur i ($k \in \mathcal{F}_i$)

fonction de décision « renforcée »

$$\hat{Y}_{ij} = U_i V_j + \sum_{k \in \mathcal{F}_i} \frac{\alpha_{ik} U_k V_j}{|\mathcal{F}_i|} \quad (2)$$

Algorithme

Moindres carrés alternés – SE CoFi

Input : Y and $\mathcal{F}$

initialize U, V and α

Repeat

For each user $i \in \mathcal{U}$

 update U_i

For each item $j \in \mathcal{V}$

 update V_j

For each item $i \in \mathcal{U}$

For each item $k \in \mathcal{F}_i$

 update α_{ik}

Until convergence

Astuce de calcul pour un produit coûteux

La parcimonie entre en jeu

réécrire : $VC^i V^T = VV^T + V_{\mathcal{Y}_i}(C^i - I)_{\mathcal{Y}_i} V_{\mathcal{Y}_i}^T$



- ▶ C^i matrice diagonale dont la majorité des termes est 1.
 - ▶ renforcer les erreur pour $Y_{ij} = 1$
- ▶ influence des lieux : VV^T se calcule une seule fois.
- ▶ $\mathcal{Y}_i$ les lieux visités par i (4 en moyenne)
 - ▶ calcul du produit de droite que pour certaines colonnes de V (4 en moyenne).

Performances en terme de MAP et de RANK

MAP et rang moyen


$$\text{MAP} = \frac{1}{|\mathcal{U}|} \sum_{i=1}^{|\mathcal{U}|} \frac{\sum_{k=1}^{|\mathcal{M}|} P(k) Y_{ik}}{|\mathcal{Y}|}$$

$$\text{RANK} = \frac{\sum_{i,j} Y_{ij} \text{rank}_{ij}}{|\mathcal{Y}|}$$



► tests réalisés
sur un serveur
24 cores avec
100Go RAM

Retour sur les influences des amis



Le principe d'affinité (*homophily*) est vérifié (pas d'influence négative)

Conclusion

Bilan

- ▶ prise en compte de la matrice ET du graphe
- ▶ gestion d'un gros volume de données
- ▶ amélioration de la recommandation de lieux
- ▶ mesure de l'influence

Perspectives

- ▶ utiliser la flexibilité de l'approche
- ▶ prendre en compte les données contextuelles
 - ▶ GPS, types de lieux, ...
- ▶ vers la recommandation d'amis (apprendre tous les α)

Questions



J. Abernethy, F. Bach, T. Evgeniou, and J.P. Vert.

A new approach to collaborative filtering : Operator estimation with spectral regularization.

The Journal of Machine Learning Research, 10 :803–826, 2009.



Y. Hu, Y. Koren, and C. Volinsky.

Collaborative filtering for implicit feedback datasets.

In *Data Mining, 2008. ICDM'08. Eighth IEEE International Conference on*, pages 263–272. Ieee, 2008.



L. Labiod and M. Nadif.

Co-clustering under nonnegative matrix tri-factorization.

In *Neural Information Processing*, pages 709–717. Springer, 2011.