

Les méthodes à noyau et la famille exponentielle

Stéphane Canu¹ et Alex J. Smola²

1- PSI - FRE CNRS 2645
INSA de Rouen, France
St Etienne du Rouvray, France
Stephane.Canu@insa-rouen.fr

2- Statistical Machine Learning Program
National ICT Australia and ANU
Alex.Smola@nicta.com.au

Rennes, 22 Septembre 2005

Deux visions de la théorie de l'apprentissage

	un point de vue	un autre...
Modèle	probabilités	la fonction « cible »
Optimisation	vraisemblance	un contraste
Exemple	mélanges	SVM
pour & contre pour & contre	bien formalisé lent	les besoins peu formel (P ?)

Question ?

comment relier ces deux formalismes ?

Plan de l'exposé

1 Cadre théorique

- les hypothèses : RKHS
- probabilités : la famille exponentielle

2 Discrimination non paramétrique et famille exponentielle

- la famille exponentielle conditionnelle dans un RKHS
- estimation des paramètres : de la fonction au vecteur

3 Le cas de la détection de nouveauté

- détection de rupture
- rapport de vraisemblance généralisé

au début étaient les noyaux...

Definition

- fonction positive : sym. & $\sum_{i=1}^n \sum_{j=1}^m \alpha_i \alpha_j k(x_i, x_j) > 0$
- noyau : une fonction positive $k(x, y) \quad \forall x, y \in \Omega$
- $\mathcal{H}_0 = \{f \in \mathbb{R}^\Omega \mid f(x) = \sum_{i=1}^n \alpha_i k(x, x_i), n \in \mathbb{N}, \alpha_i \in \mathbb{R}, x_i \in \Omega\}$
- produit scalaire sur $\mathcal{H}_0$
$$\langle f(\cdot), g(\cdot) \rangle_{\mathcal{H}_0} = \sum_{i=1}^n \sum_{j=1}^m \alpha_i \beta_j k(x_i, x_j)$$

propriétés du produit scalaire sur $\mathcal{H}_0$

- $\langle f(\cdot), k(x, \cdot) \rangle_{\mathcal{H}_0} = f(x)$ la fonctionnelle d'évaluation
- $\langle k(x, \cdot), k(y, \cdot) \rangle_{\mathcal{H}_0} = k(x, y)$ la propriété de reproduction

du noyau aux hypothèses (et vice-versa)

un espace de Hilbert doit être complet : $\|f\|_{\mathcal{H}_0}^2 = \langle f, f \rangle_{\mathcal{H}_0}$

$$\mathcal{H} = \overline{\mathcal{H}_0}, \quad \mathcal{H} \text{ est un RKHS}$$

definition : RKHS - espace de Hilbert à noyau reproduisant

- un espace de Hilbert
- de fonctions définies ponctuellement $\mathcal{H} \subset \mathbb{R}^\Omega$
- munies d'un noyau k tel que

$$\forall f \in \mathcal{H}, \quad \langle f(\cdot), k(x, \cdot) \rangle_{\mathcal{H}} = f(x)$$

...et dans l'autre sens

si la **fonctionnelle d'évaluation fonctionnel est continue** dans un espace Hilbertien alors c'est un RKHS

démonstration : il existe alors un noyau k (théorème de Riesz)

La famille exponentielle

définition : la famille exponentielle

$$\mathbf{P}(x|\theta) = \mu(x) \exp^{\theta^\top \varphi(x) - g(\theta)}$$

- $\mu(x)$ la mesure support
- $\theta \in \mathbb{R}^d$ les paramètres « naturels »
- $\varphi(x)$ les statistiques suffisantes

$g(\theta)$ la fonction de log partition est **CONVEXE**

$$\int \mathbf{P}(x) dx = 1 \quad \Leftrightarrow \quad g(\theta) = \log \int \exp^{\theta^\top \varphi(x)} \mu(x) dx$$

définition : Domaine

$$\Theta = \left\{ \theta \in \mathbb{R}^d \mid g(\theta) < \infty \right\}$$

probabilités : la famille exponentielle

Exemples : Bernoulli, Normal, power exponential family, même la loi uniforme !

la loi de Bernoulli

- $Y \sim \mathcal{B}(p) \quad p \in [0, 1]$
- $\mathbb{P}(Y = y) = p^y(1 - p)^{1-y}, \quad \forall y \in \{0, 1\}$
 $\mathbb{P}(Y = y) = \exp^{y \log p + (1-y) \log(1-p)},$
 $\mathbb{P}(Y = y) = \exp^{\theta y - g(\theta)},$
 - $\theta = \log \frac{p}{1-p}, \quad g(\theta) = \log(1 + \exp^\theta)$ it is CONVEX

la vraisemblance est CONVEXE

$$\ell(x, \theta) = -\log \mathbb{P}(Y = y)$$
$$\ell(x, \theta) = -\theta y + g(\theta)$$

le changement de paramètres rend la vraisemblance convexe

La famille exponentielle généralisée

definition : la famille exponentielle sur un RKHS

- $\mathcal{H}$ est un RKHS avec son noyau k
- le paramètre naturel est une fonction $\theta \in \mathcal{H}$
- la statistique suffisante est $\varphi(x) = k(x, \cdot)$

$$\mathbf{P}(x) = \mu(x) \exp^{\langle \theta(\cdot), k(x, \cdot) \rangle_{\mathcal{H}} - g(\theta)}$$

- et le domaine : $\theta \in \Theta \subseteq \mathcal{H}$

cadre bayésien : une distribution à priori sur θ

$$\mathbf{P}(\theta) = \frac{1}{Z} \exp^{-\frac{\|\theta\|_{\mathcal{H}}^2}{2\sigma^2}}$$

le domaine Θ est-il vide ?

Définition : noyau admissible pour une mesure μ

un noyau k est admissible pour la mesure μ si

$$\int \exp^{k(x,x)^{1/2}} \mu(x) dx < \infty$$

si le noyau k est admissible pour la mesure μ alors la famille exponentielle est bien définie sur tout le RKHS associé à k :

$$0 \leq g(\theta) < \infty$$

Exemples

- si Ω est borné alors μ est la mesure de lebesgue
- pour $\Omega = \mathbb{R}^d$ et le noyau gaussien il existe une mesure

Maximum a posteriori (MAP)

Le principe du MAP

$$\max_{\theta \in \Theta} \mathbf{P}(\theta | \text{data}) \Leftrightarrow \min_{\theta \in \Theta} -\log \mathbf{P}(\text{data} | \theta) - \log \mathbf{P}(\theta)$$

$$\min_{\theta \in \Theta} J(\theta) = - \sum_{i=1}^n \theta(x_i) + g(\theta) + \frac{1}{2\sigma^2} \|\theta\|_{\mathcal{H}}^2 \quad \text{CONVEXE}$$

rappel : $\theta(x_i) = \langle \theta(\cdot), k(x_i, \cdot) \rangle_{\mathcal{H}}$

ok, mais il faut minimiser par rapport à une **fonction**... pour résoudre ce problème il faut être spécifique !

la famille exponentielle conditionnelle dans un RKHS

Discrimination avec la famille exponentielle conditionnelle

$x \in \Omega$ and $y \in \{-1, 1\}$

la densité exponentielle conditionnelle :

$$\mathbb{P}(y|x; \tilde{\theta}) = \exp(\langle \tilde{\theta}(\cdot, \cdot), \tilde{k}(x, y, \cdot, \cdot) \rangle_{\tilde{\mathcal{H}}} - g(\tilde{\theta}(x)))$$
$$g(\tilde{\theta}(x)) = \log \sum_y \exp(\langle \tilde{\theta}(\cdot), \tilde{k}(x, y, \cdot) \rangle_{\tilde{\mathcal{H}}})$$

il faut retrouver le noyau

$$\tilde{\theta}(x, y) = y\theta(x) \Rightarrow \langle \theta(\cdot), \tilde{k}(x, y, \cdot, \cdot) \rangle_{\tilde{\mathcal{H}}} = y \langle \theta(\cdot), k(x, \cdot) \rangle_{\mathcal{H}}$$

la distribution de Rademacher conditionnelle

$$\mathbb{P}(y|x; \theta) = \exp^{y\theta(x) - g(\theta(x))}$$
$$g(\theta(x)) = \log \left(\exp^{\theta(x)} + \exp^{-\theta(x)} \right)$$

estimation des paramètres : de la fonction au vecteur

MAP pour la discrimination

$$\mathbf{P}(y|x; \theta) = \exp^{y\theta(x) - g(\theta|x)} \quad \mathbf{P}(\theta) = \frac{1}{Z} \exp^{-\frac{\|\theta\|_{\mathcal{H}}^2}{2\sigma^2}}$$

$$J(\theta) = - \sum_{i=1}^n y_i \theta(x_i) + \sum_{i=1}^n g(\theta(x_i)) + \frac{1}{2\sigma^2} \|\theta\|_{\mathcal{H}}^2$$

Dérivée au sens de Gateau

$$\nabla_{\theta} J(\theta) = - \sum_{i=1}^n y_i k(x_i, \cdot) + \sum_{i=1}^n g'(\theta(x_i)) k(x_i, \cdot) + \frac{1}{\sigma^2} \theta(\cdot)$$

Le théorème de représentation

$$\nabla_{\theta} J(\theta) = 0 \quad \Leftrightarrow \quad \theta(\cdot) = \sum_{i=1}^n \underbrace{\sigma^2 (y_i - g'(\theta(x_i)))}_{\alpha_i} k(x_i, \cdot)$$

estimation des paramètres : de la fonction au vecteur

...des fonctions au vecteurs...

$$\min_{\theta \in H} J(\theta) = - \sum_{i=1}^n y_i \theta(x_i) + \sum_{i=1}^n \log \left(\exp^{\theta(x_i)} + \exp^{-\theta(x_i)} \right) + \frac{1}{2\sigma^2} \|\theta\|^2$$

$$\begin{aligned} \theta(x_i) &= \sum_{j=1}^n \alpha_j k(x_i, x_j) \\ \theta &= K\alpha \quad \in \mathbb{R}^n \end{aligned}$$

$$\min_{\alpha \in \mathbb{R}^n} J(\alpha) = -\mathbf{y}^\top K\alpha + \mathbb{I}^\top \log \left(\exp^{K\alpha} + \exp^{-K\alpha} \right) + \frac{1}{2\sigma^2} \alpha^\top K\alpha$$

Le problème d'optimisation dans $\mathbb{R}^n$ est faisable !

estimation des paramètres : de la fonction au vecteur

La regression logistique avec npoyau¹

Quelle décision prendre pour un x donné ?

le discriminateur de Bayes décide suivant le signe du log du rapport de vraisemblance

$$\log \frac{\mathbb{P}(Y = 1|x)}{\mathbb{P}(Y = -1|x)} = 2 \sum_{i=1}^n \alpha_i k(x_i, x)$$

on peut ajouter un seuil

optimisation par méthode itérative : gradient conjugué ou méthode de Newton

$$\nabla_{\alpha} J(\alpha) = -K\mathbf{y} + K \tanh(K\alpha) + \frac{1}{\sigma^2} K\alpha$$

$$\nabla_{\alpha}^2 J(\alpha) = K \left(\left(1 + \frac{1}{\sigma^2} \right) I - \tanh(K\alpha) \tanh(K\alpha)^{\top} \right)$$

estimation des paramètres : de la fonction au vecteur

Résumé du cas de la discrimination à 2 classes

- définir une famille exponentielle dans un RKHS
- se donner un a priori gaussien sur θ
- on optimise le MAP (ou la vraisemblance régularisée ou le MDL)
- utiliser le théorème de représentation : travailler dans $\mathbb{R}^n$

Cette démarche peut être généralisée

- elle s'adapte à différents problèmes (multiclasse, estimation de « densité », regression...)
- on peut changer l'a priori (conjugué, informationel...)
- on peut aussi modifier le contraste (MDL, vraisemblance pénalisée, coût robuste...)

estimation des paramètres : de la fonction au vecteur

Résumé du cas de la discrimination à 2 classes

- définir une famille exponentielle dans un RKHS
- se donner un a priori gaussien sur θ
- on optimise le MAP (ou la vraisemblance régularisée ou le MDL)
- utiliser le théorème de représentation : travailler dans $\mathbb{R}^n$

Cette démarche peut être généralisée

- elle s'adapte à différents problèmes (multiclasse, estimation de « densité », regression...)
- on peut changer l'a priori (conjugué, informationel...)
- on peut aussi modifier le contraste (MDL, vraisemblance pénalisée, coût robuste...)

le cas des SVM

estimation des paramètres : de la fonction au vecteur

les SVM et la famille exponentielle

pour les SVM : utiliser le rapport de log vraisemblance

$$\min_{\theta \in \mathcal{H}} \frac{1}{2} \|\theta\|_{\mathcal{H}}^2 \quad \text{sous les contraintes} \quad R_i := \log \frac{\mathbb{P}(Y = 1|x_i)}{\mathbb{P}(Y = -1|x_i)} \geq 2$$

Rademacher conditionnelle : $\min_{\theta \in \mathcal{H}} 1/2 \|\theta\|_{\mathcal{H}}^2$, avec $2y_i\theta(x_i) \geq 2$

pour les SVM avec erreur

$$\min_{\theta, \xi} \frac{1}{2} \|\theta\|_{\mathcal{H}}^2 + C \sum_{i=1}^n \xi_i \quad \text{avec} \quad \frac{1}{2} \log \frac{\mathbb{P}(Y = 1|x_i)}{\mathbb{P}(Y = -1|x_i)} \geq 1 - \xi_i, \xi_i \geq 0$$

en posant $\xi_i = \max(0, 1 - 1/2 R_i)$


$$\min_{\theta \in \Theta} \sum_{i=1}^n \max \left(1 - \frac{1}{2} \log \frac{\mathbb{P}(y_i|x_i, \theta)}{1 - \mathbb{P}(y_i|x_i, \theta)}, 0 \right) + \frac{1}{2\sigma^2} \|\theta\|_{\mathcal{H}}^2$$

détection de rupture

Détection de nouveauté dans une série²

le problème

détecter un changement
dans la série



$$\underbrace{X_1, X_2, \dots, X_{t-1}, X_t}_{P_0}, \underbrace{X_{t+1}, \dots, X_{2t}}_{P_1}$$

Modèle

$$\begin{cases} \mathcal{H}_0 & : \mathbf{P}_0 = \mathbf{P}_1 \\ \mathcal{H}_1 & : \mathbf{P}_0 \neq \mathbf{P}_1 \end{cases}$$

²F. Desobry and M. Davy, *Support Vector-Based online Detection of Abrupt Changes*, IEEE ICASSP, 2003


Détection de nouveauté dans une série²

un bon outil : le rapport de vraisemblance

$$\Lambda_l(x_1, \dots, x_{2t}) = \frac{\prod_{i=1}^t \mathbf{P}_0(x_i) \prod_{i=t+1}^{2t} \mathbf{P}_1(x_i)}{\prod_{i=1}^{2t} \mathbf{P}_0(x_i)} = \prod_{i=t+1}^{2t} \frac{\mathbf{P}_1(x_i)}{\mathbf{P}_0(x_i)}$$

le problème

détecter un changement
dans la série



$$\underbrace{x_1, x_2, \dots, x_{t-1}, x_t}_{\mathbf{P}_0}, \underbrace{x_{t+1}, \dots, x_{2t}}_{\mathbf{P}_1}$$

Modèle

$$\begin{cases} \mathcal{H}_0 & : \mathbf{P}_0 = \mathbf{P}_1 \\ \mathcal{H}_1 & : \mathbf{P}_0 \neq \mathbf{P}_1 \end{cases}$$

²F. Desobry and M. Davy, *Support Vector-Based online Detection of Abrupt Changes*, IEEE ICASSP, 2003

Rapport de vraisemblance généralisé

$$\Lambda(x_1, \dots, x_{2t}) = \prod_{i=t+1}^{2t} \frac{\hat{\mathbb{P}}_1(x_i)}{\hat{\mathbb{P}}_0(x_i)}$$

$\hat{\mathbb{P}}_0$ and $\hat{\mathbb{P}}_1$ sont les estimateur max de vraisemblance des densités

la famille exponentielle à la rescousse...

$$\mathbb{P}_0(x) = \mu(x) \exp \langle \theta_0(.), k(x, .) \rangle_{\mathcal{H}} - g(\theta_0)$$

$$\mathbb{P}_1(x) = \mu(x) \exp \langle \theta_1(.), k(x, .) \rangle_{\mathcal{H}} - g(\theta_1)$$

SVM pour une classe

$$\hat{\mathbb{P}}_0(x) = \mu(x) \exp \left(\sum_{i=1}^t \alpha_i^{(0)} k(x, x_i) - g(\theta_0) \right)$$

$$\hat{\mathbb{P}}_1(x) = \mu(x) \exp \left(\sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x, x_i) - g(\theta_1) \right)$$

$\alpha_i^{(0)}$ utilise la 1^{ère} partie (x_1 pour x_t) et $\alpha_i^{(1)}$ 2^{ème} moitié (x_{t+1} pour x_{2t})

région d'acceptation des test

$$\Lambda(x_1, \dots, x_{2t}) > s \Leftrightarrow \prod_{j=t+1}^{2t} \frac{\exp \sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x_j, x_i) - g(\theta_1)}{\exp \sum_{i=1}^t \alpha_i^{(0)} k(x_j, x_i) - g(\theta_0)} > s$$

$$\Leftrightarrow \sum_{j=t+1}^{2t} \left(\sum_{i=1}^t \alpha_i^{(0)} k(x_j, x_i) - \sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x_j, x_i) \right) < s + t(b_1 - b_0)$$

s est déterminé pour un risque du premier ordre donné

simplification : $(\sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x_j, x_i))$ presque constant)

$$\sum_{j=t+1}^{2t} \left(\sum_{i=1}^t \alpha_i^{(0)} k(x_j, x_i) \right) < s' + tg(\theta_0)$$

région d'acceptation des test

$$\Lambda(x_1, \dots, x_{2t}) > s \Leftrightarrow \prod_{j=t+1}^{2t} \frac{\exp \sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x_j, x_i) - g(\theta_1)}{\exp \sum_{i=1}^t \alpha_i^{(0)} k(x_j, x_i) - g(\theta_0)} > s$$


$$\Leftrightarrow \sum_{j=t+1}^{2t} \left(\sum_{i=1}^t \alpha_i^{(0)} k(x_j, x_i) - \sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x_j, x_i) \right) < s + t(b_1 - b_0)$$

s est déterminé pour un risque du premier ordre donné

simplification : $(\sum_{i=t+1}^{2t} \alpha_i^{(1)} k(x_j, x_i))$ presque constant

$$\sum_{j=t+1}^{2t} \left(\sum_{i=1}^t \alpha_i^{(0)} k(x_j, x_i) \right) < s' + tg(\theta_0)$$

on évalue le futur à partir du passé - **et c'est rapide !**



Conclusion

Résumons nous

- la famille exponentielle permet de relier les méthodes à noyaux et les probabilités
- transformation des paramètres fonctionnels en paramètres vectoriels
- applicable à de nombreux algorithmes (*boosting...*)
- application aux modèles graphiques (CRF)

Perspectives

- extension à d'autres tests temporels (cusum)
- travailler sur les conséquences pratiques (nouvelles méthodes)
- préciser certains détails du cadre fonctionnel et l'étendre

Questions ?

Des questions ?

`http ://users.rsise.anu.edu.au/~smola`

`http ://asi.insa-rouen.fr/~scanu`