

Le LAR(s)

et autres méthodes de régression parcimonieuse

Stéphane Canu

LITIS

INSA de Rouen, France
St Etienne du Rouvray, France
Stephane.Canu@insa-rouen.fr

Paris, 20 Octobre 2006

- 1 Parcimonie et optimisation multicritère
- 2 le LAR(s)
- 3 SVR
- 4 Formulation à l'aide de noyau

Deux exemples

- Diabete : n individus et d variables

$$X = \begin{pmatrix} \text{age} & \text{sex} & \dots & x_{d=10} \\ 59 & 2 & \dots & 87 \\ \vdots & \vdots & \dots & \vdots \\ 36 & 1 & \dots & 92 \end{pmatrix} ; \mathbf{y} = \begin{pmatrix} \text{diab.} \\ 151 \\ \vdots \\ 57 \end{pmatrix}$$

	AGE	SEX	BMI	BP	...	Serum	Measurements	...	Response		
Patient	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	y
1	59	2	32.1	101	157	93.2	38	4	4.9	87	151
2	48	1	21.6	87	183	103.2	70	3	3.9	69	75
3	72	2	30.5	93	156	93.6	41	4	4.7	85	141
4	24	1	25.3	84	198	131.4	40	5	4.9	89	206
5	50	1	23.0	101	192	125.4	52	4	4.3	80	135
6	23	1	22.6	89	139	64.8	61	2	4.2	68	97
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
441	36	1	30.0	95	201	125.2	42	5	5.1	85	220
442	36	1	19.6	71	250	133.2	97	3	4.6	92	57

Table 1. Diabetes study. 442 diabetes patients were measured on 10 baseline variables. . . prediction model was desired for the response variable, a measure of disease progression one year after baseline.

- microarray* : $n = 38 \ll d = 7126$

- Moindres carrés

$$\text{Cout : } S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2$$

$$\text{prédictions : } \hat{\mu} = X\beta = \sum_{j=1}^d \mathbf{x}_j \beta_j \quad X = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \dots & \mathbf{x}_j & \dots & \mathbf{x}_d \end{bmatrix}$$


solution :

$$\nabla S(\beta) = 0 \quad \Leftrightarrow \quad \underbrace{X^\top (\mathbf{y} - \hat{\mu})}_{\text{corrélations}} = 0 \quad \Leftrightarrow \quad \beta_{\text{MC}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

- régression ℓ_1

$$\min_{\hat{\beta} \in \mathbb{R}^d} \sum_{i=1}^n \left| y_i - \sum_{j=1}^d \mathbf{x}_j \beta_j \right|$$

Le monde bouge



The Gaussian Hare and the Laplacian Tortoise

Computability of ℓ_1 vs. ℓ_2 Regression Estimators.

Portnoy & Koenker 1997

La régression d'hier de d'aujourd'hui

$$y_i = \sum_{j=1}^d x_{ij} \beta_j + \xi_i \quad i = 1, n$$

mmc telle que je l'ai appris	problèmes d'aujourd'hui
n grand	n peut être très grand
d très petit	d grand
$n > d$	$n = d, n \leq d$ ou $\exists j; \beta_j = 0$
ξ_i i.i.d. $\sim \mathcal{N}(0, \sigma^2)$	ξ_i i.i.d. $\sim \mathbf{P} \in \mathcal{P}$
$n \rightarrow \infty$	n fixé, contrôler l'erreur

problème de sélection de modèle

- on est en grande dimension
- il y a beaucoup de $\beta_j = 0$

exemples de ce type de problème

- sélection de variable
statistique
- problème inverse - déconvolution
mathématique, géophysique
- approximation parcimonieuse
informatique
- compression de données - élimination de bruit
Traitement du signal
- Théorie statistique de l'apprentissage

Trois manières d'obtenir la parcimonie

- 1 selection **a priori**
 - test statistique
 - heuristiques
- 2 parcimonie **algorithmique**
 - selection de variable (*forward-backward selection*)
 - *projection pursuit - matching pursuit et OMP*
 - *hard & soft thresholding*
- 3 **critères** parcimonieux
 - a quelle condition un critère entraine de la parcimonie ?

d est grand

nous allons nous focaliser sur les critères

- 1 Parcimonie et optimisation multicritère
- 2 le LAR(s)
- 3 SVR
- 4 Formulation à l'aide de noyau

Formulation générale : il faut régulariser

1 **fidélité aux données**

choisir $S(\beta)$ - par exemple les moindres carrés

2 **régularisation** : définir $T(\beta)$; minimiser $S(\beta)$ et $T(\beta)$

$$\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta) \quad \Leftrightarrow \quad \min_{\beta \in \mathbb{R}^d} S(\beta) \quad \text{avec} \quad T(\beta) \leq t$$

3 **sélection de modèle** : t la complexité du modèle

trouver t ou λ

et disposer d'un algorithme efficace

- critères (S et T) convexes
- parcimonie : $\exists j; \beta_j = 0$

Définition : Ensemble d'homogénéité forte (variables)

$$l_0 = \{i \in \{1, \dots, d\} \mid \beta_i = 0\}$$

Théorème

Régulier si $S(\beta) + \lambda T(\beta)$ dérivable en 0 et si $l_0(\mathbf{y}) \neq \emptyset$

$$\forall \varepsilon > 0, \exists \mathbf{y}' \in \mathcal{B}(\mathbf{y}, \varepsilon) \text{ tel que } l_0(\mathbf{y}') \neq l_0(\mathbf{y})$$

Singulier si $S(\beta) + \lambda T(\beta)$ **NON** dérivable en 0 et si $l_0(\mathbf{y}) \neq \emptyset$

$$\exists \varepsilon > 0, \forall \mathbf{y}' \in \mathcal{B}(\mathbf{y}, \varepsilon) \text{ on a } l_0(\mathbf{y}') = l_0(\mathbf{y})$$

Critère singulier $\implies$ parcimonie

Nikolova, 2000

Quels critères considérer ?

convexe + singulier $\implies \ell_1$

Lasso et Basis pursuit



$$\min_{\beta \in \mathbb{R}^d} \|\mathbf{y} - X\beta\|^2 + \lambda \sum_{i=1}^d |\beta_i| \iff \begin{cases} \min_{\beta \in \mathbb{R}^d} \|\mathbf{y} - X\beta\|^2 \\ \text{avec} \sum_{i=1}^d |\beta_i| \leq t \end{cases}$$

$$\iff \begin{cases} \min_{\beta \in \mathbb{R}^d} \sum_{i=1}^d |\beta_i| \\ \text{avec} \|\mathbf{y} - X\beta\|^2 \leq \epsilon \end{cases}$$

Tibshirani, 1996 ; Chen, Donoho & Saunders, 1999 (Basis pursuit) ;
Donoho *et al.*, 2004 - Tropp 2004

LASSO et parcimonie

$$\begin{cases} \min_{\beta \in \mathbb{R}^2} & S(\beta) = \|\mathbf{y} - X\beta\|^2 \\ \text{avec} & T(\beta) = |\beta_1| + |\beta_2| \leq t \end{cases}$$



Support vector regression - SVR

Minimise le cout ε -insensible avec une régularisation ℓ_2

$$\xi = \max(0, |\mathbf{y} - X\boldsymbol{\beta}| - \varepsilon)$$

$$\left\{ \begin{array}{ll} \min_{\boldsymbol{\beta} \in \mathbb{R}^d} & \frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) \\ \text{avec} & -\varepsilon \mathbf{I} - \xi^- \leq \mathbf{y} - X\boldsymbol{\beta} \leq \varepsilon \mathbf{I} + \xi^+ \\ \text{et} & 0 \leq \xi^+; 0 \leq \xi^- \end{array} \right.$$


Vapnik, 1995

dualité variable - exemples

parcimonie par rapport aux exemples

SVR d'après Smola & Schölkopf

$$\mathcal{L}(\alpha, \xi, \beta) = \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) - \sum_{i=1}^n \alpha_i^+ (\mathbf{y} - X\beta - \varepsilon - \xi_i^+) - \sum_{i=1}^n \alpha_i^- (-\mathbf{y} + X\beta - \varepsilon - \xi_i^-) +$$



$$\beta = \sum_{i=1}^n (\alpha_i^+ - \alpha_i^-) \mathbf{x}_i^\top \iff f(\mathbf{x}) = \sum_{i=1}^n \alpha_i \mathbf{x}_i^\top \mathbf{x}$$

$$\exists i; \alpha_i^+ = \alpha_i^- = 0$$

parcimonie par rapport aux exemples

Le Dantzig selector

$$\begin{cases} \min_{\beta \in \mathbb{R}^d} & \|\beta\|_1 \\ \text{avec} & |X^\top (X\beta - \mathbf{y})| \leq \varepsilon \mathbb{I} \end{cases}$$

C'est de la programmation linéaire

$$\begin{cases} \min_{\beta \in \mathbb{R}^d, \mathbf{u} \in \mathbb{R}^d} & \sum_{i=1}^d u_i \\ \text{avec} & -\mathbf{u} \leq \beta \leq \mathbf{u}; \quad 0 \leq \mathbf{u} \\ \text{et} & -\varepsilon \mathbb{I} \leq X^\top (X\beta - \mathbf{y}) \leq \varepsilon \mathbb{I} \end{cases}$$

Candes & Tao, 2004

pénalisation ℓ_1 - Fidélité ℓ_∞

régulier vs. singulier

$S(\beta)$	$T(\beta)$	Régression	Discrimination
sing.	sing. ℓ_1	Dantzig Selector LP SVR	LP SVM
reg.	sing. ℓ_1	LASSO LARS	régression logistique L1
sing.	reg. ℓ_2	SVR	SVM
reg.	reg. ℓ_2	Ridge	régression logistique Lagrangien SVM

TAB.: SVM et SVR : *support vector machine* et *support vector regression*. LP *linear programming*, LARS *Least angle regression stagewise*.

Sélection de pénalisation

$$T_p(\beta) = \frac{1}{p} \sum_{j=1}^d |P(\beta_j)|^p, \quad P : \text{un projecteur}$$

[Birgé & Massart, 1995]

$$T_\gamma(\beta) = \begin{cases} \sum_{j=1}^d \frac{1}{1-\gamma} \log(2-\gamma) |\beta_j| + \gamma & 0 \leq \gamma < 1 \\ \sum_{j=1}^d \frac{\gamma-1}{2} \beta_j^2 + (2-\gamma) |\beta_j| & 1 \leq \gamma \leq 2 \end{cases}$$

[Friedman, 2006]

- $p = \gamma = 2$ pénalisation ℓ_2 $P = \text{identité}$
- $p = \gamma = 1$ pénalisation ℓ_1
- $p = \gamma = 0$ pénalisation ℓ_0 non convexe
- $0 \leq p, \gamma < 1$ non convexe

Trois stratégies de résolution

- 1 Approches gloutones
 - contraintes actives pour les SVR
 - LARS pour le LASSO
- 2 programmation convexe - points intérieurs
 - LP
 - QP, SOCP *second order cone programming*
- 3 approches stochastiques
 - SMO pour les SVR
 - Décomposition : Projections aléatoires

Mais les approches gloutones peuvent donner le chemin de régularisation

Sélection de modèle : choisir λ

$$\min_{\alpha \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$$

- Tantque on a pas trouvé le bon λ
 - ① choisir un λ
 - ② $\min_{\beta \in \mathbb{R}^d} S(\beta) + \lambda T(\beta)$
 - ③ évaluer la solution
- Pour tous les λ calculer systématiquement tous les $\beta(\lambda)$
 - $\lambda = \infty \implies \beta(\infty) = 0$
 - $\lambda = 0 \implies \beta(0) = \beta_{\text{MC}}$

Chemin de régularisation

$$\{\beta(\lambda) \mid \lambda \in [0, \infty[\}$$