

Le LAR(s)

et autres méthodes de régression parcimonieuse

Stéphane Canu

LITIS

INSA de Rouen, France
St Etienne du Rouvray, France
Stephane.Canu@insa-rouen.fr

Paris, 20 Octobre 2006

1 Parcimonie et optimisation multicritère

2 le LAR(s)

- Lasso, Stagewise et LAR
- Le principe
- L'algorithme du LAR
- LARS et LASSO
- Quand faut t'il s'arrêter

3 SVR

4 Formulation à l'aide de noyau

- tout est centré - variables explicatives standardisées

$$\sum_{i=1}^n y_i = 0 \quad \sum_{i=1}^n x_{ij} = 0 \quad \sum_{i=1}^n x_{ij}^2 = 1 \quad j = 1, d$$

- Moindres carrés

$$\text{Cout : } S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2$$

$$\text{prédictions : } \hat{\mu} = X\beta = \sum_{j=1}^d \mathbf{x}_j \hat{\beta}_j \quad X = \begin{bmatrix} \vdots \\ \mathbf{x}_1 \mathbf{x}_2 \dots \mathbf{x}_j \dots \mathbf{x}_d \\ \vdots \end{bmatrix}$$

solution :

$$\nabla S(\beta) = 0 \quad \Leftrightarrow \quad \underbrace{X^\top (\mathbf{y} - \hat{\mu})}_{\text{corrélations}} = 0 \quad \Leftrightarrow \quad \beta_{\text{MC}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

- le LASSO [Tibshirani 96]

$$\left\{ \begin{array}{l} \min_{\beta \in \mathbb{R}^d} S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec } T(\beta) = \sum_{j=1}^d |\hat{\beta}_j| \leq t \end{array} \right.$$

- Forward Stagewise regression [Weisberg 80]

$$\hat{\mu}^{\text{new}} \leftarrow \hat{\mu}^{\text{old}} + \epsilon \text{sign}(\hat{c}_{\hat{j}}) \mathbf{x}_{\hat{j}}$$

$$\hat{j} = \operatorname{argmax}_{j=1,d} |\hat{c}_j| \quad \hat{c} = X^\top(\mathbf{y} - \hat{\mu}) = \nabla S(\beta)$$

Stagewise = la politique des petits pas

Les méthodes de références





Figure 1. Estimates of regression coefficients $\hat{\beta}_j, j = 1, 2, \dots, 10$, for the diabetes study. *Left Panel* Lasso estimates, as a function of $t = \sum_j |\hat{\beta}_j|$. The covariates enter the regression equation sequentially as t increases, in order $j = 3, 9, 4, 7, \dots, 1$. *Right Panel* The same plot for Forward

Forward Stagewise regression

- 1 initialisation : $\beta = 0$: résidus : $\mathbf{y} - X\beta = \mathbf{y}$
- 2 trouver le prédicteur $\mathbf{x}_j$ le plus corrélé avec le résidu :

$$\max_{j=1,d} |\hat{\mathbf{c}}| \quad \text{avec} \quad \hat{\mathbf{c}} = X^\top (\mathbf{y} - X\beta)$$


- 3 $\beta_j \leftarrow \beta_j + \epsilon'$ avec $\epsilon' = \epsilon \operatorname{sign}(\hat{c}_j)$




Chemin de régularisation (Hastie 05)

Example: Prostate Cancer Data

Lasso



Forward Stagewise



Le LAR (S)

Least Angle Regression


Least Angle Regression (LAR) Efron, Hastie, Johnstone, Tibshirani, Annals of statistics, vol. 32(2), 2004

[http ://www-stat.stanford.edu/~hastie](http://www-stat.stanford.edu/~hastie)

- 1 illustration dans $\mathbb{R}^3$
- 2 l'algorithme de base LAR
- 3 adaptation au LASSO :
LAR **S** = Lasso & Stagewise

Le principe

LAR et Stagewise (Hastie 05)



The LAR direction u_2 at step 2 makes an equal angle with x_1 and x_2 .

LAR = Stagewise + ϵ optimal et variable

Le principe

une méthode itérative constructive

$$\begin{array}{llll}
 \beta_0 = 0 & 0 & \vdots & 0 \\
 \hat{\mu}_0 = X\beta_0 = 0 & \vdots & a & \leftarrow \hat{j}_1 \\
 & 0 & 0 & \\
 \beta_1 \leftarrow \beta_0 + \gamma_1 \mathbf{w}_1 & \mathbf{w}_1 = 1 & \leftarrow \hat{j}_1 & \mathbf{w}_2 = \vdots \\
 \hat{\mu}_1 \leftarrow \hat{\mu}_0 + \gamma_1 \mathbf{x}_1 & 0 & & 0 \\
 & \vdots & & b & \leftarrow \hat{j}_2 \\
 \beta_2 \leftarrow \beta_1 + \gamma_2 \mathbf{w}_2 & 0 & & 0 & \\
 \hat{\mu}_2 \leftarrow \hat{\mu}_1 + \gamma_2 \mathbf{u}_2 & & & \vdots &
 \end{array}$$


une approche de type « contraintes active »

$\mathcal{A}$ l'ensemble des variables actives

Le principe

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables




Départ : tous les β nuls

Le principe

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables




Projection du résidu sur la variable active

Le principe

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables




Calcul du pas, équi-corrélation entre le résidu et deux variables

Le principe

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables




Projection du résidu sur les variables actives

Le principe

LAR : corrélation et géométrie (V. Guigue)

Évolution de la solution dans l'espace des variables



Calcul du pas

L'algorithme du LAR

$\mathcal{A}$ = l'ensemble des variables *intéressantes*

$$\beta_{k+1} \leftarrow \beta_k + \gamma \mathbf{w}_{k+1} \quad \in \mathbb{R}^d$$

$$\beta_{\mathcal{A}} \leftarrow \beta_{\mathcal{A}} + \gamma \mathbf{w}_{\mathcal{A}} \quad \in \mathbb{R}^{\text{card}(\mathcal{A}) \leq d} \quad \beta_{\mathcal{A}} = \beta_k(\mathcal{A})$$

$$\hat{\mu}_{k+1} \leftarrow \hat{\mu}_k + \gamma \mathbf{u}_{k+1} \quad \in \mathbb{R}^n \quad \mathbf{u} = X\mathbf{w} = X_{\mathcal{A}}\mathbf{w}_{\mathcal{A}}$$

le LAR

- 1 trouver la variable à ajouter $j : \mathcal{A} = \mathcal{A} \cup \{j\}$
- 2 calculer la direction de descente $(\mathbf{w}, \mathbf{u} = X\mathbf{w} = X_{\mathcal{A}}\mathbf{w}_{\mathcal{A}})$
- 3 calculer le pas de descente γ

L'algorithme du LAR

$$\begin{aligned}\beta_{\mathcal{A}} &\leftarrow \beta_{\mathcal{A}} + \gamma_k \mathbf{w}_{\mathcal{A}} \\ \hat{\mu}_{k+1} &\leftarrow \hat{\mu}_k + \gamma_k \mathbf{u}_k\end{aligned} \quad \{1, \dots, d\} = \mathcal{A} \cup \mathcal{A}^c$$

- ① trouver la **variable à ajouter** j : maximise le gradient

$$j = \operatorname{argmax}_{j \in \mathcal{A}^c} |\nabla_{\beta_{\mathcal{A}^c}} S(\beta)| = |X_{\mathcal{A}^c}^\top (\mathbf{y} - \hat{\mu})| \quad ; \quad \mathcal{A} = \mathcal{A} \cup j$$

- ② la **direction de descente** : méthode du second ordre

$$\mathbf{w}_{\mathcal{A}} = H^{-1} \nabla_{\beta_{\mathcal{A}}} S(\beta) \quad \begin{cases} \nabla_{\beta_{\mathcal{A}}} S(\beta) = X_{\mathcal{A}}^\top (\mathbf{y} - \hat{\mu}) = c \mathbb{I}_{\mathcal{A}} \\ H = X_{\mathcal{A}}^\top X_{\mathcal{A}} \end{cases}$$

$$(X_{\mathcal{A}}^\top X_{\mathcal{A}}) \mathbf{w}_{\mathcal{A}} = \mathbb{I}_{\mathcal{A}}$$

- ③ calculer le **pas** de descente γ

$$\text{pour conserver la propriété : } X_{\mathcal{A}}^\top (\mathbf{y} - \hat{\mu}) = c' \mathbb{I}$$

que doit on calculer pour chaque opération

- ❶ trouver la variable à ajouter j : $\mathcal{O}(n(d - k))$

$$|X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\mu})|$$

- ❷ la direction de descente : mise à jour (Choleski update)

$$X_{\mathcal{A}} = X_{\mathcal{A}} \cup s_j X_j \quad s_j = \text{sign}(\hat{c}_j)$$

$$(X_{\mathcal{A}}^{\top} X_{\mathcal{A}}) \mathbf{w}_{\mathcal{A}} = \mathbb{I}_{\mathcal{A}} \quad \mathcal{O}(nk + k^2)$$

- ❸ calculer le pas de descente γ , $\mathcal{O}(n(d - k))$

$\Leftrightarrow$ trouver la prochaine variable à ajouter

$$X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\mu}) = \mathbf{c}' \mathbb{I} \quad \Leftrightarrow \quad \mathbf{c}' = \max_{j \in \mathcal{A}^c} |\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\mu})|$$

Calcul du pas $\gamma > 0$ qui conserve l'équicorrélation

Du coté de l'ensemble des variables actives

$$X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_{k+1}) = X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k - \gamma \mathbf{u}) \quad (1)$$

$$= X_{\mathcal{A}}^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k) - \gamma X_{\mathcal{A}}^{\top} \mathbf{u} \quad (2)$$

$$= \mathbf{c} \mathbf{I} - \gamma \mathbf{I} \quad (3)$$

Chaque composante du vecteur des corrélations vaut : $c - \gamma$

$$c - \gamma = \max_{j \in \mathcal{A}^c} |\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_{k+1})| \quad (4)$$

$$= \max_{j \in \mathcal{A}^c} \underbrace{|\mathbf{x}_j^{\top}(\mathbf{y} - \hat{\boldsymbol{\mu}}_k)|}_{c_j} - \gamma \underbrace{|\mathbf{x}_j^{\top} \mathbf{u}|}_{a_j} \quad (5)$$

au maximum j

$$c - \gamma = \begin{cases} c_j - \gamma a_j \\ -c_j + \gamma a_j \end{cases} \Leftrightarrow \gamma = \min_{j \in \mathcal{A}^c}^+ \left(\frac{c - c_j}{1 - a_j}, \frac{c + c_j}{1 + a_j} \right)$$

γ : le plus petit réel positif pour qu'une variable intègre $\mathcal{A}$

évolution de la corrélation




Figure 3. LARS analysis of the diabetes study. *Left:* estimates of regression coefficients $\hat{\beta}_j$, $j = 1, 2, \dots, 10$; plotted versus $\sum |\hat{\beta}_j|$; plot is slightly different than either Lasso or Stagewise, Figure 1. *Right:* Absolute current correlations as function of LARS step; variables enter active set (2,9) in

Adaptation du LAR au LASSO

$$\left\{ \begin{array}{l} \min_{\beta \in \mathbb{R}^d} S(\beta) = \|\mathbf{y} - X\beta\|^2 = \|\mathbf{y} - \hat{\mu}\|^2 \\ \text{avec } T(\beta) = \sum_{j=1}^d |\hat{\beta}_j| \leq t \end{array} \right.$$

si $\exists j$ tel que β_j change de signe

alors on prend γ tel que $\beta_j = 0$ et cette composante quitte l'ensemble actif $\mathcal{A}$

Théorème 1

Avec la modification décrite ci-dessus,

le LARS donne **les** solutions du LASSO

les solutions = le chemin de régularisation $\beta(t)$

Le chemin de régularisation - Théorème 7

$$\beta(t) = \beta(t_0) - (t - t_0) A_A S_A \mathbf{w}_A$$

$$\textcircled{1} \quad \beta(t) = \operatorname{argmin} \|\mathbf{y} - X_A S_A \beta\|^2 \quad \text{avec} \quad \sum_A s_j \beta_j = t$$

$$\textcircled{2} \quad \mathcal{L}(\beta, \lambda) = \|\mathbf{y} - X_A S_A \beta\|^2 + \lambda \left(\sum_A s_j \beta_j - t \right)$$

$$\nabla_{\beta} \mathcal{L}(\beta, \lambda) = S_A^T X_A^T (\mathbf{y} - X_A S_A \beta) + \lambda S_A \mathbf{I} = 0$$

$$\textcircled{3} \quad \nabla \mathcal{L}(t_1) - \nabla \mathcal{L}(t_2) = S_A^T X_A^T X_A S_A (\beta(t_2) - \beta(t_1)) + (\lambda_1 - \lambda_2) S_A \mathbf{I}$$

$$\Leftrightarrow \beta(t_2) - \beta(t_1) = (\lambda_1 - \lambda_2) S_A (X_A^T X_A)^{-1} \mathbf{I}$$

$$\textcircled{4} \quad \mathbf{s}_A (\beta(t_2) - \beta(t_1)) = t_2 - t_1 = (\lambda_1 - \lambda_2) A_A$$

$$\textcircled{5} \quad \beta(t_2) - \beta(t_1) = (t_1 - t_2) A_A S_A \underbrace{(X_A^T X_A)^{-1} \mathbf{I}}_{\mathbf{w}_A}$$

...est linéaire par morceau

Quand faut t'il s'arrêter

Utiliser le C_p de Mallows

$$\mathbf{y} \sim \mathcal{N}(\mu, \sigma^2 I)$$

$$\begin{aligned} (\hat{\mu}_i - y_i)^2 &= (\hat{\mu}_i - \mu_i + \mu_i - y_i)^2 \\ (\hat{\mu}_i - \mu_i)^2 &= (\hat{\mu}_i - y_i)^2 - (\mu_i - y_i)^2 + 2(\hat{\mu}_i - \mu_i)(y_i - \mu_i) \end{aligned}$$

$$\mathbb{E}(\hat{\mu}_i - \mu_i)^2 = \mathbb{E}(\hat{\mu}_i - y_i)^2 - \sigma^2 + 2\text{cov}(\hat{\mu}_i, y_i)$$

$$\mathbb{E} \left(\frac{\|\hat{\mu} - \mu\|^2}{\sigma^2} \right) = \mathbb{E} \left(\frac{\|\hat{\mu} - \mathbf{y}\|^2}{\sigma^2} \right) - n + 2 \sum_{i=1}^n \frac{\text{cov}(\hat{\mu}_i, y_i)}{\sigma^2}$$

$$C_p = \frac{\|\hat{\mu} - \mathbf{y}\|^2}{\sigma^2} - n + 2 \underbrace{\sum_{i=1}^n \frac{\text{cov}(\hat{\mu}_i, y_i)}{\sigma^2}}_{df}$$

$$\widehat{C}_p = \frac{\|\hat{\mu} - \mathbf{y}\|^2}{\widehat{\sigma}^2} - n + 2k$$

...we do not yet have any mathematical support for this claim.

Quand faut t'il s'arrêter

Le C_p au travail sur un exemple





Figure 7. C_p estimates of risk (4.10) for the two situations of Figure 6. *Left Panel* $m = 10$ model has smallest C_p at $k = 7$; *Right Panel* $m = 64$ model has smallest C_p at $k = 16$.

Bilan sur le LAR(s)

Résumons nous

- LARS est efficace
- LARS = LASSO, LARS = *stagewise*
- problèmes de stabilité
→ utiliser plutôt le LARS *stagewise*
- calcule vite le chemin de régularisation
→ point de départ de nouvelles recherches