

Le LAR(s)

et autres méthodes de régression parcimonieuse

Stéphane Canu

LITIS

INSA de Rouen, France
St Etienne du Rouvray, France
Stephane.Canu@insa-rouen.fr

Paris, 20 Octobre 2006

1 Parcimonie et optimisation multicritère

2 le LAR(s)

3 SVR

- SVR et programmation quadratique
- Autour des SVR
- SVR et Chemin de régularisation

4 Formulation à l'aide de noyau

- Au début était le noyau
- un cas d'école
- théorème de représentation
- au delà du théorème de représentation

$$\begin{cases} \min_{\beta \in \mathbb{R}^d} & \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) \\ \text{avec} & -\varepsilon \mathbf{1} - \xi^- \leq \mathbf{y} - X\beta \leq \varepsilon \mathbf{1} + \xi^+ \\ \text{et} & 0 \leq \xi^+; 0 \leq \xi^- \end{cases}$$

Le Lagrangien et les conditions de KKT

$$\begin{aligned} \mathcal{L}(\alpha, \xi, \beta, \nu, \mu) = & \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) + \nu^\top \xi^+ + \mu^\top \xi^- \\ & + \sum_{i=1}^n \alpha_i^+ (\mathbf{y} - X\beta - \varepsilon - \xi_i^+) - \sum_{i=1}^n \alpha_i^- (\mathbf{y} - X\beta + \varepsilon + \xi_i^-) \end{aligned}$$

$$\nabla_{\beta} \mathcal{L} = 0 \iff \beta = X^\top (\alpha_i^+ - \alpha_i^-) \quad \text{Représentation}$$

Formulation Duale

$$\begin{cases} \max_{\alpha^+, \alpha^- \in \mathbb{R}^n} & -\frac{1}{2} (\alpha^+ - \alpha^-)^\top X X^\top (\alpha^+ - \alpha^-) - (\alpha^+ - \alpha^-)^\top \mathbf{y} - \varepsilon \mathbf{1}^\top (\alpha^+ + \alpha^-) \\ \text{avec} & \mathbf{1}^\top (\alpha^+ - \alpha^-) = 0 \\ \text{et} & 0 \leq \alpha^+; \alpha^- \leq C \end{cases}$$

Formulation Duale

$$\begin{cases} \max_{\alpha^+, \alpha^- \in \mathbb{R}^n} & -\frac{1}{2}(\alpha^+ - \alpha^-)^\top X X^\top (\alpha^+ - \alpha^-) - (\alpha^+ - \alpha^-)^\top \mathbf{y} - \varepsilon \mathbf{1}^\top (\alpha^+ + \alpha^-) \\ \text{avec} & \mathbf{1}^\top (\alpha^+ - \alpha^-) = 0 \\ \text{et} & 0 \leq \alpha^+; \alpha^- \leq C \end{cases}$$

QP standard : contraintes de boîtes

$$\begin{cases} \min_{\alpha \in \mathbb{R}^{2n}} & \frac{1}{2} \alpha^\top H \alpha + \mathbf{c}^\top \alpha \\ \text{avec} & \mathbf{d}^\top \alpha = 0 \\ \text{et} & 0 \leq \alpha \leq C \end{cases}$$

l_0	$\mathbf{x}_i$ inutile	$\alpha_i = 0$	$ y_i - \mathbf{x}_i^\top \beta < \varepsilon$
l_s	$\mathbf{x}_i$ support	$0 < \alpha_i < C$	$ y_i - \mathbf{x}_i^\top \beta = \varepsilon$
l_c	$\mathbf{x}_i$ exagéré	$\alpha_i = C$	$ y_i - \mathbf{x}_i^\top \beta > \varepsilon$

$$\begin{cases} \min_{\alpha \in \mathbb{R}^{2n}} & \frac{1}{2} \alpha^\top H \alpha + \mathbf{c}^\top \alpha \\ \text{avec} & \mathbf{d}^\top \alpha = 0 \\ \text{et} & 0 \leq \alpha \leq C \end{cases}$$

Si on connaît l_0 , l_s et l_c , c'est relativement facile

$$\begin{pmatrix} H_s & \mathbf{d}_s \\ \mathbf{d}_s^\top & 0 \end{pmatrix} \begin{pmatrix} \alpha_s \\ \alpha_0 \end{pmatrix} = \begin{pmatrix} \mathbf{c} \\ 0 \end{pmatrix}$$

$$\alpha_s = H_s^{-1}(\mathbf{c} - \mathbf{d}_s \alpha_0)$$

$$\mathbf{d}_s^\top \alpha_s = \mathbf{d}_s^\top H_s^{-1}(\mathbf{c} - \mathbf{d}_s \alpha_0) = 0 \iff \alpha_0 = \frac{\mathbf{d}_s^\top H_s^{-1} \mathbf{c}}{\mathbf{d}_s^\top \mathbf{d}_s}$$

$L = \text{chol}(H);$

$f = L \setminus (L' \setminus c);$

$a0 = (d' * f) / (d' * d);$

$a = L \setminus (L' \setminus (c - d * a0));$

$\%f = H^{-1}c$

$\%a = H^{-1}(c - a0 * d)$

l_0	$\mathbf{x}_i$ inutile	$\alpha_i = 0$	$ y_i - \mathbf{x}_i^\top \boldsymbol{\beta} < \varepsilon$
l_s	$\mathbf{x}_i$ support	$0 < \alpha_i < C$	$ y_i - \mathbf{x}_i^\top \boldsymbol{\beta} = \varepsilon$
l_c	$\mathbf{x}_i$ exagéré	$\alpha_i = C$	$ y_i - \mathbf{x}_i^\top \boldsymbol{\beta} > \varepsilon$

algorithme des contraintes actives - SimpleSVM

initialisation

Tant que (la solution courante n'est pas optimale) **faire**
 mettre à jour la répartition des groupes
 calculer les coefficients α_i

Fait

Autour des SVR

1 d'autres cout
$$\begin{cases} \min_{\beta \in \mathbb{R}^d} & \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n J(\xi_i^+) + J(\xi_i^-) \\ \text{avec} & -\varepsilon \mathbf{1} - \xi^- \leq \mathbf{y} - X\beta \leq \varepsilon \mathbf{1} + \xi^+ \\ \text{et} & 0 \leq \xi^+; 0 \leq \xi^- \end{cases}$$

$$J(\xi) = \xi^2/2 \text{ si } \xi > 1; \quad |\xi| - 1/2 \text{ sinon}$$

2 ν -SVR : $\frac{\text{card}(I_0)}{n} < \nu < \frac{\sum_{i=1}^n J(\xi_i^+) + J(\xi_i^-)}{n}$ (ε variable)

$$\begin{cases} \min_{\beta \in \mathbb{R}^d} & \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n J(\xi_i^+) + J(\xi_i^-) + n\nu\varepsilon \\ \text{avec} & -\varepsilon \mathbf{1} - \xi^- \leq \mathbf{y} - X\beta \leq \varepsilon \mathbf{1} + \xi^+ \\ \text{et} & 0 \leq \xi^+; 0 \leq \xi^- \end{cases}$$

3 pénalisation ℓ_1 : LP SVR

$$\begin{cases} \min_{\beta \in \mathbb{R}^d} & \sum_{i=1}^n \alpha_i^+ + \alpha_i^- + C \sum_{i=1}^n (\xi_i^+ + \xi_i^-) \\ \text{avec} & -\varepsilon \mathbf{1} - \xi^- \leq \mathbf{y} - XX^T(\alpha^+ - \alpha^-) \leq \varepsilon \mathbf{1} + \xi^+ \\ \text{et} & 0 \leq \xi^+; 0 \leq \xi^-; 0 \leq \alpha^+; 0 \leq \alpha^- \end{cases}$$

2 hyperparamètres à régler !


$$\min_{\beta \in \mathbb{R}^d} \frac{1}{2} \|\beta\|^2 + \textcolor{blue}{C} \sum_{i=1}^n \max(0, |y_i - \mathbf{x}_i^\top \beta| - \textcolor{red}{\varepsilon})$$

- $\textcolor{blue}{C}$: la régularité de la solution
- $\textcolor{red}{\varepsilon}$: la largeur du « tube »

les chemins de régularisation

- 1 en fonction de $\textcolor{blue}{C}$ [Gunter & Zhu *et al* 05, Rosset 04]
- 2 en fonction de $\textcolor{blue}{C}$ et de $\textcolor{red}{\varepsilon}$ [Wang *et al* 06]

5 ensembles d'individus à gérer



Lorsque les groupes sont fixés

la solution varie **linéairement** en fonction de C et de ϵ (où de ν)

$$\alpha(C, \epsilon) = \alpha(C_0, \epsilon_0) + \frac{1}{C}(\epsilon - \epsilon_0)\mathbf{d}$$

1 Parcimonie et optimisation multicritère

2 le LAR(s)

3 SVR

- SVR et programmation quadratique
- Autour des SVR
- SVR et Chemin de régularisation

4 Formulation à l'aide de noyau

- Au début était le noyau
- un cas d'école
- théorème de représentation
- au delà du théorème de représentation

Au début était le noyau

Au début était le noyau

Soit k une fonction de deux variables sur $\mathbb{R}$

Noyau positif

Un noyau $k(s, t)$ sur Ω est dit positif s'il est symétrique ($k(s, t) = k(t, s)$) et s'il vérifie pour tout entier n fini :

$$\forall \{\alpha_i\}_{i=1,n} \in \mathbb{R}, \forall \{\mathbf{x}_i\}_{i=1,n} \in \Omega, \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \geq 0$$

Matrice de Gram

Soit $k(s, t)$ un noyau positif sur Ω et $(\mathbf{x}_i)_{i=1,n}$ une suite de points de Ω . On appelle matrice de Gram la matrice carrée K de dimension n et de terme général $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$.

Au début était le noyau

zoologie kernelistique...

type	nom	$k(s, t)$
radial	gaussien	$\exp\left(-\frac{r^2}{b}\right), \quad r = \ s - t\ $
radial	laplacien	$\exp(-r/b)$
radial	rationnel	$1 - \frac{r^2}{r^2 + b}$
radial	loc. gauss.	$\max\left(0, 1 - \frac{r}{3b}\right)^d \exp\left(-\frac{r^2}{b}\right)$
non stat	χ^2	$\exp(-r/b), \quad r = \sum_k \frac{(s_k - t_k)^2}{s_k + t_k}$
projectif	polynôme	$(s^\top t)^p$
projectif	affine	$(s^\top t + b)^p$
projectif	cosinus	$s^\top t / \ s\ \ t\ $
projectif	corrélation	$\exp\left(\frac{s^\top t}{\ s\ \ t\ } - b\right)$

TAB.: Quelques exemples de noyaux usuels pour $\Omega = \mathbb{R}^d$. Les noyaux dépendent d'un paramètre de largeur de bande b qui caractérise l'amplitude de leur zone d'influence.

Au début était le noyau

Il est beau mon noyau...

- des histogrammes (comme le noyau dit du χ^2),
- des chaînes de caractères ou des mots
- et même des graphes.
- des mesures de probabilités
- même complexes comme celles des images où des modèles de Markov cachés,

Au début était le noyau

$$\mathcal{H}_0 = \left\{ f \mid m_f < \infty; f_j \in \mathbb{R}; t_j \in \Omega, f(\mathbf{x}) = \sum_{j=1}^{m_f} f_j k(\mathbf{x}, t_j) \right\}$$

$g(\mathbf{x}) = \sum_{i=1}^{m_g} g_i k(\mathbf{x}, s_i)$: forme bilinéaire positive :

$$\forall f, g \in \mathcal{H}_0, \langle f, g \rangle_{\mathcal{H}_0} = \sum_{j=1}^{m_f} \sum_{i=1}^{m_g} f_j g_i k(t_j, s_i)$$

qui définit un produit scalaire - espace pré-hilbertien

$$\forall f \in \mathcal{H}_0, \forall \mathbf{x} \in \Omega, f(\mathbf{x}) = \langle f(\cdot), k(\mathbf{x}, \cdot) \rangle_{\mathcal{H}_0}$$

espace de Hilbert à noyau reproduisant

Un espace de Hilbert $\mathcal{F}$ muni du produit scalaire $\langle \cdot, \cdot \rangle_{\mathcal{F}}$ est dit « à noyau reproduisant » s'il existe un noyau k pour lequel :

$$\forall s \in \Omega, k(\cdot, s) \in \mathcal{F} \text{ et } \forall f \in \mathcal{F}, f(s) = \langle f(\cdot), k(s, \cdot) \rangle_{\mathcal{F}}$$

un cas d'école

$$\begin{cases} \min_{f \in \mathcal{H}} & \frac{1}{2} \|f\|_{\mathcal{H}}^2 \\ \text{avec} & f(\mathbf{x}_i) = y_i, \quad i = 1, \dots, n \end{cases}$$

lagrangien L multiplicateurs de Lagrange $\alpha_i, i = 1, \dots, n$:

$$L(f, \alpha) = \frac{1}{2} \|f\|^2 - \sum_{i=1}^n \alpha_i (f(\mathbf{x}_i) - y_i)$$

$$\nabla_f L(f, \alpha) = 0 \quad \Leftrightarrow \quad f(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}_i, \mathbf{x})$$

car $f(\mathbf{x}_i) = \langle f(\cdot), k(\mathbf{x}_i, \cdot) \rangle_{\mathcal{H}}$ **reproduction**

le problème dual :

$$\max_{\alpha \in \mathbb{R}^n} L(\alpha), \text{ avec } L(\alpha) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^n \alpha_i y_i$$

théorème de représentation

Théorème de représentation

Soit $\mathcal{H}$ un EHNR de noyau $k(s, t)$. Soit S une fonction de Ω sur $\mathbb{R}$ (un critère de fidélité) et Φ une fonction non décroissante de $\mathbb{R}$ dans $\mathbb{R}$. S'il existe une fonction f^* réalisant le minimum du critère suivant :

$$f^* = \operatorname{argmin}_{f \in \mathcal{H}} \sum_{i=1}^n S(y_i, f(\mathbf{x}_i)) + \Phi(\|f\|_{\mathcal{H}}^2)$$

alors il existe un vecteur $\alpha \in \mathbb{R}^n$ tel que :

$$f^*(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}, \mathbf{x}_i)$$

deux approches pour la *kernelisation*

- 1 le noyau comme dictionnaire de données

$$X = K \implies n = d$$

matrice de Gram : $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$

- 2 formulation fonctionnelle (pour les pénalisations ℓ_2)

$$k(\mathbf{x}_i, \mathbf{x}_j) \text{ représente } \mathbf{x}_i^\top \mathbf{x}_j \iff XX^\top = K$$

l'enjeu

- ne pas calculer $K^\top K$
- ne pas calculer toute la matrice K

au delà du théorème de représentation

noyaux et représentation

$$\mathcal{H}_f = \left\{ f : \Omega \mapsto \mathbb{R} \mid \exists \alpha_i \in \mathbb{R}, i = 1, n; f(\mathbf{x}) = \sum_{i=1}^n \alpha_i k(\mathbf{x}, \mathbf{x}_i) \right\}$$

$$\mathcal{H}_0 = \left\{ f \mid m_f < \infty; f_j \in \mathbb{R}; t_j \in \Omega, f(\mathbf{x}) = \sum_{j=1}^{m_f} f_j k(\mathbf{x}, t_j) \right\}$$

$$\min_{f \in \mathcal{H}_f}$$

$$\neq$$

$$\min_{f \in \mathcal{H}}$$


$$\min_{\alpha \in \mathbb{R}^n}$$

$$\neq$$

$$\min_{\alpha \in \mathbb{R}^n}$$

Conclusions

- Statistique et optimisation
- **parcimonie** - passage à l'échelle
- **noyaux** - un dictionnaire de données pratique
- **Chemin de régularisation** - LARS



Compressive imaging
[Baraniuk et al, 2006]

Perspectives

- kernelisation du LASSO et du sélecteur
- approches stochastique
- apprentissage robuste

Questions ?

Des questions ?

LAR(s) (et svmpath) en R
Matlab

www-stat.stanford.edu/~hastie

asi.insa-rouen.fr/~vguigue/LARS.html

kernlab cran.r-project.org/src/contrib/Descriptions/kernlab.html
SVR Matlab asi.insa-rouen.fr/~arakotom

Danzig selector

www.ll-magic.org/

- Least Angle Regression. Least angle regression, Bradley Efron, Trevor Hastie, Iain Johnstone and Robert Tibshirani ; Annals of statistics, vol. 32 (2), pp.407-499, 2004
- A tutorial on support vector regression, A. Smola and B. Scholkopf, Statistics and Computing 14(3), pp 199-222, 2004
- The Dantzig selector : Statistical estimation when p is much smaller than n , Emmanuel Candes and Terence Tao Submitted to IEEE Transactions on Information Theory, June 2005.
- Two-Dimensional Solution Path for Support Vector Regression, Gang Wang, Dit-Yan Yeung, Frederick H. Lochovsky, ICML, 2006
- Piecewise Linear Regularized Solution Paths, Saharon Rosset, Ji Zhu. Annals of Statistics, to appear, 2006
- Algorithmic linear dimension reduction in the l_1 norm for sparse vectors, A. C. Gilbert, M. J. Strauss, J. A. Tropp, and R. Vershynin, 2006 (submitted).
- An iterative thresholding algorithm for linear inverse problems with a sparsity constraint, I. Daubechies, M. Defrise and C. De Mol, Comm. Pure Appl. Math, 57, pp.1413-1541, 2004.
- Local strong homogeneity of a regularized estimator, Mila Nikolova, SIAM Journal on Applied Mathematics, vol. 61, no. 2, pp. 633-658, 2000.